
Étude d'ajustement contrastif de l'encodeur sémantique sur le corpus SocialGouv

Auteur principal :	Remy RAYANE (Responsable D2 & Issue #49)
Soutien & Relecture :	Mahé BEGNIS, Jibril BENSALEM
Date :	6 octobre 2026
Référence :	Issue GitHub #49 (feat/49-ajustement-encodeur)
Statut :	Exécuté intégralement, validé statistiquement, prêt pour revue

Table des matières

1	Contexte et Objectifs	2
1.1	Contraintes méthodologiques strictes	2
2	Protocole expérimental et Découpage des données	2
2.1	Le Banc de Test de Référence (Ground Truth)	2
2.2	Cloisonnement Anti-Fuite (Train Exclusion Set)	2
2.3	Génération synthétique locale (Qwen2.5-7B)	3
3	Ajustement Contrastif de l'Encodeur	3
3.1	Architecture et Fonction de Perte	3
3.2	Hyperparamètres d'entraînement	3
3.3	Convergence de la perte	3
4	Résultats et Validation Statistique	4
4.1	Tableau comparatif des métriques de recherche	4
4.2	Analyse des résultats	4
5	Export ONNX et Contrôles de Parité	4
5.1	Fichiers générés	5
5.2	Contrôles de conformité	5
6	Synthèse et Livrables de l'Issue #49	5

1 Contexte et Objectifs

Le sujet du projet impose que l'application de recherche sémantique du Volet A ne se contente pas d'exécuter un modèle générique sur étagère, mais s'appuie sur un modèle adapté au domaine juridique du Code du travail et des fiches pratiques du ministère du Travail (SocialGouv).

L'**Issue #49** a pour objet d'ajuster finement l'encodeur `intfloat/multilingual-e5-small` par **apprentissage contrastif** (*contrastive learning*) sur des paires (question, passage) représentatives du corpus, et d'en mesurer scientifiquement le gain par un protocole expérimental apparié et reproductible.

1.1 Contraintes méthodologiques strictes

1. **Étanchéité absolue (*Zero Data Leakage*)** : Aucune fiche, aucun passage et aucune question du jeu de test (Issue #44 / PR #54) ne doit servir à l'entraînement ou à la sélection du modèle.
2. **Préservation du protocole E5** : Conservation systématique des préfixes obligatoires (`query:` pour les requêtes et `passage:` pour les documents).
3. **Évaluation statistique appariée** : Calcul des métriques de rang (`Recall@k`, `MRR@10`) avec test exact de McNemar et test d'Obuchowski (données groupées par fiche) pour trancher la significativité statistique de l'écart.
4. **Portabilité navigateur (ONNX & Quantification)** : Export ONNX FP32, quantification dynamique INT8 (q8) et vérification des critères de parité et fidélité établis au Notebook 02.
5. **Gestion des artefacts hors Git** : Les poids PyTorch et les fichiers `.onnx` dépassant 100 Mio restent exclus du versionnement Git (règle stricte du projet).

2 Protocole expérimental et Découpage des données

2.1 Le Banc de Test de Référence (Ground Truth)

Le benchmark d'évaluation est constitué à partir du jeu de 105 questions annotées de l'équipe (Issue #44, PR #54) :

- **72 questions de test dans_corpus** ont été appariées à leurs passages cibles dans le découpage structurel **M2** (`data/decoupage/passages/passages_m2.parquet`, 4 240 passages).
- Le jeu couvre 67 fiches pratiques distinctes du ministère du Travail.

2.2 Cloisonnement Anti-Fuite (Train Exclusion Set)

Pour empêcher toute mémorisation de surface ou surapprentissage sur les questions évaluées :

- **Exclusion au niveau de la fiche (URL)** : Les 67 fiches associées au jeu de test et au lot de calibration ont été **totalelement** **proscrites** de la phase d'entraînement.
- **Volume exclu** : 1 463 passages exclus sur 4 240 (soit **34,5 % du corpus**).
- **Vivier d'entraînement** : 2 777 passages issus de **194 fiches vierges** de toute évaluation.

2.3 Génération synthétique locale (Qwen2.5-7B)

L'inférence locale validée dans le cadre de l'Issue #31 (qwen2.5-7b-instruct:q4_k_m-local exécuté via Ollama) a été mise à profit pour générer des questions d'utilisateurs réalistes :

- **Échantillonnage stratifié** : 110 passages candidats représentatifs sélectionnés sur 110 fiches distinctes (longueur médiane ~250 tokens).
- **Prompting de rôle** : Requêtes formulées du point de vue d'un salarié ou citoyen cherchant une réponse concrète, sans méta-références (« selon le texte », etc.).
- **Filtrage automatique** :
 - Contrôle syntaxique (interrogation finale, longueur entre 25 et 220 caractères).
 - Contrôle de non-recouvrement lexical : rejet automatique si la similarité Jaccard sur les tokens avec une question du jeu de test dépasse 0,40.
- **Résultat** : **109 paires validées**, 1 rejetée. Un échantillon de contrôle a été audité manuellement dans data/adaptation/echantillon_controle_train.json.

3 Ajustement Contrastif de l'Encodeur

3.1 Architecture et Fonction de Perte

- **Modèle de départ** : intfloat/multilingual-e5-small (117 millions de paramètres, dimension 384).
- **Fonction de perte** : MultipleNegativesRankingLoss (MNRL).
- Pour chaque mini-batch de taille B , la perte maximise la similarité cosinus entre la question $\mathbf{q}_i$ et son passage cible $\mathbf{p}_i$, tout en utilisant l'ensemble des $B-1$ autres passages du lot comme négatifs implicites (*in-batch negatives*).
- Température / facteur d'échelle : échelle standard SentenceTransformers ($s = 20.0$).

3.2 Hyperparamètres d'entraînement

Les hyperparamètres ont été choisis pour adapter le modèle au vocabulaire du droit du travail sans détruire sa structure multilingue pré-entraînée (*catastrophic forgetting*) :

- **Taille de lot (*batch size*)** : 16 (soit 15 négatifs par exemple).
- **Taux d'apprentissage (*learning rate*)** : 2×10^{-5} avec optimiseur AdamW et décroissance linéaire.
- **Époques** : 2 (14 pas d'optimisation).
- **Warmup** : 10 % des étapes.
- **Durée d'entraînement** : 185,5 secondes sur CPU (16 cœurs).

3.3 Convergence de la perte

Étape (sur 14)	Époque	Training Loss	Norme du Gradient
2	0.29	1.5610	12.11
4	0.57	1.3730	8.47
6	0.86	0.8857	7.60

Étape (sur 14)	Époque	Training Loss	Norme du Gradient
8	1.14	0.7160	6.74
10	1.43	0.4952	6.66
12	1.71	0.6111	7.29
14	2.00	0.4717	5.75

La perte a décru de manière régulière et robuste (de 1,56 à 0,47), confirmant un apprentissage efficace sans instabilité.

4 Résultats et Validation Statistique

L'évaluation compare les performances de récupération d'information (*Information Retrieval*) avant et après ajustement, en indexant la totalité des **4 240 passages M2** et en interrogeant le modèle avec les **72 questions de test**.

4.1 Tableau comparatif des métriques de recherche

Métrique	Avant (Base pré-entraîné)	Après (Modèle ajusté)	Gain absolu	Valeur p (McNemar / Obuchowski)	Significatif ($\alpha = 0.05$)
Recall@1	19,44 %	26,39 %	+6,94 %	$p = 0.2004$	Non
Recall@3	37,50 %	51,39 %	+13,89 %	$p = 0.0080$	OUI ($p < 0.01$)
Recall@5	43,06 %	62,50 %	+19,44 %	$p = 0.0002$	OUI ($p < 0.001$)
Recall@10	58,33 %	73,61 %	+15,28 %	$p = 0.0048$	OUI ($p < 0.01$)
MRR@10	0,3250	0,4203	+0,0954	—	—

4.2 Analyse des résultats

- Bond spectaculaire sur Recall@5 (+19,44 points)** : Le Recall@5 passe de 43,06 % à 62,50 %. La valeur p du test apparié avec regroupement par fiche est de **\$0.0002\$**, ce qui démontre une amélioration hautement significative sur le plan statistique.
- Gain substantiel en précision de premier rang (MRR@10 : +0,0954)** : Le rang réciproque moyen passe de 0,325 à 0,420, signifiant que le passage pertinent apparaît désormais en moyenne entre la 2e et la 3e position au lieu de la 3e et 4e position.
- Généralisation confirmée hors fiches vues** : Puisque l'entraînement a été effectué exclusivement sur des fiches différentes de celles du test, ce gain atteste que l'encodeur a appris à mieux aligner le style interrogatif des citoyens français avec le formalisme juridique des fiches du ministère, sans aucun effet de mémorisation brute.

5 Export ONNX et Contrôles de Parité

Pour permettre le déploiement dans le navigateur client via **Transformers.js** (Volet A), le modèle PyTorch affiné a été converti en ONNX et quantifié selon les exigences du Notebook 02.

5.1 Fichiers générés

Format	Fichier	Taille disque	Rôle applicatif
FP32	models/multilingual-e5-small-finetuned/onnx/model.onnx	448,5 Mio	Modèle de référence ONNX haute précision
INT8 (q8)	models/multilingual-e5-small-finetuned/onnx/model_quantized.onnx	112,7 Mio	Modèle compact servi au navigateur Web

5.2 Contrôles de conformité

- Contrôle 1 : Parité numérique FP32 (PyTorch vs ONNX FP32) :**
 - Cosinus minimal :** \$1.00000000\$ (seuil de parité strict : \$\ge 0.99999\$).
 - Écart absolu maximal composante :** \$1,17 \times 10^{-7}\$.
 - Statut : VALIDÉ AVEC SUCCÈS.**
-
- Contrôle 2 : Fidélité de la quantification INT8 (PyTorch FP32 vs ONNX q8) :**
 - Cosinus médian :** \$0.9834\$ (seuil attendu : \$\ge 0.98\$).
 - Cosinus minimal :** \$0.9789\$ (seuil : \$\ge 0.97\$).
 - Concordance du Top-1 :** \$100,0\%\$ sur le banc de validation.
 - Statut : VALIDÉ AVEC SUCCÈS.**

6 Synthèse et Livrables de l'Issue #49

Tous les critères de validation et livrables de l'Issue #49 sont rigoureusement remplis :

- x **Génération de paires synthétiques avec le modèle local :** 109 paires question-passage générées avec Qwen2.5-7B local.
- x **Filtrage et contrôle d'échantillon :** Validé et consigné dans data/adaptation/echantillon_controle_train.json.
- x **Vérification d'absence de fuite du test :** 67 fiches totalement exclues du train set, contrôle Jaccard < 0.40.
- x **Ajustement contrastif (négatifs du lot) :** Réalisé avec MultipleNegativesRankingLoss et préfixes query: / passage: .
- x **Mesure avant/après appariée :** Recall@5 en hausse de **+19,44 pts** (\$p = 0.0002\$).
- x **Conversion ONNX et contrôles notebook 02 :** Parité FP32 (\$1.00000000\$) et fidélité q8 validées.
- x **Poids hors Git :** Dossier models/ protégé par le .gitignore.