
Protocole d'évaluation de la recherche du volet A (notebook 03)

Équipe	Data Tigers
Projet	NLP 2 · Master 2 Data & IA · FGES, Université Catholique de Lille
Ticket	Issue #46 · Branche feat/46-notebook-03
Responsable principal	Mahé BEGNIS
Soutien	Remy RAYANE
Statut	figé le 10 octobre 2026, avant toute mesure : décisions D1 à D8 validées au Weekly 4 du 7 octobre (#10)

Table des matières

1	Objet et règle d'emploi	2
2	Données	2
2.1	Jeu de questions (#44)	2
2.2	Corpus et index	3
2.3	Complément CDTN (#56)	3
3	Règle de pertinence (D4)	3
4	Systèmes comparés	4
5	Métriques	4
6	Analyse principale (D1, D2, D3)	5
7	Analyses secondaires (D7)	5
8	Sigles, abstention et CDTN	6
8.1	Sigles	6
8.2	Abstention (D6)	6
8.3	CDTN	6
9	Mise en œuvre et reproductibilité	6
10	Décisions validées au Weekly 4 (7 octobre 2026, #10)	7
11	Historique	7

1 Objet et règle d'emploi

Ce protocole fixe, avant toute mesure sur le lot de test, la règle de pertinence, les systèmes comparés, les métriques, l'analyse principale, les analyses secondaires et leurs règles de décision.

- **Figé avant la mesure.** Une fois validé, il est figé par un commit, et son empreinte SHA-256 est inscrite dans le notebook 03. Le notebook refuse de lire le lot de test si l'empreinte ne correspond pas.
- **Rien d'autre n'est conclusif.** Toute analyse absente de ce document est présentée comme exploratoire.
- **Déclaration.** Le 6 octobre 2026, un aperçu de l'encodeur sur le jeu de questions a été calculé pendant un audit, hors protocole (journal d'usage de l'IA, section 4). Aucune décision ci-dessous ne s'appuie sur lui : chacune est justifiée par le rapport J2, par la validation sur PIAF (#45), par les annotations seules ou par un calcul de puissance.
- **Seconde déclaration.** Le 6 octobre 2026, la PR #63 (ajustement de l'encodeur, #49) a mesuré l'encodeur de base et l'encodeur ajusté sur les 72 questions du corpus du lot de test, avec sa propre règle de pertinence, et sa description en donne les résultats. Ces mesures sont hors protocole et ne remplacent pas celle du notebook 03. Les décisions D1 à D8 ont été proposées le 6 octobre à 10 h 02 (commit fe548ce), avant l'ouverture de cette PR à 10 h 52 ; l'amendement de D4 (section 3) a été rédigé sans lire ces résultats et ne s'appuie que sur les annotations. La PR #63 a été fermée sans fusion le 7 octobre ; au Weekly 4, ses mesures sur le lot de test ont été déclarées exploratoires, et la comparaison officielle avant et après l'ajustement fera l'objet d'une mesure unique prévue d'avance (#49).

2 Données

2.1 Jeu de questions (#44)

- **Fichier.** `evaluation/questions/questions_annotées.csv`, dans la version figée par le tag annoté `jeu-questions-v1`, posé le 6 octobre 2026 sur le commit `cdb48c9`. Le notebook refuse tout autre fichier ; les empreintes sont en section 9.
- **Recherche.** Elle se mesure sur les questions du lot de test classées dans `_corpus` : 73 dans le jeu figé, et 24 hors corpus.
- **Abstention.** Elle se mesure sur toutes les questions du lot de test, celles du corpus comme celles hors corpus.
- **Lot de calibration.** Il ne sert qu'à mettre au point le notebook ; le seuil d'abstention vient du CDTN (section 8.2).
- **Annotation secondaire.** L'accord entre annotateurs est calculé et publié ; l'annotation principale fait foi. Il est calculé par `scripts/evaluation/controle_jeu.py` sur l'annotation principale telle qu'elle était au moment de la seconde annotation (commit `187a9f8`), donc avant l'arbitrage de Q062, qui l'aurait gonflé.
- **Accord sur le type.** Sur les 21 questions doublement annotées, les deux annotations donnent le même type 20 fois ; le kappa de Cohen vaut 0,88, avec un intervalle indicatif à 95 % de 0,59 à 1 par rééchantillonnage des 21 paires.
- **Accord sur la réponse.** Sur les 15 questions que les deux annotations placent dans le corpus, elles désignent la même fiche 14 fois et les mêmes fiches pertinentes 14 fois, mais les mêmes passages pertinents en M2 seulement 7 fois, avec au moins un passage pertinent commun 9 fois. Dans les 6 autres cas, l'annotateur secondaire a choisi un autre passage de la même fiche, ou, pour Q051, une autre fiche.

- **Conséquence.** Au niveau du passage, la vérité de terrain dépend de l'annotateur pour 6 des 15 questions comparées : un système qui montre un autre passage valable est compté en échec. Le Recall au niveau du passage est donc un minorant prudent, à lire à côté du niveau de la fiche (D8), bien plus stable entre annotateurs. Les chiffres du README du jeu (accord sur l'URL 19 fois sur 21, sur l'extrait 14 fois sur 16) comptent comme accord deux extraits différents d'une même fiche ; ils concordent avec ceux-ci.

2.2 Corpus et index

- **Passages.** Les découpages Mo, M1, M2, M2 à 256 tokens et M3 du notebook 01, contrôlés par les empreintes de `data/decoupage/passages/manifeste.json`.
- **Index.** Ceux d'évaluation du notebook 02, dans `data/indexation/variantes/`, contrôlés par les empreintes de `variantes.json`. L'index M2 est celui du site : même empreinte SHA-256, qui commence par 2ec45586.

2.3 Complément CDTN (#56)

Analyse secondaire, rapportée à part (section 8.3).

3 Règle de pertinence (D4)

- **Normalisation.** Appliquée à l'extrait comme au passage : minuscules, apostrophe typographique remplacée par l'apostrophe droite, puis seuls les lettres, y compris accentuées, et les chiffres sont conservés ; les tirets de liste disparaissent ainsi. La comparaison est faite deux fois, avec et sans retrait des marques de liste numérotées (un nombre suivi d'un point et d'une espace), car la copie depuis le site les perd parfois, mais les retirer partout effacerait aussi une année en fin de phrase. Un passage est pertinent si l'une des deux comparaisons le déclare tel.
- **Passage pertinent.** Un passage est pertinent pour une question si son texte normalisé et l'extrait normalisé partagent un fragment contigu qui couvre au moins la moitié de l'extrait, ou au moins la moitié du passage avec un minimum de 80 caractères ; chaque moitié est arrondie à l'entier supérieur.
- **Pourquoi la seconde condition.** Elle ne joue que pour les extraits de plus de 160 caractères normalisés : en deçà, un fragment commun de 80 caractères couvre déjà la moitié de l'extrait. Sans elle, un passage plus court que la moitié de l'extrait ne pourrait jamais être pertinent. Or le plus long passage normalisé compte 897 caractères en M2 à 256 tokens et 1 000 en M1 : un extrait de plus de 1 794 caractères n'aurait aucun passage pertinent en M2 à 256 tokens, quel que soit le système. C'est le cas de deux réponses en liste du jeu, Q046 (formations éligibles au CPF, 2 138 caractères normalisés) et Q052 (conditions de l'assurance chômage, 2 590). La règle avantagerait alors les grands passages par construction, le biais qu'elle doit éviter. Le minimum de 80 caractères, celui d'un extrait, empêche de déclarer pertinent un passage très court sur quelques mots.
- **Fiche pertinente (D8).** Une fiche est pertinente si elle contient au moins un passage pertinent.
- **Longueur minimale.** Un extrait normalisé, sans retrait des marques, compte au moins 80 caractères ; dans le jeu fusionné le 6 octobre, le plus court en compte 83.
- **Contrôle avant la mesure.** Chaque question du corpus doit avoir au moins un passage pertinent dans chaque découpage. Sinon, elle est signalée, comptée comme un échec pour ce découpage, et leur nombre est publié.

Pourquoi un fragment et non l'extrait entier : dans le jeu fusionné le 6 octobre, d'après les seules annotations, 76 des 78 extraits tiennent entiers dans un passage M2, mais 71 en M2 à 256 tokens, 67 en M1, 66 en Mo et 65 en M3. Exiger l'extrait entier avantagerait M2 par construction.

Application au même jeu, d'après les seules annotations (`scripts/evaluation/controle_jeu.py`) : en M1, M2, M2 à 256 tokens et M3, chaque question du corpus a au moins un passage pertinent ; 64 en ont un seul en M2, 61 en M2 à 256 tokens, 62 en M3 et 53 en M1. En Mo, Q051 n'en a aucun : son extrait vient du chapeau de la fiche, absent de ce découpage. Avec la première condition seule, Q046 n'aurait aucun passage pertinent en Mo, M1 et M2 à 256 tokens, Q052 aucun en Mo, M1, M2 à 256 tokens et M3, et Q062 aucun en M3. La seconde condition ne retire aucun passage pertinent ; elle en ajoute à cinq questions, toutes à extrait long (Q018, Q025, Q046, Q052 et Q062). Les passages ajoutés appartiennent à la fiche annotée, sauf, pour Q018 en M1 et en M2 à 256 tokens, un passage de la fiche « Le salaire : fixation et paiement » qui reprend mot pour mot une partie de l'extrait : la règle juge le texte, non la fiche, comme elle le faisait déjà pour Q086. La règle est implémentée dans `scripts/evaluation/pertinence.py`, dont la présélection est contrôlée contre une recherche exhaustive et contre une réécriture indépendante de la règle.

4 Systèmes comparés

Code	Système	Configuration
E5 servi	l'encodeur tel que le site le sert	questions encodées dans le navigateur en q8 (Xenova/multilingual-e5-small, révision 761b726d, transformers.js 4.3.0) ; index M2 avec en-tête, en fp32, celui du site
E5 fp32	l'encodeur de référence	questions encodées en Python en fp32 (intfloat/multilingual-e5-small, révision 614241f6), sur chacun des six index : M0, M1, M2, M2 à 256 tokens, M2 sans en-tête, M3
BM25 de référence	la référence lexicale (D3)	V3 de #47 : formule de Lucene, $k_1 = 1,2$, $b = 0,75$, mots vides Snowball sans négations, racinisation Snowball, sur l'en-tête et le texte des passages M2
Autres références	BM25 V0, V1, V2, V4 et TF-IDF V0 à V4 de #47	mêmes passages ; résultats descriptifs
Aléatoire	tirage uniforme	espérance exacte, sans tirage

Règles communes :

- préfixe query : devant chaque question pour l'encodeur ;
- classement par `rank_by_score`, les ex aequo dans l'ordre de l'index ;
- une question sans aucun passage de score positif, pour une référence lexicale, compte comme un échec (D5).

5 Métriques

- **Au niveau du passage** : Recall@k pour $k = 1, 3, 5$ et 10, et MRR@10. Une question est réussie à k si au moins un passage pertinent figure parmi les k premiers.
- **Au niveau de la fiche (D8)** : Recall@5, une question étant réussie si l'un des 5 premiers passages appartient à une fiche pertinente.

- **Intervalles à 95 %** : robustes au regroupement des questions par fiche annotée. Pour une proportion, intervalle de Wilson calculé sur l'effectif corrigé de l'effet de plan, qui reste dans $[0, 1]$ (`proportion_ci`, méthode `wilson`); pour un écart apparié, intervalle de Wald à erreur type robuste (`paired_success_test`), sauf s'il y a moins de 10 paires discordantes : le Wald dégénère alors, jusqu'à une largeur nulle sans aucune discordance, et l'on retient l'intervalle d'Agresti et Min (Statistics in Medicine, 2005), qui ajoute une demi-observation à chaque case de la table. Les deux viennent de `scripts/evaluation/metrics.py`, avec la fiche en groups.

6 Analyse principale (D1, D2, D3)

- **Question.** E5 servi est-il non inférieur à BM25 de référence, en Recall@5 au niveau du passage, sur les questions du corpus du lot de test ? C'est le critère du rapport J2.
- **Statistique.** L'écart $d = \text{Recall@5 (E5 servi)} - \text{Recall@5 (BM25 de référence)}$, avec son intervalle de confiance à 95 %, robuste aux groupes.
- **Critère satisfait (D2)** si la borne basse de l'intervalle dépasse -15 points : c'est un test de non-infériorité, au risque unilatéral de 2,5 %.
- **E5 servi déclaré meilleur** si, en outre, la borne basse dépasse 0.
- **Critère non démontré** dans les autres cas, ce qui ne prouve pas pour autant une infériorité.
- **Pourquoi 15 points.** Avec 72 questions et un écart réel nul, le test de non-infériorité a une puissance de 72 à 93 % pour une marge de 15 points, selon que le taux de désaccord entre systèmes vaut 0,25 ou 0,14 (0,14 est celui de PIAF entre E5 et BM25 V3). Pour une marge de 10 points, elle n'est que de 40 à 62 %. Le rapport J2 dimensionnait déjà le jeu pour 15 points.
- **Également rapportés** : la table de contingence, la valeur p exacte de McNemar et celle d'Obuchowski avec les questions groupées par fiche.

7 Analyses secondaires (D7)

Chaque famille est corrigée par la méthode de Holm, au seuil de 5 %. Sauf mention contraire, la métrique est Recall@5 au niveau du passage, avec l'encodeur en fp32.

Famille	Comparaisons	Règle de décision
F1, découpages	M0, M1 et M3, chacun contre M2 : 3 tests bilatéraux	M2 reste le découpage servi, sauf si un autre fait significativement mieux (règle du notebook 01)
F2, réglages de M2	M2 à 256 tokens contre M2; M2 sans en-tête contre M2 : 2 tests	le réglage actuel reste, sauf écart significatif en faveur de l'autre
F3, précision servie	E5 servi (q8) contre E5 fp32 sur M2 : 1 test	la quantification est acceptée si l'écart n'est pas significatif ; l'intervalle est publié
F4, références	TF-IDF, variantes de BM25, aléatoire	descriptif : valeurs et intervalles, sans test

Les autres métriques (Recall@1, Recall@3, Recall@10, MRR@10, niveau fiche) sont descriptives. Chaque découpage est jugé avec sa propre application de la règle D4.

8 Sigles, abstention et CDTN

8.1 Sigles

- **Sous-ensemble.** Les questions du corpus du lot de test qui contiennent un sigle de la liste ci-dessous : 7 dans le jeu fusionné le 6 octobre, donc une analyse descriptive seulement.
- **Extension des sigles, fixée ici.** CDI : contrat à durée indéterminée ; CDD : contrat à durée déterminée ; RTT : réduction du temps de travail ; CSE : comité social et économique ; SMIC : salaire minimum interprofessionnel de croissance ; VAE : validation des acquis de l'expérience ; CPF : compte personnel de formation.
- **Mesure.** Le rang du premier passage pertinent avant et après extension, question par question, sans test.

8.2 Abstention (D6)

- **Score d'une question.** Le plus grand cosinus avec les passages M2, pour E5 servi.
- **Sans seuil.** L'AUC entre les questions du corpus et les questions hors corpus du lot de test, avec un intervalle à 95 % par rééchantillonnage stratifié (10 000 tirages, graine fixée).
- **Avec seuil, à titre exploratoire.** Le seuil vaut le 5e centile, par interpolation linéaire, des scores maximaux, pour E5 servi, des variantes du CDTN rédigées en question (#56), c'est-à-dire contenant un point d'interrogation (règle du 4 octobre). Seules comptent les variantes des requêtes dont au moins une référence vise une fiche de notre corpus, reconnue par son identifiant exact : les autres renvoient à des sources absentes de notre corpus et feraient baisser le seuil (Weekly 4, décision 3). Sur le test, on rapporte la part des questions hors corpus rejetées et celle des questions du corpus conservées, avec leurs intervalles de Wilson.
- **Seuil fixé avant la mesure.** Calculé le 10 octobre 2026 par `scripts/evaluation/cdtn_seuil.py`, sur 479 variantes issues de 103 requêtes, qui visent 50 fiches de notre corpus, encodées dans le navigateur comme sur le site : **0,8560** (scores maximaux de 0,830 à 0,945). Les vecteurs du navigateur restent fidèles au fp32 (cosinus d'au moins 0,9926), et un recalcul indépendant redonne la même valeur à 5e-7 près. L'empreinte du fichier `data/evaluation/notebook03/seuil_cdtn.json`, contrôlée par le notebook, est en section 9. La règle de secours, le plus petit score maximal des questions du corpus du lot de calibration, n'est plus utilisée.

8.3 CDTN

Analyse secondaire séparée (#56) : pertinence jugée à la section, variantes groupées par requête, résultats jamais fusionnés avec ceux du jeu de l'équipe.

9 Mise en œuvre et reproductibilité

- **Notebook.** `scripts/evaluation/03_evaluation.ipynb`, exécuté en entier par `nbclient` sur un noyau privé, dans l'environnement figé du dossier (`requirements-lock.txt`).
- **Verrou.** Le lot de test n'est lu qu'en mode mesure, et seulement si les empreintes de ce protocole, du jeu et du fichier de seuil sont celles inscrites. Celle du protocole est inscrite dans le notebook ; les deux autres, ci-dessous, et dans le notebook.

Empreintes SHA-256 figées le 10 octobre 2026 :

```
evaluation/questions/questions_annotées.csv (jeu figé)
807498144fec46722ffab045a87c191b6282a86300799976869d4d6c1755fb35
data/evaluation/notebook03/seuil_cdtm.json (seuil du CDTM)
3432fb168cc7d92d374f1151c2f3a3a7938dfed812ba825d651beca87fa083c4
evaluation/questions/annotations_secondaires.csv (pour mémoire)
b71d73136a047d3f60cdfbbbc341a790e7a75a52d84ec99ca3b92190e704b228
```

- **Une seule exécution de mesure.** Les rangs bruts, par question et par système, sont sauvegardés dans data/evaluation/notebook03/.
- **Contrôles.** Rangs recalculés sans tri; deux exécutions identiques; fidélité des vecteurs q8 du navigateur contrôlée comme au notebook 02.
- **Interdits.** Modifier le lot de test après la mesure; régler un paramètre sur le lot de test; ajouter une analyse sans l'étiqueter « exploratoire ».

10 Décisions validées au Weekly 4 (7 octobre 2026, #10)

N°	Décision	Proposition	Justification
D1	Comparaison principale	Recall@5 au niveau du passage, E5 servi contre BM25 de référence	le site affiche 5 résultats; c'est la configuration que voit l'utilisateur
D2	Marge de non-infériorité	15 points	puissance de 72 à 93 %, contre 40 à 62 % pour 10 points; dimensionnement du J2
D3	Référence BM25	V3, formule de Lucene	meilleure variante sur PIAF, qui est indépendant de notre jeu
D4	Règle de pertinence	fragment contigu couvrant la moitié de l'extrait normalisé, ou la moitié du passage avec au moins 80 caractères	équitable entre découpages, réponses en liste comprises
D5	Question sans résultat lexical	échec	aucun passage n'est montré à l'utilisateur
D6	Abstention	AUC sans seuil, et seuil tiré des variantes du CDTM visant une fiche du corpus	lot de calibration trop petit pour un seuil fiable
D7	Comparaisons multiples	Holm par famille, sinon exploratoire	une seule analyse principale
D8	Niveau fiche	Recall@5 au niveau de la fiche, en métrique secondaire	le site affiche la fiche du passage

11 Historique

- **6 octobre 2026** : version proposée (Mahé BEGNIS).
- **6 octobre 2026, après l'audit du jeu fusionné (cdb48c9)** : seconde condition ajoutée à D4 pour les extraits longs, chiffres mis à jour sur le jeu fusionné, accord entre annotateurs publié, seconde déclaration (Mahé BEGNIS).
- **7 octobre 2026, Weekly 4** : D1 à D8 validées par l'équipe, avec D4 amendée et D6 précisée (#10).

- **10 octobre 2026** : protocole figé, avec le tag et les empreintes du jeu, et le seuil du CDTN calculé avant la mesure (Mahé BEGNIS).