

Comprendre l'encodeur multilingual-e5-small

Équipe Data Tigers • NLP 2 • M2 Data & IA • FGES

Support d'apprentissage pour l'indexation du corpus (notebook 02)

Objet	Expliquer comment l'encodeur transforme un texte en vecteur, ce qu'il faut respecter pour l'utiliser, et comment lire ses résultats
Public	Toute l'équipe, sans prérequis au-delà du module NLP 2
Version	27 septembre 2026, révisée après la correction du découpage M2 et l'exécution du notebook 02
Vérifications	Chaque chiffre est soit cité d'une source primaire () , soit mesuré sur notre corpus ()

Les exemples de ce document ont été calculés le 27 septembre 2026 sur les 4 240 passages du découpage M2, avec le modèle `intfloat/multilingual-e5-small` en précision `fp32`. Ce sont des **illustrations** : quatre requêtes écrites pour l'occasion ne mesurent pas la qualité d'un système. L'évaluation se fera au notebook 03, sur un jeu de questions rédigé par des membres de l'équipe qui ne construisent pas l'index.

Sommaire

1	Le problème que l'encodeur résout	3
2	Représenter un texte par un vecteur	3
2.1	Représentation creuse et représentation dense	3
2.2	La similarité cosinus	4
3	Du texte au vecteur : l'architecture du modèle	4
3.1	La tokenisation	4
3.2	La table d'embeddings et les positions	5
3.3	Les 12 couches Transformer	5
3.4	De plusieurs vecteurs à un seul : moyenne et normalisation	6
4	Comment le modèle a appris	6
4.1	Trois étapes	6
4.2	La perte contrastive InfoNCE	6
4.3	Pourquoi deux préfixes	7
4.4	Une conséquence : des scores resserrés	7

5	Le bi-encodeur et l'architecture de notre site	7
5.1	Bi-encodeur contre modèle croisé	7
5.2	Ce qui se passe hors ligne et en ligne	8
5.3	Les fichiers du modèle et la quantification	8
6	Les contraintes à respecter	9
7	Pourquoi nous ne retirons pas les mots vides	10
8	Lire et interpréter les résultats	10
8.1	Un score n'est pas une probabilité	10
8.2	Exemples réels, dont un échec	11
8.3	Mesurer la qualité : les métriques	12
8.4	Pièges d'interprétation	12
9	Pourquoi ce modèle	13
10	Glossaire	14
11	Sources	14

1 Le problème que l'encodeur résout

Le cas A3 demande de retrouver, pour une question en langage naturel, les passages du corpus qui y répondent, de les classer, et d'afficher pour chacun un score, la référence de sa section et un lien vers la fiche. Aucun texte n'est généré : le système retrouve des passages existants.

Deux familles de méthodes savent le faire.

- La **recherche lexicale** (TF-IDF, BM25) compare des mots. Un passage remonte s'il contient les mots de la question, pondérés par leur rareté. Elle est rapide, transparente, et échoue dès que la question n'emploie pas les mots du texte.
- La **recherche dense** compare des sens. Un encodeur transforme la question et chaque passage en un vecteur de nombres ; deux textes de sens proche ont des vecteurs proches, même sans mot commun.

Un exemple sur notre corpus

Pour la question familière « *Peut-on être viré quand on est en arrêt de travail ?* », le mot « viré » n'apparaît dans aucun passage . Un TF-IDF construit sur les passages M2 renvoie en tête une retranscription sur le métier d'inspecteur, un passage sur la cause réelle et sérieuse, et un passage sur des prélèvements atmosphériques (scores 0,277, 0,255 et 0,217). L'encodeur renvoie trois passages consacrés à l'arrêt de travail et à ses effets sur le contrat (section 8.2).

Une question ne prouve rien. Elle montre seulement ce que chaque famille sait faire. La recherche lexicale reste la référence à battre : le rapport J2 a fixé comme critère que l'encodeur ne fasse pas moins bien que BM25 sur le même jeu de questions.

2 Représenter un texte par un vecteur

2.1 Représentation creuse et représentation dense

	TF-IDF (creuse)	Encodeur e5 (dense)
Dimension	une par mot du vocabulaire : 15 314 sur nos passages 	384, fixée par le modèle
Valeurs	presque toutes nulles : 75 valeurs non nulles en médiane par passage, soit 0,49 % 	toutes non nulles
Sens d'une dimension	le poids d'un mot précis	aucun, pris isolément
Mots absents	invisibles : un mot inconnu ne compte pas	découpés en morceaux connus, et interprétés dans leur contexte
Apprentissage	aucun, sinon le calcul des fréquences	appris sur environ un milliard de paires de textes

2.2 La similarité cosinus

La proximité de deux vecteurs $\mathbf{u}$ et $\mathbf{v}$ se mesure par le cosinus de l'angle qu'ils forment :

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} = \frac{\sum_{i=1}^{384} u_i v_i}{\sqrt{\sum_i u_i^2} \sqrt{\sum_i v_i^2}}.$$

Il vaut 1 pour deux vecteurs de même direction, 0 pour deux vecteurs orthogonaux. Si les vecteurs sont **normalisés**, c'est-à-dire de longueur 1, le cosinus se réduit au produit scalaire $\mathbf{u} \cdot \mathbf{v}$. C'est pourquoi on normalise tous les vecteurs : chercher les passages les plus proches revient alors à multiplier une matrice par un vecteur.





Schéma en deux dimensions ; les vecteurs réels en ont 384.

3 Du texte au vecteur : l'architecture du modèle



3.1 La tokenisation

Le modèle ne lit pas des mots mais des **tokens**, morceaux de texte tirés d'un vocabulaire de 250 002 unités construit par l'algorithme Unigram de SentencePiece . Les mots fréquents sont un seul token, les mots rares sont découpés en morceaux connus. Voici la tokenisation réelle de deux entrées ; le trait souligné _ marque un début de mot.

```

<s> _que ry : _Le _salarié _d émission naire _per ço it - il _l ' al location _chômage
_? </s>

<s> _passage : _Article _L . _ 1234 -9 _du _Code _du _travail </s>

```

Trois observations utiles.

- « démissionnaire » devient d, émission, naire : le modèle reconstruit le sens d'un mot rare à partir de ses morceaux et du contexte. Seul un caractère absent du vocabulaire deviendrait le token inconnu <unk> : il n'y en a aucun dans nos 4 240 passages 📖.
- Le préfixe query : coûte 3 tokens, le préfixe passage : en coûte 2 📖. Ces tokens comptent dans la limite de 512 et participent à la moyenne finale.
- Chaque texte est encadré par les tokens spéciaux <s> et </s>, eux aussi comptés dans la limite.

3.2 La table d'embeddings et les positions

Chaque token est remplacé par une ligne d'une table de 250 037 lignes et 384 colonnes, à laquelle on ajoute un vecteur de position (512 positions au plus). La table compte 35 lignes de plus que le vocabulaire du tokeniseur : ces lignes ne sont jamais utilisées 📖.

Composant	Paramètres	Part
Table d'embeddings des tokens (250 037 × 384)	96 014 208	81,6 %
12 couches Transformer	21 293 568	18,1 %
dont, par couche, l'attention	592 128	
dont, par couche, le réseau à propagation avant	1 182 336	
Positions (512 × 384) et types de segment	197 376	0,2 %
Couche de sortie « pooler », inutilisée ici	147 840	0,1 %
Normalisation des embeddings	768	
Total	117 653 760	100 %

Paramètres comptés sur le modèle chargé 📖 ; architecture lue dans son fichier de configuration 📄.

Plus des quatre cinquièmes du modèle sont la table d'embeddings, qui couvre une centaine de langues. Nos passages n'en utilisent que 10 081 lignes sur 250 002, soit 4,0 % 📖. C'est ce qui rend possible la réduction du vocabulaire envisagée au jalon J2 pour alléger le modèle servi.

3.3 Les 12 couches Transformer

Chaque couche transforme la suite de vecteurs en une nouvelle suite de vecteurs, en deux temps.

1. **L'attention** permet à chaque token de regarder tous les autres. Pour chaque token, le modèle calcule une requête Q , une clé K et une valeur V ; le nouveau vecteur est une moyenne des valeurs, pondérée par la ressemblance entre sa requête et les clés des autres :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V, \quad d = 32.$$

Le calcul est fait 12 fois en parallèle (12 « têtes » de 32 dimensions, $12 \times 32 = 384$), chaque tête pouvant suivre un type de relation différent.

2. **Le réseau à propagation avant** transforme chaque vecteur isolément : 384 vers 1 536 dimensions, activation GELU, puis retour à 384.

Des connexions résiduelles et des normalisations entourent ces deux étapes. À la sortie de la douzième couche, chaque token a un vecteur de 384 nombres qui dépend de toute la phrase : le « salarié » d'une phrase sur le licenciement n'a pas le même vecteur que celui d'une phrase sur les congés.

3.4 De plusieurs vecteurs à un seul : moyenne et normalisation

Pour obtenir un vecteur par texte, on fait la **moyenne des vecteurs des tokens réels**, en ignorant les tokens de remplissage ajoutés quand on encode plusieurs textes de longueurs différentes en même temps. Avec $\mathbf{h}_t$ le vecteur du token t et m_t valant 1 pour un token réel et 0 pour un remplissage :

$$\mathbf{e} = \frac{\sum_t m_t \mathbf{h}_t}{\sum_t m_t}, \quad \hat{\mathbf{e}} = \frac{\mathbf{e}}{\|\mathbf{e}\|}.$$

Le masque rend le résultat indépendant du remplissage : un passage encodé seul ou au milieu d'un lot de passages plus longs donne le même vecteur, à $8,8 \times 10^{-8}$ près . Après normalisation, les 4 240 vecteurs ont une longueur comprise entre 0,99999982 et 1,0000001 .

4 Comment le modèle a appris

4.1 Trois étapes

1. **Initialisation** à partir de microsoft/Multilingual-MiniLM-L12-H384, un modèle multilingue compact obtenu par distillation d'un modèle plus grand .
2. **Pré-entraînement contrastif faiblement supervisé** sur environ un milliard de paires de textes multilingues, sans annotation humaine : titre et contenu de pages web, titre et contenu d'articles de presse, paires de traductions, **titre de section et passage de Wikipédia**, question et réponse de forums. Lots de 32 000 paires, 30 000 pas d'entraînement .
3. **Ajustement fin supervisé** sur environ 1,6 million de paires annotées de recherche d'information : MS MARCO, Natural Questions, TriviaQA, SQuAD, Mr. TyDi, MIRACL, entre autres. Lots de 512, deux époques, avec des négatifs difficiles et une distillation depuis un modèle croisé plus précis .


Les paires « titre de section, passage » du pré-entraînement ressemblent à nos entrées, qui commencent par « fiche > section ». C'est une raison de penser que l'en-tête aide, pas une preuve : le notebook 03 mesurera son effet en comparant les passages avec et sans en-tête.

4.2 La perte contrastive InfoNCE

L'apprentissage rapproche le vecteur d'une question de celui de son passage et l'éloigne de ceux des autres passages du même lot, qui servent de négatifs. Pour un lot de n paires (q_i, p_i) :

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n \log \frac{\exp(\cos(q_i, p_i)/\tau)}{\sum_{j=1}^n \exp(\cos(q_i, p_j)/\tau)}, \quad \tau = 0,01.$$

C'est une classification : parmi les n passages du lot, retrouver le bon. La température τ règle la sévérité de la comparaison .



Chaque ligne est une question du lot, chaque colonne un passage. La perte pousse la case verte (la bonne paire) à dominer toute sa ligne : les autres passages du lot jouent le rôle de mauvaises réponses, gratuitement.

4.3 Pourquoi deux préfixes

Le même encodeur sert pour les questions et les passages. Les auteurs brisent la symétrie en ajoutant `query:` devant les questions et `passage:` devant les passages, chacun suivi d'une espace. Ils observent que cette asymétrie compte surtout quand le corpus contient des paraphrases de la question . La documentation du modèle précise : `query:` et `passage:` pour une recherche, `query:` des deux côtés pour une similarité entre textes de même nature, comme le découpage sémantique M3 .

4.4 Une conséquence : des scores resserrés

Avec une température aussi basse, seul l'ordre des scores compte pendant l'apprentissage, pas leur valeur. Les cosinus se concentrent donc dans une bande étroite, un comportement que la documentation annonce entre 0,7 et 1,0 . Sur notre corpus, deux passages pris au hasard ont un cosinus médian de 0,834 ; 90 % des paires sont entre 0,790 et 0,873 . Un score de 0,83 ne signifie donc **pas** « assez proche ».

5 Le bi-encodeur et l'architecture de notre site


5.1 Bi-encodeur contre modèle croisé

	Bi-encodeur (notre choix)	Modèle croisé
Principe	question et passage encodés séparément, puis comparés par produit scalaire	question et passage lus ensemble, un score par paire
Passages	encodés une seule fois, hors ligne	relus à chaque question
Coût par question	un encodage et un produit matrice-vecteur	un passage complet dans le modèle pour chaque candidat
Précision	bonne	meilleure, mais inapplicable dans un navigateur à cette échelle

Le bi-encodeur est ce qui rend le cas A3 possible sans serveur : tout le travail lourd se fait une fois, chez nous.

5.2 Ce qui se passe hors ligne et en ligne

hors ligne, une fois (notebook 02)



en ligne, à chaque question, sur la machine du visiteur

La recherche est **exhaustive** : la question est comparée aux 4 240 vecteurs, soit environ 1,6 million de multiplications, négligeables pour un navigateur. L'index pèse 6,21 Mio en fp32 et 1,55 Mio en entiers de 8 bits 📦. Aucune « base vectorielle » n'est nécessaire : ces outils et leurs index approchés servent à interroger des corpus bien plus grands, sans parcourir tous les vecteurs ; la plupart fonctionnent comme un serveur, et le sujet exclut tout serveur d'inférence.

5.3 Les fichiers du modèle et la quantification

Le dépôt `Xenova/multilingual-e5-small` fournit le même modèle au format ONNX, en plusieurs précisions 📦 :

Type	Fichier	Taille	Remarque
fp32	<code>model.onnx</code>	448,5 Mio	chargé par défaut hors WASM, y compris en WebGPU
fp16	<code>model_fp16.onnx</code>	224,4 Mio	demi-précision
q8	<code>model_quantized.onnx</code>	112,8 Mio	chargé par défaut en WASM
int8, uint8	<code>model_int8.onnx</code> , <code>model_uint8.onnx</code>	112,6 Mio	autres variantes 8 bits
q4	<code>model_q4.onnx</code>	380,2 Mio	plus lourd que q8

Tailles lues sur le Hub 📦 ; types par défaut lus dans le code de `Transformers.js 4.3.0`, fichier `src/utils/dtypes.js` 📦.

Quantifier, c'est stocker chaque poids sur moins de bits : 8 au lieu de 32 divise la taille par quatre, au prix d'une petite erreur sur chaque calcul. Le fichier q4 pèse plus que le q8 parce que, d'après les tailles, la quantification 4 bits ne touche que les couches de calcul et laisse la table d'embeddings en fp32 : 96,0 millions de poids de 4 octets font à eux seuls 366 Mio. Cette explication est déduite des tailles, pas vérifiée dans le graphe ONNX.

Point de vigilance majeur, mesuré au notebook 02. L'index est calculé en fp32 avec PyTorch, mais les questions sont encodées dans le navigateur avec le modèle q8. Sur 822 requêtes de contrôle, le navigateur retrouve le même premier résultat que le calcul exact pour 91,8 % d'entre elles, et ce premier résultat reste parmi les 5 premiers pour 821 requêtes sur 822 📦. Une simulation du q8 en

Python annonçait 96,5 % : elle sous-estimait l'écart, parce qu'ONNX Runtime Web n'exécute pas le fichier q8 exactement comme ONNX Runtime en Python. La mesure qui fait foi se fait donc dans le navigateur. En fp32, le navigateur reproduit exactement le calcul de référence.

6 Les contraintes à respecter

Contrainte	Pourquoi	Comment le vérifier
passage: devant chaque passage, query: devant chaque question	le modèle a appris ainsi ; sur nos quatre requêtes, mettre passage: devant la question fait tomber le premier résultat de référence aux rangs 1, 4, 5 et 9 📌	colonne entree_encodeur de l'export, qui contient déjà le préfixe
512 tokens au plus, préfixe et tokens spéciaux compris	au-delà, la fin du texte est coupée sans avertissement	le notebook 01 garantit un maximum de 512 ; contrôler aussi la longueur des questions
Même tokeniseur des deux côtés	sinon les deux vecteurs ne parlent pas la même langue	tokenisations intfloat et Xenova identiques sur 500 blocs sur 500 📌
Moyenne des tokens et normalisation, des deux côtés	le modèle a été entraîné avec la moyenne	dans Transformers.js, options pooling: "mean" et normalize: true
Type de poids explicite dans le navigateur	le type par défaut dépend du périphérique : q8 en WASM, fp32 ailleurs	passer dtype: "q8" et vérifier les octets téléchargés
Alignement de l'index et des métadonnées	la ligne <i>i</i> de la matrice doit correspondre au passage <i>i</i>	empreinte commune dans le manifeste
Même texte que l'export	recomposer l'entrée risque de changer le préfixe ou l'en-tête	encoder entree_encodeur tel quel
Versions figées	un autre modèle ou une autre révision donne d'autres vecteurs	révisions des dépôts et fichier requirements-lock.txt

Piège de la documentation. L'exemple de la carte Xenova/multilingual-e5-small appelle l'extracteur sans préfixe et sans option. Or, par défaut, Transformers.js ne fait **ni moyenne ni normalisation** (pooling: "none", normalize: false) 📌 : cet exemple renvoie un vecteur par token et non un vecteur par texte. L'appel correct est :

```
await extracteur("query: " + question, { pooling: "mean", normalize: true })
```

7 Pourquoi nous ne retirons pas les mots vides

Retirer les mots vides (« le », « de », « ne », « pas », etc.) est une étape classique des méthodes par sac de mots comme TF-IDF : ces mots, très fréquents, n'aident pas à distinguer les documents et brulent le décompte. Nous ne le faisons pas pour l'encodeur, pour quatre raisons.


- 1. Le modèle a appris sur du texte naturel**, avec ses mots grammaticaux. Lui donner un texte amputé l'éloigne de ce qu'il a vu à l'entraînement, sur les passages comme sur les questions.
- 2. La littérature va dans ce sens.** Dai et Callan (SIGIR 2019, tableau 3) retirent mots vides et ponctuation de requêtes de description, longues de 14 mots en moyenne : un modèle BERT perd en qualité (nDCG@20 de 0,529 à 0,503), tandis qu'un modèle par sac de mots gagne (de 0,404 à 0,427) 📊. Leur modèle lit question et document ensemble, en anglais : c'est une indication pour notre encodeur, pas une preuve.
- 3. Sur notre corpus, ces mots portent du droit** 📜. La liste française du projet Snowball (154 mots) retire « ne », « pas », « sans », « pour », « sur » et « par » ; la liste stopwords-iso (691 mots) retire en plus « plus », « moins », « avant », « après », « pendant », « sauf », « aucun », « peut » et « doit ». Or 28,3 % de nos passages contiennent une négation, 523 contiennent « au moins », 478 « sans ». Avec l'une comme l'autre liste, « Licenciement sans cause réelle et sérieuse » et « Licenciement pour cause réelle et sérieuse » deviennent le même texte.
- 4. Il n'y a rien à gagner.** Le retrait économiserait 33 à 39 % des tokens, mais aucun passage n'est tronqué : la limite de 512 est déjà respectée.

Une liste construite sur la fréquence dans le corpus ne fait pas mieux : au-delà d'une fréquence documentaire de 0,3, elle retire « employeur », « salarié », « salariés », « entreprise », « code » et « travail » 📜, qui distinguent précisément « l'employeur peut-il » de « le salarié peut-il ». Pour les références lexicales TF-IDF et BM25, en revanche, la question se pose : le notebook 03 comparera BM25 sans liste, avec Snowball, avec Snowball sans les négations, et avec une coupure par fréquence, avec et sans racinisation française.

8 Lire et interpréter les résultats

8.1 Un score n'est pas une probabilité

Le graphique ci-dessous donne les scores des 4 240 passages pour la question « Quelles mentions sont interdites sur le bulletin de paie ? » 📜. Le meilleur passage obtient 0,902, la médiane est à 0,801, et le plus mauvais passage du corpus obtient encore 0,726.



Une barre par tranche de 0,005. Les passages utiles sont dans la queue de droite, presque invisible à cette échelle.

Trois règles de lecture en découlent.

- **Seul l'ordre compte.** Un score n'est comparable qu'aux autres scores de la même question.
- **Il n'existe pas de seuil universel.** Pour masquer les résultats trop faibles ou décider une abstention (cas B1), un seuil doit être calibré sur le jeu de questions, et vérifié sur des questions hors corpus.
- **Les écarts sont petits.** Entre le premier et le deuxième résultat, l'écart va de 0,0008 à 0,0095 sur nos quatre requêtes 📊 : le classement fin est fragile, d'où l'importance de mesurer l'écart fp32 et q8.

8.2 Exemples réels, dont un échec

Rang	Score	Fiche > section	Début du passage
« Quelles mentions sont interdites sur le bulletin de paie ? »			
1	0,9022	Le bulletin de paie > Et les mentions interdites ?	Aucune mention relative à l'exercice du droit de grève...
2	0,8927	Le bulletin de paie > Chapô	Au moment du versement de son salaire, un bulletin de paie...
3	0,8839	Le bulletin de paie > Quelles sont les mentions obligatoires ?	Les mentions suivantes doivent obligatoirement figurer...
« Mon employeur peut-il me licencier pendant un arrêt maladie ? »			
1	0,8846	Les absences liées à la maladie... > Peut-il y avoir licenciement pour maladie ?	L'état de santé du salarié ne peut pas constituer en soi un motif de licenciement...
2	0,8835	Les absences liées à la maladie... > Chapô	En cas d'accident ou de maladie non professionnel, le salarié peut bénéficier d'un arrêt de travail...
« Peut-on être viré quand on est en arrêt de travail ? »			
1	0,8764	Les absences liées à la maladie... > Chapô	En cas d'accident ou de maladie non professionnel...
2	0,8755	L'arrêt de travail pour accident du travail... > Que se passe-t-il pendant l'arrêt de travail ?	Le contrat de travail du salarié victime d'un accident du travail...
« Combien de temps peut durer la période d'essai d'un CDI ? »			
1	0,8927	Le contrat à durée déterminée (CDD) > Quelle est la durée de la période d'essai ?	Le contrat de travail à durée déterminée peut comporter une période d'essai...
5	0,8837	La période d'essai > Quelle est la durée de la période d'essai ?	Au terme de l'article L. 1221-19 du Code du travail, le contrat de travail à durée indéterminée...

La dernière requête est un **échec instructif**. Le passage qui répond, celui qui cite l'article L. 1221-19 propre au CDI, n'arrive qu'au rang 5, à 0,009 du premier, derrière un passage sur le CDD. Le passage CDD partage avec la question l'expression « période d'essai » ; le passage CDI écrit « contrat de travail à durée indéterminée » là où la question dit « CDI ». Un essai va dans ce sens : en écrivant « contrat à durée indéterminée », ce passage remonte au rang 2, derrière un autre passage de la même fiche 📄. Une seule question ne prouve rien, mais le jeu de questions devra contenir des sigles. Avec la métrique Recall@5, cette question compte comme réussie ; avec Recall@1, comme ratée. Le choix de la métrique fait partie de l'interprétation.

8.3 Mesurer la qualité : les métriques

Pour une question dont on connaît le ou les passages qui répondent :

- **Recall@k** : 1 si un passage qui répond figure parmi les k premiers, 0 sinon, en moyenne sur les questions. C'est la métrique la plus lisible pour un affichage de k résultats.
- **MRR** (rang réciproque moyen) : $\frac{1}{|Q|} \sum_q \frac{1}{\text{rang}_q}$. Le premier bon résultat au rang 1 vaut 1, au rang 5 vaut 0,2.
- **nDCG@k** : récompense les bons résultats d'autant plus qu'ils sont hauts, quand plusieurs passages répondent à des degrés divers.

Deux méthodes se comparent sur les **mêmes questions**, par un test apparié de McNemar. D'après le calcul du jalon J2, détecter un écart de 10 points avec un taux de désaccord de 0,20 demande environ 155 questions.

8.4 Pièges d'interprétation

- **Scores élevés partout** : deux passages sans rapport sont à 0,83 en médiane. Comparer des rangs, jamais des valeurs absolues.
- **Doublons** : deux passages identiques ont le même vecteur et occupent deux places du classement. Le découpage M2 en compte 57 à texte identique, mais seulement 3 à entrée identique grâce à l'en-tête 📄.
- **Comparer deux modèles par leurs scores** n'a pas de sens : chaque modèle a sa propre échelle.
- **Les projections en deux dimensions** (ACP, t-SNE, UMAP) aident à explorer mais déforment les distances : deux points voisins sur le dessin peuvent être éloignés dans les 384 dimensions, et inversement.
- **Une réussite sur quelques questions** ne dit rien de la qualité générale : seules comptent les mesures sur le jeu de questions complet.

9 Pourquoi ce modèle

Le choix a été fait au jalon J2 sous quatre contraintes : exécution dans le navigateur, coût nul, corpus en français, poids téléchargé raisonnable. Sept candidats ont été mesurés (poids quantifiés en 8 bits, relevés au J2) :

Modèle	Poids	Verdict
Xenova/multilingual-e5-small	112,8 Mio	retenu
Xenova/paraphrase-multilingual-MiniLM-L12-v2	112,8 Mio	équivalent, sans avantage
Xenova/distiluse-base-multilingual-cased-v2	129,0 Mio	plus lourd
Xenova/multilingual-e5-base	265,7 Mio	2,4 fois plus lourd
onnx-community/embeddinggemma-300m-ONNX	294,6 Mio	hors budget
Xenova/bge-m3	543,3 Mio	hors budget
Xenova/all-MiniLM-L6-v2	21,9 Mio	anglais uniquement

Ce qui le justifie

- **Entraîné pour la recherche**, avec des paires question-passage et des préfixes dédiés, contrairement aux modèles de paraphrase, entraînés à comparer des phrases de même nature.
- **Multilingue, français compris** : 100 langues, et des résultats publiés en français sur MIRACL, un jeu de recherche sur Wikipédia : nDCG@10 de 47,6 pour la version small, 49,7 pour la base, 54,5 pour la large . Le rapport J2 affirmait qu'aucun résultat de recherche en français n'était publié : c'est inexact, et à corriger.
- **Léger** : 384 dimensions pour un index de 6,21 Mio en fp32 ; 19,8 ms pour encoder une question dans le navigateur, mesurés au J2.
- **Licence MIT**, compatible avec un site public.

Ses limites

- L'ajustement fin supervisé est surtout anglais, et aucune source d'entraînement n'est spécialisée en droit : le texte juridique n'y figure qu'au hasard des pages web. L'exemple CDD et CDI montre la conséquence possible sur un vocabulaire spécialisé.
- Le fichier du modèle pèse 112,8 Mio (135,6 Mio téléchargés à la première visite, mesurés au J2), au-dessus de la limite de 100 Mio par fichier de GitHub : le modèle doit être servi depuis le Hub, ou réduit à son vocabulaire utile.
- La limite de 512 tokens impose le découpage, et la moyenne des tokens peut diluer le sens d'un passage long.

Les deux voies d'amélioration déclarées au J2 répondent à ces limites : l'ajustement fin contrastif sur nos propres paires question-passage, et la réduction du vocabulaire.

10 Glossaire

Terme	Définition
Token	morceau de texte du vocabulaire du modèle : un mot, une partie de mot ou un signe
Embedding, plongement	vecteur de nombres qui représente un token ou un texte
Encodeur	réseau qui transforme un texte en vecteurs
Bi-encodeur	encodeur qui traite question et passage séparément, pour les comparer ensuite
Moyenne masquée	moyenne des vecteurs des seuls tokens réels, sans les tokens de remplissage
Normalisation L2	division d'un vecteur par sa longueur, pour qu'il soit de longueur 1
Similarité cosinus	cosinus de l'angle entre deux vecteurs ; produit scalaire s'ils sont normalisés
Perte contrastive	fonction d'entraînement qui rapproche les bonnes paires et éloigne les mauvaises
Température	paramètre qui règle la sévérité de la perte contrastive
Quantification	stockage des poids sur moins de bits, pour réduire la taille du modèle
ONNX	format standard de modèle, exécutable dans le navigateur par ONNX Runtime Web
Recall@k, MRR, nDCG	métriques de qualité d'un classement, décrites en section 8.3

11 Sources

- Modèle intfloat/multilingual-e5-small, révision 614241f, carte et fichiers de configuration : <https://huggingface.co/intfloat/multilingual-e5-small>
- Conversion ONNX Xenova/multilingual-e5-small, révision 761b726 : <https://huggingface.co/Xenova/multilingual-e5-small>
- L. Wang et al., *Text Embeddings by Weakly-Supervised Contrastive Pre-training*, arXiv 2212.03533 : perte InfoNCE, température, préfixes.
- L. Wang et al., *Multilingual E5 Text Embeddings : A Technical Report*, arXiv 2402.05672 : données et hyperparamètres d'entraînement, résultats MIRACL par langue (tableau 6).
- Z. Dai, J. Callan, *Deeper Text Understanding for IR with Contextual Neural Language Modeling*, SIGIR 2019, arXiv 1905.09217, tableau 3.
- Transformers.js 4.3.0, fichiers src/utils/dtypes.js et src/pipelines/feature-extraction.js, paquet npm @huggingface/transformers.
- Listes de mots vides : Snowball, <https://snowballstem.org/algorithms/french/stop.txt> ; stopwords-iso, <https://github.com/stopwords-iso/stopwords-fr>.
- Mesures sur notre corpus : passages M2 du notebook scripts/decoupage/01_corpus_decoupage.ipynb.