Récupération v2 : confirmation sur le lot de test

Équipe	Data Tigers
Projet	NLP 2 · Master 2 Data & IA · FGES, Université Catholique de Lille
Ticket	#138 (récupération v2 du volet B)
Responsable	Mahé BEGNIS
Statut	confirmation unique faite le 9 novembre 2026 à 11 :02 UTC, selon le protocole 07 figé au commit `b1a36b1` et publié dans la PR #141 avant l'exécution.

Table des matières

1 Ce qui a été comparé . . . 2
2 Contrôles préalables . . . 2
3 Critère principal : rappel du contexte . . . 2
4 Critères secondaires . . . 2
5 Lecture . . . 3
6 Limites . . . 3
7 Reproduction . . . 3
8 Suite . . . 4

1 Ce qui a été comparé

- **Référence R0** : la chaîne B1, soit E5 en fp32 et les 5 premiers passages.
- **Récupération v2** : `rrf+k10+bge-m3@20`, retenue sur le jeu CDTN (étude 01). Elle fusionne E5 et BM25 V3, fait reclasser les 20 premiers candidats par bge-m3, et donne 10 passages au modèle.
- **Questions** : les 73 questions du corpus du lot de test de `jeu-questions-v1`, issues de 61 fiches.
- **Pertinence** : la règle D4, à partir de l'extrait annoté de chaque question. Chacune des 73 questions a au moins un passage pertinent.
- **Portée** : la récupération seule. Aucune réponse n'a été générée.

2 Contrôles préalables

- **Fichiers figés** : le protocole, le script et le module étaient committés à l'identique ; les résultats de la grille avaient l'empreinte inscrite au protocole (`2c8619ca…`).
- **Chaîne verrouillée** : ses dix empreintes étaient celles de la PR #131.
- **Reproduction du notebook 03** : pour les 73 questions, les rangs du premier passage pertinent d'E5 et de BM25 V3, jusqu'au 10e, sont identiques à ceux publiés. Le Recall@5 d'E5 est retrouvé (33 sur 73), et le MRR@10 aussi (0,326), sans avoir été visé.

3 Critère principal : rappel du contexte

	R0	Récupération v2
Questions dont le contexte contient un passage pertinent	33 sur 73 (45,2 %)	53 sur 73 (72,6 %)

Les deux réussissent	v2 seule	R0 seule	Aucune
31	22	2	18

- **Écart apparié** : +27,4 points, intervalle de Wald à 95 % robuste aux fiches [+16,3 ; +38,5]. L'intervalle d'Agresti-Min, qui ne tient pas compte des fiches, donne [+15,1 ; +38,3].
- **Test d'Obuchowski** (61 fiches) : $\chi^2 = 16{,}39$, $p = 5{,}1 \times 10^{-5}$. Le test binomial exact sur les 24 paires discordantes donne $p = 3{,}6 \times 10^{-5}$.
- **Conclusion selon le protocole 07** : la borne basse de l'intervalle est positive. **L'amélioration est démontrée.**

4 Critères secondaires

Critère	R0	v2	Écart [IC 95 %]	p d'Obuchowski	p corrigé (Holm)
Recall@5 du classement v2, à budget égal de 5 passages	45,2 %	68,5 %	+23,3 [+12,7 ; +33,9]	$2{,}3 \times 10^{-4}$	$4{,}7 \times 10^{-4}$
Rappel au niveau de la fiche	80,8 %	94,5 %	+13,7 [+5,1; +22,3]	$8{,}0 \times 10^{-3}$	$8{,}0 \times 10^{-3}$

Descriptifs :

- **MRR@10** : 0,326 pour R0, 0,528 pour la v2.
- **Tokens du prompt** : 1 672 en moyenne pour R0 ; 4 004 en moyenne et 5 517 au plus pour la v2, sous le plafond de 7 616. Aucune question n'est coupée par le budget.

5 Lecture

- **Le gain ne vient pas seulement du nombre de passages.** À 5 passages, la v2 atteint déjà 68,5 %, plus que les 10 premiers passages d'E5 seul (58,9 %, notebook 03). Le classement lui-même est meilleur, grâce à la fusion avec BM25 et au reclasseur. Ce dernier est la partie de la v2 sur laquelle le lot de test n'avait encore rien révélé.
- **Le gain est plus grand que sur le CDTN** : +27,4 points ici, contre +14,2. Les deux jeux ne mesurent pas la même chose. Le CDTN juge par section, avec plusieurs passages pertinents et une référence plus haute (70,9 %) ; le lot de test juge sur un seul extrait. Le chiffre du CDTN reste le plus prudent.
- **Deux questions seulement sont perdues** par la v2 par rapport à R0, contre 22 gagnées.

6 Limites

- **Récupération seule** : l'effet sur les réponses du modèle n'est pas mesuré. Un contexte deux fois plus long, moins précis et classé autrement peut aider ou gêner le générateur. L'adaptateur a en outre été entraîné sur des contextes de 5 passages d'E5.
- **Lot de test déjà exploité pour E5 et BM25** (protocole 07, section 8). Les choix de la v2 ont été faits sur le CDTN, et k = 10 a été fixé d'avance ; la composante sans précédent sur ce lot est le reclasseur.
- **Extrait unique** : la règle D4 ne connaît qu'un extrait par question, ce qui sous-estime les deux systèmes. Le jugement manuel des passages (#139) sert d'analyse de sensibilité.
- **Effectif** : 73 questions et 61 fiches. Les intervalles sont larges, mais leur borne basse reste nettement positive.

7 Reproduction

- **Commande** : `python scripts/recuperation/confirmer_test.py`. Elle s'arrête si le protocole, le script ou le module diffèrent du commit `b1a36b1`.
- **Empreintes SHA-256 des sorties** (`data/evaluation/recuperation/confirmation/`, non versionné) : `resultats.json` `3679f6fbed8a36ba…`, `questions.csv` `5a829be7d4fa2b25…`. Protocole 07 : `0d460075167a80ad…`.

- **Durée** : 3 min 29 s sur le Mac, dont le reclassement de 1 460 couples par bge-m3 sur CPU.

8 Suite

- **Chaîne complète, à titre exploratoire** après la mesure du protocole 06 : B2 avec la récupération v2, modèle de base et modèle adapté, sur la même machine.
- **#139** : jugement manuel des passages, pour la sensibilité et pour évaluer les voisins.
- **Démonstration** : bge-m3 demande de l'ordre de 2 s par question sur CPU ; à mesurer sur le Legion avant de l'intégrer à la #128.