
Journal d'usage de l'IA

Équipe Data Tigers • NLP 2 • M2 Data & IA • FGES

Ouvert le 18 septembre 2026, tenu jusqu'à la soutenance

Équipe	Data Tigers
Membres	Mahé BEGNIS, Remy RAYANE, Jibril BENSALAM, Vaneck DAGAR, Maïmouna SIGNATE
Module	NLP 2, projet de fin de module
Formation	Master 2 Data & IA, FGES, Université Catholique de Lille
Année universitaire	2026-2027
Ouvert le	18 septembre 2026
Dernière mise à jour	25 septembre 2026, session 9
Objet.	Ce journal consigne l'usage des assistants IA sur le projet, conformément à la règle du sujet : « L'usage d'assistants IA est autorisé et encouragé. En contrepartie, le journal des usages doit être tenu, et tout membre de l'équipe peut être interrogé en soutenance sur n'importe quelle portion du code produit. »
Responsable de la tenue	Mahé BEGNIS. Chaque membre renseigne ses propres sessions selon le modèle donné en section 5.

Table des matières

1	Principes d'usage retenus par l'équipe	3
2	Outils déclarés	3
3	Sessions	4
3.1	Session 1, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	4
3.2	Session 2, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	4
3.3	Session 3, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	4
3.4	Session 4, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	5
3.5	Session 5, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	5
3.6	Session 6, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	5
3.7	Session 7, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	6
3.8	Session 8, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	7
3.9	Session 9, 25 septembre 2026, Remy RAYANE, Google Antigravity	7
3.10	Session 10, 3 octobre 2026, Remy RAYANE, Google Antigravity & Gemini 3.8 Flash	8
3.11	Session 11, 4 octobre 2026, Remy RAYANE, Google Antigravity & Gemini 3.8 Flash	9
3.12	Session 12, 4 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code	10
3.13	Session 13, 6 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code	11

3.14	Session 14, 6 octobre 2026 (après-midi), Mahé BEGNIS, Claude Opus 5.5 via Claude Code	12
3.15	Session 15, 7 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code	13
3.16	Session 16, 10 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code	13
4	Erreurs détectées par la vérification	14
5	Modèle de saisie	15
6	Ce que ce journal alimentera	16

1 Principes d'usage retenus par l'équipe

L'équipe utilise l'IA pour trois choses, et refuse de l'utiliser pour une quatrième.

Ce pour quoi nous l'utilisons.

- 1. Réflexion sur l'architecture et les décisions.** Explorer les options, en peser les conséquences, faire émerger les contraintes que nous n'avions pas vues. Exemple concret : le choix du couple de cas d'usage A3 et B1 a été instruit en comparant les dix cas proposés sur sept critères, ce qui a fait apparaître que A3 constitue la couche de récupération de B1 et économise 5 à 8 jours-homme.
- 2. Challenger nos idées.** Nous soumettons nos décisions à une critique argumentée avant de les figer. Exemple : notre première répartition des tâches présentait un écart de charge d'un facteur 3,3 entre le membre le plus chargé et le moins chargé, et plaçait le même binôme sur les trois domaines les plus critiques. Le chiffrage de cette répartition nous a conduits à la revoir.
- 3. Accélérer les tâches à faible valeur ajoutée.** Recherche de jeux de données, relevé de tailles de fichiers, lecture de documentations, mise en forme. Exemple : l'identification du corpus a comparé en quelques minutes une dizaine de sources publiques avec leur volumétrie, leur licence et leur date de mise à jour, là où la recherche manuelle aurait pris plusieurs heures sans garantie d'exhaustivité.

Ce pour quoi nous refusons de l'utiliser. Produire du code ou une analyse que personne dans l'équipe ne saurait expliquer. Le sujet prévient qu'une réponse insuffisante en soutenance affecte l'évaluation de toute l'équipe. Toute production assistée passe donc en revue par le binôme du domaine concerné, et le relecteur doit savoir l'exposer sans support.

Règle de vérification. Aucune affirmation produite par l'assistant n'est reprise sans mesure. Les chiffres des livrables proviennent de commandes exécutées, dont la méthode est décrite en annexe de chaque document. Cette exigence a permis de détecter plusieurs erreurs, listées en section 4.

2 Outils déclarés

Outil	Nature	Membres	Usage
Claude Opus 5, puis Claude Opus 5.5 (sessions 12 et 13)	modèle de langage, fenêtre de contexte de 1 million de tokens	Mahé BEGNIS	architecture, décisions, recherches, critique, rédaction assistée
Claude Code	environnement de développement augmenté, exécute le modèle ci-dessus	membres disposant d'un abonnement	exécution de commandes, lecture de fichiers, mesures
Google Antigravity	plateforme d'agents, alternative gratuite	les autres membres	même usage, divergence déclarée au jalon J2
Gemini 3.8 Flash (High)	modèle de langage multimodal rapide, exécuté sous Google Antigravity	Remy RAYANE	raisonnement, génération de scripts, analyse de contextes
ChatGPT	interface conversationnelle web	les autres membres	brainstorming, reformulations, documentation ponctuelle

La divergence entre Claude Code et Google Antigravity est déclarée dans le rapport de jalon J2. Elle est motivée par le fait que l'abonnement Claude n'est pas détenu par toute l'équipe. Elle constitue aussi un terrain de comparaison qui alimentera la section des cinq outils novateurs du rapport final.

3 Sessions

3.1 Session 1, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Audit du sujet, étude comparative des dix cas d'usage, préparation de la réunion de cadrage.

Produit. 01_AUDIT_SUJET_PROJET.md (4 180 mots), 02_ETUDE_COMPARATIVE_CAS_USAGE.md (4 877 mots), 03_SUPPORT_REUNION_J2.md (7 962 mots).

Mesures exécutées. Lecture intégrale du sujet (20 pages, 4 692 mots). Comptage des notions du module sur 11 fichiers de cours et de TP dédoublonnés, soit 245 851 caractères. Relevé des tailles de modèles ONNX et GGUF par l'API Hugging Face. Lecture des limites GitHub dans la documentation officielle. Relevé matériel du poste de travail.

Résultats retenus. Les notions RAG, ONNX, Transformers.js, quantisation et adaptation de modèle totalisent zéro occurrence dans les supports du module, alors que le projet les exige. Aucun modèle ONNX multilingue prêt à l'emploi ne tient sous la limite GitHub de 100 Mio. Le sujet affirme que l'architecture BiLSTM-CRF a été étudiée en journée 2, alors que le CRF n'apparaît qu'une fois dans le notebook, dans une cellule de prolongements facultatifs.

Ce que l'équipe a validé. Le choix du couple A3 et B1, après confrontation des trois scénarios proposés.

Temps d'appropriation. Immédiat pour la lecture et le comptage. La mise au point du protocole de mesure a demandé plusieurs itérations, décrites en section 4.

3.2 Session 2, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Conversion du support de réunion en PDF composé avec LaTeX.

Produit. Chaîne de conversion dans `latex/` : `md2tex.py` (259 lignes), `build.py` (123 lignes), `preamble.tex` (149 lignes), plus le PDF de 19 pages.

Choix technique. Un convertisseur dédié a été écrit plutôt que d'utiliser un outil générique, afin de dimensionner les tableaux par mesure. Avant de produire le document, XeLaTeX mesure la largeur réelle du plus large fragment insécable de chaque colonne, et ces largeurs pilotent la répartition. Le nombre de débordements est passé de 63, dont un de 116 points, à zéro.

Ce que l'équipe a validé. Le rendu, par relecture visuelle page par page. Trois défauts invisibles dans le journal de compilation ont été trouvés à cette occasion, listés en section 4.

3.3 Session 3, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Évaluation du dépôt `affaan-m/ECC`, proposé comme outil candidat pour la section des cinq outils novateurs.

Mesures exécutées. Licence, nombre de contributeurs, cadence des publications, étoiles, forks, téléchargements npm, contenu de `install.sh` et de `.env.example`.

Résultats retenus. Projet sain : licence MIT, 336 contributeurs, publications régulières. Mais 261 879 étoiles pour seulement 8 840 téléchargements npm hebdomadaires, alors que des bibliothèques comparables en font plusieurs millions. Conclusion transmise à l'équipe : cet outil ne nous distinguera pas, puisqu'il est au 16e rang mondial des dépôts les plus étoilés et que ses voisins immédiats au classement sont deux concurrents du même créneau. Ce qui distinguera notre rapport est la qualité de la critique, non le choix de l'outil.

Décision de l'équipe. Report du choix du panier d'outils, qui n'est pas un attendu du jalon J2.

3.4 Session 4, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Instruction des décisions du jalon J2, puis rédaction du rapport.

Produit. 04_JALON_J2_DECISIONS.md (6 703 mots), 05_RAPPORT_J2.md (4 104 mots) et son PDF de 12 pages.

Mesures exécutées.

Mesure	Méthode	Résultat retenu
Faisabilité de l'exécution navigateur	page statique servie en local, Chromium piloté par Playwright, 20 passes après chauffe	19,8 ms par requête, 3 052 ms au premier chargement, 568 ms en cache, 135,6 Mio de charge utile
Empreinte mémoire des modèles locaux	calcul du cache KV à partir des fichiers de configuration officiels	Qwen2.5-7B à 56,0 Kio par token, soit 2,3 à 3,4 fois moins que les autres candidats
Recherche de corpus	interrogation des API Hugging Face et data.gouv.fr, contrôle d'accessibilité de dix sources	AgentPublic/travail-emploi, 5 702 passages, 29,6 Mio, licence Etalab 2.0
Dimensionnement du jeu de référence	calcul de puissance statistique	60 questions donnent un intervalle de plus ou moins 10,1 points, insuffisant pour distinguer 0,80 de 0,85

Apport le plus net. La recherche de corpus. Dix sources publiques ont été testées pour leur accessibilité réelle, leur volumétrie, leur licence et leur fraîcheur, en quelques minutes. Cette recherche a écarté les documents internes de la formation, absents du sitemap public, et fait émerger un jeu de données administratif français dont la structure correspond exactement aux besoins du cas A3.

Ce que l'équipe a validé. Le corpus, le modèle du volet B, la machine cible, le protocole d'évaluation et la répartition des tâches, après discussion point par point.

3.5 Session 5, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Vérification en lecture seule de l'état réel du dépôt GitHub, avant envoi du rapport.

Résultats. Organisation et dépôt créés, cinq membres inscrits, enseignant collaborateur en lecture, six tickets ouverts et assignés. En revanche, aucun milestone n'existe et un seul label personnalisé est défini, alors que le rapport en annonçait respectivement trois et dix.

Conséquence. La section 2 du rapport a été reprise pour décrire l'état vérifié, et la structure du board y figure désormais comme structure retenue et non comme état de fait. Une procédure de création des milestones et des labels a été établie.

Enseignement. C'est la vérification qui a évité d'envoyer un document contenant deux affirmations que l'enseignant aurait pu infirmer en un clic.

3.6 Session 6, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Création des milestones et des labels du board, en écriture sur le dépôt.

Vérification préalable. L'identité du jeton a été contrôlée avant toute écriture : compte mahebegniss, aucune variable d'environnement ne la surchargeant. Les opérations passent par l'API et non par des commits, donc sans attribution de co-auteur.

Produit. Quatre milestones, un par jalon noté, avec échéance et barème. Onze labels de projet répartis sur trois axes indépendants. Six tickets rattachés et étiquetés. Le label Jalon 2, rendu redondant par le milestone du même nom, a été retiré.

Difficulté rencontrée, et ce qu'elle apprend. Deux pièges se sont présentés.

Le premier : après le retrait d'un label, la requête de contrôle a renvoyé un état périmé indiquant que deux tickets le portaient encore. Un garde-fou conditionnait la suppression du label à un décompte nul, et a donc refusé d'agir. Une lecture directe a montré que le retrait avait bien eu lieu. **Une lecture immédiatement consécutive à une écriture n'est pas fiable sur cette API**, et une condition de sécurité doit échouer vers l'inaction, ce qui a été le cas.

Le second : la commande `gh api` bascule silencieusement de GET en POST dès qu'un champ `-f` est fourni. Une requête destinée à lire les tickets d'un label a donc tenté d'en créer un, et n'a échoué que parce que le titre manquait. **Ce comportement n'est pas signalé à l'usage**, et il aurait pu écrire dans le dépôt sans intention. À retenir pour la section des outils novateurs.

Ce que l'équipe a validé. La liste des milestones, celle des labels, et le choix de réutiliser le label documentation existant plutôt que d'en créer un doublon.

Temps d'appropriation. Quelques minutes pour la syntaxe, vérifiée sur l'aide en ligne avant exécution. L'essentiel du temps est allé aux contrôles après écriture.

3.7 Session 7, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Mise en place de la structure du dépôt, publication des livrables du jalon J2.

Vérification préalable. Identité du jeton contrôlée avant toute écriture. Les commits portent l'auteur et le validateur Mahé Begnis, avec l'adresse sans réponse du compte GitHub, ce qui les rattache au compte sans exposer d'adresse personnelle. L'identité a été passée commande par commande, sans modifier la configuration git de la machine.

Produit. Répertoire docs/ organisé en jalons, journal, suivi, études et chaîne LaTeX. Fichier README.md décrivant l'organisation, les branches et les conventions de commit. Trois branches publiées, main, dev et docs/5-rapport-jalon-j2, et le tag jalon-j2.

Deux difficultés rencontrées.

Le système de fichiers de macOS est insensible à la casse. La commande destinée à supprimer l'ancien `readme.md` a détruit le `README.md` écrit quelques secondes plus tôt, les deux noms désignant le même fichier. Détecté par le contrôle systématique qui suit chaque écriture, le fichier a été réécrit, et le changement de casse forcé en deux étapes avec `git mv`, seule méthode fiable sur ce type de système.

Le clone local pointait encore vers l'ancienne adresse personnelle du dépôt, périmée depuis son transfert à l'organisation. GitHub redirige silencieusement, ce qui rend l'erreur invisible à l'usage. L'adresse a été corrigée avant toute publication.

Ce que l'équipe a validé. La structure du dépôt, la stratégie de branches, et le choix de ne pas créer de branche de documentation permanente.

Temps d'appropriation. Faible pour les commandes, l'essentiel du temps allant aux contrôles après chaque écriture.

3.8 Session 8, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Deux questions soulevées par l'équipe à la relecture du rapport. Le sujet valorise un modèle entraîné par nous, or le volet A repose sur un encodeur préexistant. Et l'équipe souhaite intégrer un modèle français au volet B.

Mesure exécutée. Faisabilité d'un ajustement fin contrastif de l'encodeur sur la machine de référence. Chargement du modèle, construction d'un lot de 32 paires question-passage, passe avant et arrière avec optimiseur, dix pas chronométrés après chauffe, sur le processeur graphique.

Résultat. Un pas prend 89 ms. Trois époques sur 17 106 paires demandent 2,4 minutes. Le coût de calcul ne fait pas obstacle, ce qui ouvre une voie que nous pensions fermée. Le relevé confirme au passage un calcul antérieur : 117,7 millions de paramètres mesurés contre 117,3 prédicts, soit 0,3 pour cent d'écart.

Second point, le modèle français. Quatre modèles Mistral ont été comparés sur leur licence, leur taille quantifiée et leur cache par token. Mistral-7B-Instruct-v0.3 est retenu comme second modèle : même classe de taille que le principal, ce qui rend la comparaison valide, et tient dans le budget mémoire à toutes les longueurs de contexte. Mistral-Nemo-Instruct-2407, au français probablement meilleur, atteint 12,6 Gio à 32 768 tokens et sort du budget.

Difficulté rencontrée. Le premier lancement du banc d'essai s'est terminé sans aucune sortie, le tube vers une commande de filtrage ayant retenu l'affichage jusqu'à la fin du processus, lequel a été interrompu. Relancé en écriture directe vers un fichier, avec vidage explicite du tampon, il a produit le résultat. **Un banc d'essai long ne doit jamais écrire à travers un tube.**

Ce que l'équipe a validé. L'ajustement fin comme réponse à la valorisation du sujet, et l'ajout du modèle français en comparaison.

3.9 Session 9, 25 septembre 2026, Remy RAYANE, Google Antigravity

Objet. Élaboration du plan d'action opérationnel pour le Domaine 2 (Encodeur et Indexation) dans le cadre de la résolution de l'Issue #30 (milestone Mi-parcours), ciblant l'indexation vectorielle sur le corpus réduit de référence PIAF.

Produit. Plan_Action_Index.md (286 lignes, ~2 400 mots) détaillant les spécifications techniques, les fondements NLP (asymétrie E5, normalisation L2), l'architecture de découplage binaire/JSON, ainsi que l'architecture des scripts du pipeline décrits dans le plan d'action : préparation du corpus (prepare_piaf_corpus.py), encodage et export binaire (build_vector_index.py), recherche dense (src/retrieval/dense_search.py) et banc d'évaluation comparatif (evaluate_benchmarks.py).

Mesures exécutées.

- Analyse du jeu de données Hugging Face AgentPublic/piaf : 3 835 questions, 761 contextes uniques (paragraphe Wikipédia francophones), 191 articles distincts. Longueur moyenne de 688,4 caractères par contexte (~130 à 150 sous-mots).
- Calcul théorique de l'empreinte de la matrice d'embeddings pour 761 passages en dimension 384 : $761 \times 384 \times 4$ octets = 1 168 896 octets (1,11 Mio en float32, 285 Kio en int8), respectant strictement le budget réseau et mémoire du navigateur (< 5 Mio).
- Contrôle de la complexité algorithmique côté client : la normalisation L2 appliquée dès l'indexation permet de réduire la similarité cosinus à un simple produit scalaire en $O(d)$ opérations, vectorisable en WebAssembly / SIMD sans surcoût.

Résultats retenus.

- Choix de PIAF comme jeu réduit de calibration grâce à la présence d'une vérité terrain humaine (*Ground Truth* paires questions-contextes).
- Adoption stricte des préfixes asymétriques E5 (passage: pour les contextes, query: pour les requêtes) pour prévenir la dégradation de Recall@k documentée par les auteurs sur les tâches de recherche asymétrique (Wang et al., 2022, arXiv :2212.03533).
- Découplage strict entre la matrice dense brute (piaf_reduced_index.bin) et les métadonnées (piaf_reduced_meta.json) pour éviter la surcharge de sérialisation JSON en mémoire navigateur.
- Définition d'un protocole d'évaluation quantitatif objectif fondé sur Recall@k (k=1, 3, 5, 10), MRR et latence d'inférence.

Ce qui a été écarté, et pourquoi.

- Stockage de l'index dans un JSON monolithique incluant texte et vecteurs : écarté car l'encodage de tableaux de flottants en texte alourdit la charge utile d'un facteur 2,5 à 3 et bloque le thread principal du navigateur lors de l'exécution de `JSON.parse()`.
- Démarrage direct sur le corpus final volumineux sans passage par un corpus réduit contrôlé : écarté afin de valider et figer les formats d'échange et la chaîne d'évaluation avant le passage à l'échelle.

Ce que l'équipe a validé, et par qui.

- Soumis à la relecture de Mahé Begnis (binôme sur le Domaine D2 Encodeur et Index).

Temps d'appropriation constaté.

- 30 minutes pour formaliser l'architecture de stockage binaire Float32 et valider la compatibilité avec l'API `TypedArray (Float32Array)` côté navigateur.

Difficultés rencontrées.

- Format binaire multi-plateforme : obligation de spécifier explicitement l'ordre des octets en Little-Endian (standard x86/ARM/WebAssembly) pour permettre un mapping mémoire direct sans réordonnement d'octets.

3.10 Session 10, 3 octobre 2026, Remy RAYANE, Google Antigravity & Gemini 3.8 Flash

Objet. Résolution intégrale de l'Issue #45 (milestone J3 / mi-parcours) : implémentation, test unitaire et exécution du banc d'évaluation comparatif (Aléatoire vs BM25 vs Dense E5) sur le jeu public français PIAF (AgentPublic/piaf), avec test de significativité statistique apparié (McNemar).

Produit.

- `scripts/evaluation/metrics.py` (190 lignes) : module autonome de métriques IR (`recall_at_k`, `reciprocal_rank`, `evaluate_retrieval`, `compute_mcnemar_test`) incluant un banc de tests unitaires par assertions.
- `scripts/evaluation/01_valider_sur_piaf.py` (220 lignes) : pipeline d'évaluation reproductible de bout en bout avec sauvegarde des résultats structurés dans `data/evaluation/piaf/`.
- `docs/etudes/evaluation/01_validation_metriques_piaf.md` : note de synthèse méthodologique, tableau comparatif, analyse qualitative et guide de réutilisation pour le Notebook 03.

Mesures exécutées.

- Extraction déterministe de 761 contextes uniques (passages Wikipédia) et 3 835 questions annotées depuis AgentPublic/piaf (révision figée bda8c063bc7297180796cd835d1974c0bc71c521).

- Encodage normalisé L2 avec `intfloat/multilingual-e5-small` (préfixes `passage:` et `query:`) et calcul de similarité cosinus par produit scalaire matriciel ($3\,835 \times 761$).
- Calcul des métriques globales :
- **Aléatoire** : $\text{Recall}@1 = 0,08 \%$, $\text{Recall}@5 = 0,76 \%$, $\text{MRR} = 0,0036$
- **BM25 (rank_bm25)** : $\text{Recall}@1 = 64,25 \%$, $\text{Recall}@5 = 81,07 \%$, $\text{MRR} = 0,7147$
- **Dense E5** : $\text{Recall}@1 = 66,78 \%$, $\text{Recall}@5 = 87,20 \%$, $\text{MRR} = 0,7567$ (+6,13 points de $\text{Recall}@5$ face à BM25).
- Test de McNemar sur le $\text{Recall}@5$: 438 victoires exclusives E5 contre 203 pour BM25 sur 641 paires discordantes, $\chi^2 = 85,42$, $p = 8,84e-21$ (gain hautement significatif).
- Temps d'inférence CPU moyen mesuré : 6,08 ms par requête pour E5 contre 0,37 ms pour BM25.

Résultats retenus.

- Validation mathématique complète de la chaîne de métriques via assertions sur calculs manuels préalables.
- Le module `metrics.py` est certifié prêt pour l'évaluation sur le corpus SocialGouv (Notebook 03).

Ce qui a été écarté, et pourquoi.

- Généralisation hâtive des performances au corpus réglementaire : explicitement rejetée dans le rapport, PIAF étant encyclopédique et ne reflétant pas la complexité des articles de loi ni des sigles métiers (CDI, CDD).

Ce que l'équipe a validé, et par qui.

- Soumis à la relecture de Mahé BEGNIS (binôme Domaine D2).

Temps d'appropriation constaté.

- 20 minutes pour formaliser le module de métriques pures et le test exact de McNemar.

Difficultés rencontrées.

- Gestion des versions de paquets : installation et configuration requises de `transformers`, `sentence-transformers` et `rank-bm25` dans l'environnement local.

3.11 Session 11, 4 octobre 2026, Remy RAYANE, Google Antigravity & Gemini 3.8 Flash

Objet. Résolution intégrale de l'Issue #47 (milestone J3) : conception, implémentation et benchmarking des références lexicales TF-IDF et BM25 sur les 4 240 passages M2 du corpus travail-emploi SocialGouv, étude de 5 variantes de prétraitement et évaluation du portage client.

Produit.

- `scripts/evaluation/lexical_baselines.py` (220 lignes) : module modulaire et typé contenant les classes `LexicalTokenizer`, `BM25Retriever` et `TfidfRetriever`, supportant les variantes de stopwords (Snowball avec et sans négations), le stemming français et les exports web.
- `scripts/evaluation/02_references_lexicales.py` (215 lignes) : banc d'expérimentation complet, mesure des vocabulaires, latences, empreinte mémoire d'export et validation qualitative sur requêtes types.
- `docs/etudes/evaluation/02_references_lexicales_tfidf_bm25.md` : rapport complet d'analyse comparative, étude des négations en droit et proposition d'arbitrage pour le site web.

Mesures exécutées.

- Indexation des 4 240 passages M2 sous 5 variantes (V0 brute, V1 standard, V2 sans négations, V3 stemming + sans négations, V4 filtrage fréquentiel).
- Contraction du vocabulaire par racinisation (V3) : passage de 15 440 à 8 695 termes uniques (-43,6 %).
- Préservation des négations (V2 vs V1) : surcoût marginal négligeable (+2 mots au vocabulaire, +0,01 Mio en gzip), crucial pour l'intégrité juridique des clauses restrictives.
- Poids de l'index BM25 optimisé pour le navigateur : 2,32 Mio brut / 0,74 Mio en gzip (face aux 112,8 Mio du modèle ONNX).
- Latences moyennes mesurées : ~8 ms par requête pour BM25, ~2 ms pour TF-IDF.

Résultats retenus.

- La variante V3 (Stemming + Snowball sans négations) est retenue comme référence optimale pour le benchmark du Notebook 03.
- Recommandation pour le Weekly : intégration possible de BM25 en JavaScript pour un moteur de recherche léger, instantané et sans dépendance ONNX.

Ce qui a été écarté, et pourquoi.

- Suppression aveugle des mots vides usuels : rejetée car elle élimine « ne », « pas », « sans », « aucun », inversant le sens des interdictions dans les textes de loi.

Ce que l'équipe a validé, et par qui.

- Soumis à la relecture de Mahé BEGNIS (binôme Domaine D2).

Temps d'appropriation constaté.

- 25 minutes pour formaliser le tokenizer juridique et l'estimation de l'index inversé Web.

Difficultés rencontrées.

- Prise en charge des dépendances spécifiques : installation et configuration requises de `nltk` pour les ressources Snowball françaises.

3.12 Session 12, 4 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Consignée le 6 octobre 2026, deux jours après la session : la règle de tenue du jour même (section 5) n'a pas été respectée.

Objet. Relecture de la validation des métriques sur PIAF (#45, PR #55), puis analyse du jeu de questions de l'équipe (#44) et des jeux de questions externes.

Produit.

- Corrections poussées sur la PR #55 : module de métriques, script de validation sur PIAF, rapport et PDF.
- Issue #56 (complément CDTN), mise à jour de #46, commentaires sur la PR #54 et sur l'issue #47.

Mesures exécutées.

- Reproduction des chiffres de la première version et recalcul des rangs sans tri, sur les 3 835 questions de PIAF.
- Quatre variantes de BM25 sur PIAF ; tests appariés avec questions groupées par paragraphe et par article.
- Appariement des requêtes du CDTN aux passages M2 ; contrôle des extraits du jeu de l'équipe contre les passages M2.

Résultats retenus.

- Recall@k aligné sur la convention de l'équipe (au moins un passage pertinent dans le top k), entrées invalides refusées.
- Sur PIAF, l'avantage de l'encodeur sur BM25 dépend du réglage de BM25 : de 6,1 à 2,3 points de Recall@5. PIAF ne sert qu'à valider le code.
- Jeu de l'équipe en analyse principale, CDTN en analyse secondaire, variantes groupées par requête.

Ce qui a été écarté, et pourquoi.

- La valeur p calculée en supposant les questions indépendantes : elles sont groupées par paragraphe et par article, ce qui la rend trop optimiste.

Ce que l'équipe a validé, et par qui.

- Le complément CDTN, demandé par Jibril BENSALAM, Vaneck DAGAR et Maïmouna SIGNATE, validé par Mahé BEGNIS. La PR #55, fusionnée par Remy RAYANE le 6 octobre.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- La chaîne docs/latex n'affiche ni les formules, ni les liens Markdown, ni les listes imbriquées dans une liste numérotée : documents réécrits en conséquence.

3.13 Session 13, 6 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. Audit de l'état du dépôt et du jeu de questions, remise au propre des pull requests et des tickets, correction de la PR #58 (#47).

Produit.

- PR #59, qui reporte le notebook 02 dans dev ; corrections poussées sur la PR #58 : module et script des références lexicales, rapport et PDF, PDF du journal.
- Index des réunions complété (PR #36) ; comptes rendus de #6 et #26 rétablis, dates des Weekly et jalons corrigés, branches fusionnées supprimées.

Mesures exécutées.

- Reproduction du script de la PR #57, comparaison des listes de mots vides, mesure réelle du poids de l'index, recouplement avec rank_bm25.
- Contrôle du jeu de questions contre les règles de son README et contre les passages M2.
- Recherche de secrets dans l'historique du dépôt, audit des dépendances (npm audit, pip-audit).

Résultats retenus.

- Le notebook 02 n'était pas dans dev : la PR #40 avait été fusionnée dans une branche déjà intégrée.
- Références lexicales sur la liste Snowball figée, BM25 avec la formule de Lucene par défaut, poids mesuré (0,65 Mio en gzip pour V3).
- Avant le gel du jeu : 57 pré-annotations à valider et 21 doubles annotations à faire.

Ce qui a été écarté, et pourquoi.

- Les comparaisons entre BM25 et l'encodeur du premier rapport lexical : non mesurées, et contredites sur deux requêtes.

Ce que l'équipe a validé, et par qui.

- Les PR #55, #58 et #59, fusionnées par Remy RAYANE le 6 octobre.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- L'assistant ne peut ni fusionner une PR sans relecture, ni approuver une PR qui contient ses propres commits : ces actions reviennent à un autre membre.

3.14 Session 14, 6 octobre 2026 (après-midi), Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. Audit du jeu de questions fusionné (#44), gel du jeu, règle de pertinence et dossier du Weekly 4.

Produit.

- `scripts/evaluation/controle_jeu.py` (contrôle du jeu et accord entre annotateurs); règle de pertinence D4 amendée et protocole mis à jour (PR #62).
- Tag `jeu-questions-v1`, posé avec l'accord de Mahé; audit publié en commentaire de la PR #54; dossier du Weekly 4.

Mesures exécutées.

- Contrôles du jeu sur les cinq découpages, accord calculé sur l'annotation d'avant l'arbitrage de Qo62.
- Règle de pertinence vérifiée par trois implémentations sur 470 couples découpage et extrait.

Résultats retenus.

- Accord sur le type 20 fois sur 21 (κ 0,88); mêmes passages pertinents 7 fois sur 15.
- Avec la règle initiale, deux réponses en liste (Qo46, Qo52) n'avaient aucun passage pertinent possible dans les petits découpages.

Ce qui a été écarté, et pourquoi.

- La lecture des résultats de la PR #63 sur le lot de test : le protocole devait rester indépendant de ces chiffres.

Ce que l'équipe a validé, et par qui.

- Le gel du jeu par Mahé BEGNIS; la règle amendée au Weekly 4.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- Le dossier temporaire de l'assistant a été vidé : environnement d'exécution à reconstruire depuis le fichier figé.

3.15 Session 15, 7 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. Préparation et suivi du Weekly 4 (#10).

Produit.

- Synthèse des sept décisions à prendre, avec leurs options et une recommandation ; message de répartition des tâches pour l'équipe.

Résultats retenus.

- Les sept recommandations ont été validées par l'équipe ; échéance du volet A fixée au 18 octobre.

Ce que l'équipe a validé, et par qui.

- Les décisions, par l'équipe réunie au Weekly 4.

Temps d'appropriation constaté.

- Non relevé sur le moment.

3.16 Session 16, 10 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. État des lieux du dépôt, application des décisions du Weekly 4, préparation de la mesure du notebook 03 (#46).

Produit.

- Décisions du Weekly 4 publiées sur #10 ; protection de dev et main (une approbation requise) ; quatre branches fusionnées supprimées.
- `scripts/evaluation/cdtn_seuil.py` : seuil d'abstention tiré du CDTN ; protocole figé ; empreintes et verrou dans le notebook ; générateur des tableaux du rapport (PR #62).
- Audit statistique du protocole par simulation, test de non-infériorité de Tango corrigé de l'effet de plan (`03_audit_statistique.md`) ; jeu complémentaire du CDTN et sa règle figée (`04_cdtn.md`, #56) ; proposition de protocole pour l'encodeur ajusté (`05_protocole_ajustement.md`, #49) (PR #62).
- Moteur de recherche du site, avec tests et parité (PR #67, #48) ; fiches d'outils Transformers.js, ONNX Runtime et uv (PR #68, #25).

Mesures exécutées.

- Seuil calculé avant la mesure (0,8560, sur 479 variantes du CDTN), recalculé de façon indépendante ; fidélité des vecteurs du navigateur au fp32.
- Verrou testé : mesure refusée si le jeu, le protocole ou le seuil est modifié d'un octet.
- Simulation de 10 000 tirages par scénario sur la structure du lot de test (73 questions, 61 fiches), sans aucune donnée de mesure.
- Parité du moteur du site sur les 24 requêtes du contrôle, en Node puis dans le navigateur.

Résultats retenus.

- Aucun calcul sur le lot de test : la mesure attend la relecture de la PR #62.
- La règle figée du critère du J2 conclut à tort dans 3,0 à 5,2 % des cas à la marge, au lieu de 2,5 % ; le score de Tango corrigé tient 1,9 à 2,5 %. Amendement proposé, à décider avant la mesure.
- CDTN : 155 requêtes et 607 formulations appariées ; moteur du site identique à la page de contrôle sur 24 requêtes sur 24.

Ce que l'équipe a validé, et par qui.

- Relecture de la PR #62 demandée à Remy RAYANE.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- Données du CDTN sans licence : lues au commit figé dans data/, jamais versionnées.

4 Erreurs détectées par la vérification

Cette section est tenue volontairement. Elle documente ce que la relecture systématique a permis de rattraper, et constitue le principal argument en faveur de notre méthode.

Date	Erreur	Détection	Correction
18/09	Comptage des notions faussé par une recherche en sous-chaîne, qui comptait « rag » dans « paragraphe »	incohérence des ordres de grandeur	comptage refait avec frontières de mots
18/09	Expression régulière renvoyant zéro occurrence de LSTM alors qu'il y en avait 133	contradiction avec un autre compteur	passage à une implémentation Python vérifiée
18/09	Nombre de fichiers audités annoncé à 12, réel 14 dont 3 quasi-doublons	recomptage explicite	corpus de référence ramené à 11 fichiers dédoublonnés
18/09	Classification des paquets Python ignorant les roues universal2, donc deux paquets déclarés à tort incompatibles	contrôle manuel des étiquettes	reclassement complet
18/09	Rang mondial du dépôt ECC annoncé au 13e, réel 16e	comptage des dépôts plus étoilés	corrigé, et l'argument en est sorti renforcé
18/09	Tirets cadratins rendus en « --- » dans les tableaux du PDF	relecture visuelle du rendu	caractères Unicode utilisés directement
19/09	Taille d'un modèle annoncée par l'API à 0,5 Mio, réelle 294,6 Mio, les poids étant dans des fichiers externes	invraisemblance pour un modèle de 300 millions de paramètres	mesure des fichiers externes
19/09	Charge utile du navigateur relevée à 5,5 Mio pour un modèle de 112,8 Mio	invraisemblance	les ressources d'origine tierce ne déclarent pas leur taille, mesure refaite fichier par fichier, résultat 135,6 Mio
19/09	Seuil de réussite Recall@5 proposé à 0,80 sans fondement	recherche des résultats publiés du modèle : 23 mesures de récupération, toutes en anglais	seuils reformulés en écarts appariés face à une baseline
19/09	Conclusion hâtive sur l'absence de board, tirée d'une sortie vide	la sortie vide masquait une erreur de périmètre d'autorisation	aucune conclusion tirée, limite déclarée dans le rapport
19/09	Rapport annonçant trois milestones et dix labels inexistantes	consultation du dépôt	section 2 alignée sur l'état vérifié
19/09	Lecture immédiatement consécutive à une écriture renvoyant un état périmé	garde-fou conditionnant la suppression à un décompte nul	suppression refusée puis reprise après contrôle direct
19/09	gh api basculant de GET en POST dès qu'un champ -f est fourni	échec en 422 sur un titre manquant	requêtes de lecture écrites sans -f
19/09	Suppression de readme.md détruisant le README.md écrit juste avant, le système de fichiers étant insensible à la casse	contrôle systématique après écriture	fichier réécrit, casse forcée en deux étapes avec git mv
19/09	Clone local pointant vers l'ancienne adresse du dépôt, périmée depuis son transfert à l'organisation	lecture de l'adresse distante avant publication	adresse corrigée avant tout envoi

Date	Erreur	Détection	Correction
19/09	Banc d'essai terminé sans aucune sortie, le tube de filtrage retenant l'affichage	fichier de sortie vide alors que le processus était terminé	écriture directe vers un fichier, tampon vidé explicitement
04/10	Test de McNemar pour questions groupées attribué à Durkalski (2003), alors que la formule employée est celle d'Obuchowski (1998)	lecture du code source d'une implémentation publiée	attribution et formule corrigées avant publication
04/10	Appariement du CDTN à nos passages : 189 requêtes le matin, 175 l'après-midi, selon la règle employée	recalcul indépendant	règle d'appariement à écrire et figer avant la mesure (#56)
06/10	Aperçu des résultats de l'encodeur calculé sur le jeu de test avant l'écriture du protocole, puis un commentaire affirmant qu'aucune mesure n'avait été faite	relecture de la méthode, puis du commentaire avant envoi	aperçu ni utilisé ni diffusé aux annotateurs, phrase corrigée avant envoi, protocole à écrire avant toute mesure
06/10	Règle de pertinence proposée qui excluait par construction les réponses en liste des petits découpages	audit du jeu final contre les cinq découpages	seconde condition ajoutée avant la validation du protocole, d'après les seules annotations
10/10	Nombre de fiches visées par le seuil du CDTN annoncé à 61 au lieu de 50, compté sur toutes les requêtes appariées	recomptage avant le commit	corrigé avant le gel du protocole
10/10	Empreinte SHA-256 débordant de 254 points dans la marge du PDF du protocole	journal de compilation	empreintes regroupées dans un bloc de code
10/10	Chiffres de l'audit statistique tirés d'un essai préliminaire, à une autre graine, et non du script versionné	réexécution du script avant le commit	chiffres alignés sur la sortie reproductible

Bilan intermédiaire. Seize erreurs ou pièges détectés et traités en deux jours. **Cinq d'entre elles figuraient déjà dans un livrable rédigé** et ont été rattrapées avant l'envoi : le nombre de fichiers audités, le rang du dépôt ECC, le seuil de réussite sans fondement, les milestones et labels inexistantes, et le rendu des tirets dans le PDF composé.

Aucune n'a été trouvée par simple relecture du texte. Toutes l'ont été par confrontation à une mesure, à un calcul indépendant ou à l'inspection visuelle du rendu. C'est la méthode qui les a fait apparaître, pas l'attention.

5 Modèle de saisie

Chaque membre ajoute ses sessions selon ce modèle, le jour de l'usage. Les éléments ne se reconstituent pas après coup.

```
### Session N, date, prénom NOM, outil et modèle

**Objet.**
**Produit.**
**Mesures exécutées.**
**Résultats retenus.**
**Ce qui a été écarté, et pourquoi.**
**Ce que l'équipe a validé, et par qui.**
**Temps d'appropriation constaté.**
**Difficultés rencontrées.**
```

Deux règles de tenue :

1. Une session non consignée le jour même est considérée comme non consignée. Le sujet valorise le temps d'appropriation constaté et les conditions dans lesquelles un outil échoue, qui sont les premiers éléments oubliés.
2. Toute production assistée porte le nom de son relecteur. Sans relecteur nommé, elle n'entre pas dans un livrable.

6 Ce que ce journal alimentera

Trois sections du rapport final s'appuieront directement sur ce document.

- **Analyse technique.** Les mesures consignées ici fournissent les chiffres de coût, de latence et de qualité demandés.
- **Retour d'expérience.** La section 4 documente les difficultés réelles et leur résolution, que le sujet demande de traiter de façon factuelle.
- **Cinq outils novateurs.** Les temps d'appropriation, les échecs et les comparaisons entre outils consignés au fil de l'eau constituent la matière de cette section, qui vaut jusqu'à trois points et dont la grille valorise au moins une critique argumentée.