
Journal d'usage de l'IA

Équipe Data Tigers • NLP 2 • M2 Data & IA • FGES

Ouvert le 18 septembre 2026, tenu jusqu'à la soutenance

Équipe	Data Tigers
Membres	Mahé BEGNIS, Remy RAYANE, Jibril BENSALÉM, Vaneck DAGAR, Maïmouna SIGNATE
Module	NLP 2, projet de fin de module
Formation	Master 2 Data & IA, FGES, Université Catholique de Lille
Année universitaire	2026-2027
Ouvert le	18 septembre 2026
Dernière mise à jour	19 septembre 2026, session 6
Objet.	Ce journal consigne l'usage des assistants IA sur le projet, conformément à la règle du sujet : « L'usage d'assistants IA est autorisé et encouragé. En contrepartie, le journal des usages doit être tenu, et tout membre de l'équipe peut être interrogé en soutenance sur n'importe quelle portion du code produit. »
Responsable de la tenue	Mahé BEGNIS. Chaque membre renseigne ses propres sessions selon le modèle donné en section 5.

Table des matières

1	Principes d'usage retenus par l'équipe	2
2	Outils déclarés	2
3	Sessions	2
3.1	Session 1, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	3
3.2	Session 2, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	3
3.3	Session 3, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	3
3.4	Session 4, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	4
3.5	Session 5, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	4
3.6	Session 6, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code	4
4	Erreurs détectées par la vérification	5
5	Modèle de saisie	6
6	Ce que ce journal alimentera	7

1 Principes d'usage retenus par l'équipe

L'équipe utilise l'IA pour trois choses, et refuse de l'utiliser pour une quatrième.

Ce pour quoi nous l'utilisons.

- 1. Réflexion sur l'architecture et les décisions.** Explorer les options, en peser les conséquences, faire émerger les contraintes que nous n'avions pas vues. Exemple concret : le choix du couple de cas d'usage A3 et B1 a été instruit en comparant les dix cas proposés sur sept critères, ce qui a fait apparaître que A3 constitue la couche de récupération de B1 et économise 5 à 8 jours-homme.
- 2. Challenger nos idées.** Nous soumettons nos décisions à une critique argumentée avant de les figer. Exemple : notre première répartition des tâches présentait un écart de charge d'un facteur 3,3 entre le membre le plus chargé et le moins chargé, et plaçait le même binôme sur les trois domaines les plus critiques. Le chiffrage de cette répartition nous a conduits à la revoir.
- 3. Accélérer les tâches à faible valeur ajoutée.** Recherche de jeux de données, relevé de tailles de fichiers, lecture de documentations, mise en forme. Exemple : l'identification du corpus a comparé en quelques minutes une dizaine de sources publiques avec leur volumétrie, leur licence et leur date de mise à jour, là où la recherche manuelle aurait pris plusieurs heures sans garantie d'exhaustivité.

Ce pour quoi nous refusons de l'utiliser. Produire du code ou une analyse que personne dans l'équipe ne saurait expliquer. Le sujet prévient qu'une réponse insuffisante en soutenance affecte l'évaluation de toute l'équipe. Toute production assistée passe donc en revue par le binôme du domaine concerné, et le relecteur doit savoir l'exposer sans support.

Règle de vérification. Aucune affirmation produite par l'assistant n'est reprise sans mesure. Les chiffres des livrables proviennent de commandes exécutées, dont la méthode est décrite en annexe de chaque document. Cette exigence a permis de détecter plusieurs erreurs, listées en section 4.

2 Outils déclarés

Outil	Nature	Membres	Usage
Claude Opus 5	modèle de langage, fenêtre de contexte de 1 million de tokens	Mahé BEGNIS	architecture, décisions, recherches, critique, rédaction assistée
Claude Code	environnement de développement augmenté, exécute le modèle ci-dessus	membres disposant d'un abonnement	exécution de commandes, lecture de fichiers, mesures
Google Antigravity	plateforme d'agents, alternative gratuite	les autres membres	même usage, divergence déclarée au jalon J2

La divergence entre Claude Code et Google Antigravity est déclarée dans le rapport de jalon J2. Elle est motivée par le fait que l'abonnement Claude n'est pas détenu par toute l'équipe. Elle constitue aussi un terrain de comparaison qui alimentera la section des cinq outils novateurs du rapport final.

3 Sessions

3.1 Session 1, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Audit du sujet, étude comparative des dix cas d'usage, préparation de la réunion de cadrage.

Produit. 01_AUDIT_SUJET_PROJET.md (4 180 mots), 02_ETUDE_COMPARATIVE_CAS_USAGE.md (4 877 mots), 03_SUPPORT_REUNION_J2.md (7 962 mots).

Mesures exécutées. Lecture intégrale du sujet (20 pages, 4 692 mots). Comptage des notions du module sur 11 fichiers de cours et de TP dédoublonnés, soit 245 851 caractères. Relevé des tailles de modèles ONNX et GGUF par l'API Hugging Face. Lecture des limites GitHub dans la documentation officielle. Relevé matériel du poste de travail.

Résultats retenus. Les notions RAG, ONNX, Transformers.js, quantisation et adaptation de modèle totalisent zéro occurrence dans les supports du module, alors que le projet les exige. Aucun modèle ONNX multilingue prêt à l'emploi ne tient sous la limite GitHub de 100 Mio. Le sujet affirme que l'architecture BiLSTM-CRF a été étudiée en journée 2, alors que le CRF n'apparaît qu'une fois dans le notebook, dans une cellule de prolongements facultatifs.

Ce que l'équipe a validé. Le choix du couple A3 et B1, après confrontation des trois scénarios proposés.

Temps d'appropriation. Immédiat pour la lecture et le comptage. La mise au point du protocole de mesure a demandé plusieurs itérations, décrites en section 4.

3.2 Session 2, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Conversion du support de réunion en PDF composé avec LaTeX.

Produit. Chaîne de conversion dans latex/ : md2tex.py (259 lignes), build.py (123 lignes), preamble.tex (149 lignes), plus le PDF de 19 pages.

Choix technique. Un convertisseur dédié a été écrit plutôt que d'utiliser un outil générique, afin de dimensionner les tableaux par mesure. Avant de produire le document, XeLaTeX mesure la largeur réelle du plus large fragment insécable de chaque colonne, et ces largeurs pilotent la répartition. Le nombre de débordements est passé de 63, dont un de 116 points, à zéro.

Ce que l'équipe a validé. Le rendu, par relecture visuelle page par page. Trois défauts invisibles dans le journal de compilation ont été trouvés à cette occasion, listés en section 4.

3.3 Session 3, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Évaluation du dépôt affaan-m/ECC, proposé comme outil candidat pour la section des cinq outils novateurs.

Mesures exécutées. Licence, nombre de contributeurs, cadence des publications, étoiles, forks, téléchargements npm, contenu de install.sh et de .env.example.

Résultats retenus. Projet sain : licence MIT, 336 contributeurs, publications régulières. Mais 261 879 étoiles pour seulement 8 840 téléchargements npm hebdomadaires, alors que des bibliothèques comparables en font plusieurs millions. Conclusion transmise à l'équipe : cet outil ne nous distinguera pas, puisqu'il est au 16e rang mondial des dépôts les plus étoilés et que ses voisins immédiats au classement sont deux concurrents du même créneau. Ce qui distinguera notre rapport est la qualité de la critique, non le choix de l'outil.

Décision de l'équipe. Report du choix du panier d'outils, qui n'est pas un attendu du jalon J2.

3.4 Session 4, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Instruction des décisions du jalon J2, puis rédaction du rapport.

Produit. 04_JALON_J2_DECISIONS.md (6 703 mots), 05_RAPPORT_J2.md (4 104 mots) et son PDF de 12 pages.

Mesures exécutées.

Mesure	Méthode	Résultat retenu
Faisabilité de l'exécution navigateur	page statique servie en local, Chromium piloté par Playwright, 20 passes après chauffe	19,8 ms par requête, 3 052 ms au premier chargement, 568 ms en cache, 135,6 Mio de charge utile
Empreinte mémoire des modèles locaux	calcul du cache KV à partir des fichiers de configuration officiels	Qwen2.5-7B à 56,0 Kio par token, soit 2,3 à 3,4 fois moins que les autres candidats
Recherche de corpus	interrogation des API Hugging Face et data.gouv.fr, contrôle d'accessibilité de dix sources	AgentPublic/travail-emploi, 5 702 passages, 29,6 Mio, licence Etalab 2.0
Dimensionnement du jeu de référence	calcul de puissance statistique	60 questions donnent un intervalle de plus ou moins 10,1 points, insuffisant pour distinguer 0,80 de 0,85

Apport le plus net. La recherche de corpus. Dix sources publiques ont été testées pour leur accessibilité réelle, leur volumétrie, leur licence et leur fraîcheur, en quelques minutes. Cette recherche a écarté les documents internes de la formation, absents du sitemap public, et fait émerger un jeu de données administratif français dont la structure correspond exactement aux besoins du cas A3.

Ce que l'équipe a validé. Le corpus, le modèle du volet B, la machine cible, le protocole d'évaluation et la répartition des tâches, après discussion point par point.

3.5 Session 5, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Vérification en lecture seule de l'état réel du dépôt GitHub, avant envoi du rapport.

Résultats. Organisation et dépôt créés, cinq membres inscrits, enseignant collaborateur en lecture, six tickets ouverts et assignés. En revanche, aucun milestone n'existe et un seul label personnalisé est défini, alors que le rapport en annonçait respectivement trois et dix.

Conséquence. La section 2 du rapport a été reprise pour décrire l'état vérifié, et la structure du board y figure désormais comme structure retenue et non comme état de fait. Une procédure de création des milestones et des labels a été établie.

Enseignement. C'est la vérification qui a évité d'envoyer un document contenant deux affirmations que l'enseignant aurait pu infirmer en un clic.

3.6 Session 6, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Création des milestones et des labels du board, en écriture sur le dépôt.

Vérification préalable. L'identité du jeton a été contrôlée avant toute écriture : compte mahebegniss, aucune variable d'environnement ne la surchargeant. Les opérations passent par l'API et non par des commits, donc sans attribution de co-auteur.

Produit. Quatre milestones, un par jalon noté, avec échéance et barème. Onze labels de projet répartis sur trois axes indépendants. Six tickets rattachés et étiquetés. Le label Jalon 2, rendu redondant par le milestone du même nom, a été retiré.

Difficulté rencontrée, et ce qu'elle apprend. Deux pièges se sont présentés.

Le premier : après le retrait d'un label, la requête de contrôle a renvoyé un état périmé indiquant que deux tickets le portaient encore. Un garde-fou conditionnait la suppression du label à un décompte nul, et a donc refusé d'agir. Une lecture directe a montré que le retrait avait bien eu lieu. **Une lecture immédiatement consécutive à une écriture n'est pas fiable sur cette API**, et une condition de sécurité doit échouer vers l'inaction, ce qui a été le cas.

Le second : la commande `gh api` bascule silencieusement de GET en POST dès qu'un champ `-f` est fourni. Une requête destinée à lire les tickets d'un label a donc tenté d'en créer un, et n'a échoué que parce que le titre manquait. **Ce comportement n'est pas signalé à l'usage**, et il aurait pu écrire dans le dépôt sans intention. À retenir pour la section des outils novateurs.

Ce que l'équipe a validé. La liste des milestones, celle des labels, et le choix de réutiliser le label documentation existant plutôt que d'en créer un doublon.

Temps d'appropriation. Quelques minutes pour la syntaxe, vérifiée sur l'aide en ligne avant exécution. L'essentiel du temps est allé aux contrôles après écriture.

4 Erreurs détectées par la vérification

Cette section est tenue volontairement. Elle documente ce que la relecture systématique a permis de rattraper, et constitue le principal argument en faveur de notre méthode.

Date	Erreur	Détection	Correction
18/09	Comptage des notions faussé par une recherche en sous-chaîne, qui comptait « rag » dans « paragraphe »	incohérence des ordres de grandeur	comptage refait avec frontières de mots
18/09	Expression régulière renvoyant zéro occurrence de LSTM alors qu'il y en avait 133	contradiction avec un autre compteur	passage à une implémentation Python vérifiée
18/09	Nombre de fichiers audités annoncé à 12, réel 14 dont 3 quasi-doublons	recomptage explicite	corpus de référence ramené à 11 fichiers dédoublonnés
18/09	Classification des paquets Python ignorant les roues <code>universal2</code> , donc deux paquets déclarés à tort incompatibles	contrôle manuel des étiquettes	reclassement complet
18/09	Rang mondial du dépôt ECC annoncé au 13e, réel 16e	comptage des dépôts plus étoilés	corrigé, et l'argument en est sorti renforcé
18/09	Tirets cadratins rendus en « --- » dans les tableaux du PDF	relecture visuelle du rendu	caractères Unicode utilisés directement
19/09	Taille d'un modèle annoncée par l'API à 0,5 Mio, réelle 294,6 Mio, les poids étant dans des fichiers externes	invraisemblance pour un modèle de 300 millions de paramètres	mesure des fichiers externes
19/09	Charge utile du navigateur relevée à 5,5 Mio pour un modèle de 112,8 Mio	invraisemblance	les ressources d'origine tierce ne déclarent pas leur taille, mesure refaite fichier par fichier, résultat 135,6 Mio

Date	Erreur	Détection	Correction
19/09	Seuil de réussite Recall@5 proposé à 0,80 sans fondement	recherche des résultats publiés du modèle : 23 mesures de récupération, toutes en anglais	seuils reformulés en écarts appariés face à une baseline
19/09	Conclusion hâtive sur l'absence de board, tirée d'une sortie vide	la sortie vide masquait une erreur de périmètre d'autorisation	aucune conclusion tirée, limite déclarée dans le rapport
19/09	Rapport annonçant trois milestones et dix labels inexistants	consultation du dépôt	section 2 alignée sur l'état vérifié
19/09	Lecture immédiatement consécutive à une écriture renvoyant un état périmé	garde-fou conditionnant la suppression à un décompte nul	suppression refusée puis reprise après contrôle direct
19/09	gh api basculant de GET en POST dès qu'un champ -f est fourni	échec en 422 sur un titre manquant	requêtes de lecture écrites sans -f

Bilan intermédiaire. Treize erreurs ou pièges détectés et traités en deux jours. **Cinq d'entre elles figuraient déjà dans un livrable rédigé** et ont été rattrapées avant l'envoi : le nombre de fichiers audités, le rang du dépôt ECC, le seuil de réussite sans fondement, les milestones et labels inexistants, et le rendu des tirets dans le PDF composé.

Aucune n'a été trouvée par simple relecture du texte. Toutes l'ont été par confrontation à une mesure, à un calcul indépendant ou à l'inspection visuelle du rendu. C'est la méthode qui les a fait apparaître, pas l'attention.

5 Modèle de saisie

Chaque membre ajoute ses sessions selon ce modèle, le jour de l'usage. Les éléments ne se reconstituent pas après coup.

```
### Session N, date, prénom NOM, outil et modèle

**Objet.**
**Produit.**
**Mesures exécutées.**
**Résultats retenus.**
**Ce qui a été écarté, et pourquoi.**
**Ce que l'équipe a validé, et par qui.**
**Temps d'appropriation constaté.**
**Difficultés rencontrées.**
```

Deux règles de tenue :

1. Une session non consignée le jour même est considérée comme non consignée. Le sujet valorise le temps d'appropriation constaté et les conditions dans lesquelles un outil échoue, qui sont les premiers éléments oubliés.
2. Toute production assistée porte le nom de son relecteur. Sans relecteur nommé, elle n'entre pas dans un livrable.

6 Ce que ce journal alimentera

Trois sections du rapport final s'appuieront directement sur ce document.

- **Analyse technique.** Les mesures consignées ici fournissent les chiffres de coût, de latence et de qualité demandés.
- **Retour d'expérience.** La section 4 documente les difficultés réelles et leur résolution, que le sujet demande de traiter de façon factuelle.
- **Cinq outils novateurs.** Les temps d'appropriation, les échecs et les comparaisons entre outils consignés au fil de l'eau constituent la matière de cette section, qui vaut jusqu'à trois points et dont la grille valorise au moins une critique argumentée.