Journal d'usage de l'IA

Équipe Data Tigers • NLP 2 • M2 Data & IA • FGES

Ouvert le 18 septembre 2026, tenu jusqu'à la soutenance

Équipe	Data Tigers
Membres	Mahé BEGNIS, Remy RAYANE, Jibril BENSALEM, Vaneck DAGAR, Maïmouna SIGNATE
Module	NLP 2, projet de fin de module
Formation	Master 2 Data & IA, FGES, Université Catholique de Lille
Année universitaire	2026-2027
Ouvert le	18 septembre 2026
Dernière mise à jour	17 octobre 2026, sessions 28 à 31, consignées a posteriori (section 3)
Objet.	Ce journal consigne l'usage des assistants IA sur le projet, conformément à la règle du sujet : « L'usage d'assistants IA est autorisé et encouragé. En contrepartie, le journal des usages doit être tenu, et tout membre de l'équipe peut être interrogé en soutenance sur n'importe quelle portion du code produit. »
Responsable de la tenue	Mahé BEGNIS. Chaque membre renseigne ses propres sessions selon le modèle donné en section 5.

Table des matières

1 **Principes d'usage retenus par l'équipe** . . . 2
2 **Outils déclarés** . . . 2
3 **Sessions** . . . 3
3.1 Session 1, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code . . . 3
3.2 Session 2, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code . . . 3
3.3 Session 3, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code . . . 3
3.4 Session 4, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code . . . 4
3.5 Session 5, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code . . . 4
3.6 Session 6, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code . . . 5
3.7 Session 7, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code . . . 5
3.8 Session 8, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code . . . 6
3.9 Session 9, 25 septembre 2026, Remy RAYANE, Google Antigravity . . . 6
3.10 Session 10, 3 octobre 2026, Remy RAYANE, Google Antigravity & Gemini 3.8 Flash . . . 7
3.11 Session 11, 4 octobre 2026, Remy RAYANE, Google Antigravity & Gemini 3.8 Flash . . . 8
3.12 Session 12, 4 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code . . . 9
3.13 Session 13, 6 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code . . . 10

3.14 Session 14, 6 octobre 2026 (après-midi), Mahé BEGNIS, Claude Opus 5.5 via Claude Code 11
3.15 Session 15, 7 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code 12
3.16 Session 16, 10 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code 12
3.17 Session 17, 11 octobre 2026, Jibril BENSALEM, Codex dans ChatGPT Work 13
3.18 Session 18, 13 octobre 2026, Jibril BENSALEM, Codex dans ChatGPT Work 14
3.19 Session 19, 13 octobre 2026, Jibril BENSALEM, Codex dans ChatGPT Work 15
3.20 Session 28, 11 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code 16
3.21 Session 29, 13 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code 16
3.22 Session 30, 14 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code 17
3.23 Session 31, 17 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code 19

4 Erreurs détectées par la vérification 20

5 Modèle de saisie 22

6 Ce que ce journal alimentera 23

1 Principes d'usage retenus par l'équipe

L'équipe utilise l'IA pour trois choses, et refuse de l'utiliser pour une quatrième.

Ce pour quoi nous l'utilisons.

1. **Réflexion sur l'architecture et les décisions.** Explorer les options, en peser les conséquences, faire émerger les contraintes que nous n'avions pas vues. Exemple concret : le choix du couple de cas d'usage A3 et B1 a été instruit en comparant les dix cas proposés sur sept critères, ce qui a fait apparaître que A3 constitue la couche de récupération de B1 et économise 5 à 8 jours-homme.
2. **Challenger nos idées.** Nous soumettons nos décisions à une critique argumentée avant de les figer. Exemple : notre première répartition des tâches présentait un écart de charge d'un facteur 3,3 entre le membre le plus chargé et le moins chargé, et plaçait le même binôme sur les trois domaines les plus critiques. Le chiffrage de cette répartition nous a conduits à la revoir.
3. **Accélérer les tâches à faible valeur ajoutée.** Recherche de jeux de données, relevé de tailles de fichiers, lecture de documentations, mise en forme. Exemple : l'identification du corpus a comparé en quelques minutes une dizaine de sources publiques avec leur volumétrie, leur licence et leur date de mise à jour, là où la recherche manuelle aurait pris plusieurs heures sans garantie d'exhaustivité.

Ce pour quoi nous refusons de l'utiliser. Produire du code ou une analyse que personne dans l'équipe ne saurait expliquer. Le sujet prévient qu'une réponse insuffisante en soutenance affecte l'évaluation de toute l'équipe. Toute production assistée passe donc en revue par le binôme du domaine concerné, et le relecteur doit savoir l'exposer sans support.

Règle de vérification. Aucune affirmation produite par l'assistant n'est reprise sans mesure. Les chiffres des livrables proviennent de commandes exécutées, dont la méthode est décrite en annexe de chaque document. Cette exigence a permis de détecter plusieurs erreurs, listées en section 4.

2 Outils déclarés

Outil	Nature	Membres	Usage
Claude Opus 5, puis Claude Opus 5.5 (à partir de la session 12)	modèle de langage, fenêtre de contexte de 1 million de tokens	Mahé BEGNIS, Vaneck DAGAR	architecture, décisions, recherches, critique, rédaction assistée
Claude Code	environnement de développement augmenté, exécute le modèle ci-dessus	membres disposant d'un abonnement	exécution de commandes, lecture de fichiers, mesures
Google Antigravity	plateforme d'agents, alternative gratuite	les autres membres	même usage, divergence déclarée au jalon J2
Gemini 3.8 Flash (High)	modèle de langage multimodal rapide, exécuté sous Google Antigravity	Remy RAYANE	raisonnement, génération de scripts, analyse de contextes
ChatGPT	interface conversationnelle web	les autres membres	brainstorming, reformulations, documentation ponctuelle
Codex dans ChatGPT Work	agent de code exécuté dans ChatGPT Work	Jibril BENSALEM	suivi des charges, relecture du CDTN, compilation du PDF du journal (sessions 17 à 19)

La divergence entre Claude Code et Google Antigravity est déclarée dans le rapport de jalon J2. Elle est motivée par le fait que l'abonnement Claude n'est pas détenu par toute l'équipe. Elle constitue aussi un terrain de comparaison qui alimentera la section des cinq outils novateurs du rapport final.

3 Sessions

3.1 Session 1, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Audit du sujet, étude comparative des dix cas d'usage, préparation de la réunion de cadrage.

Produit. `01_AUDIT_SUJET_PROJET.md` (4 180 mots), `02_ETUDE_COMPARATIVE_CAS_USAGE.md` (4 877 mots), `03_SUPPORT_REUNION_J2.md` (7 962 mots).

Mesures exécutées. Lecture intégrale du sujet (20 pages, 4 692 mots). Comptage des notions du module sur 11 fichiers de cours et de TP dédoublonnés, soit 245 851 caractères. Relevé des tailles de modèles ONNX et GGUF par l'API Hugging Face. Lecture des limites GitHub dans la documentation officielle. Relevé matériel du poste de travail.

Résultats retenus. Les notions RAG, ONNX, Transformers.js, quantisation et adaptation de modèle totalisent zéro occurrence dans les supports du module, alors que le projet les exige. Aucun modèle ONNX multilingue prêt à l'emploi ne tient sous la limite GitHub de 100 Mio. Le sujet affirme que l'architecture BiLSTM-CRF a été étudiée en journée 2, alors que le CRF n'apparaît qu'une fois dans le notebook, dans une cellule de prolongements facultatifs.

Ce que l'équipe a validé. Le choix du couple A3 et B1, après confrontation des trois scénarios proposés.

Temps d'appropriation. Immédiat pour la lecture et le comptage. La mise au point du protocole de mesure a demandé plusieurs itérations, décrites en section 4.

3.2 Session 2, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Conversion du support de réunion en PDF composé avec LaTeX.

Produit. Chaîne de conversion dans `latex/` : `md2tex.py` (259 lignes), `build.py` (123 lignes), `preambule.tex` (149 lignes), plus le PDF de 19 pages.

Choix technique. Un convertisseur dédié a été écrit plutôt que d'utiliser un outil générique, afin de dimensionner les tableaux par mesure. Avant de produire le document, XeLaTeX mesure la largeur réelle du plus large fragment insécable de chaque colonne, et ces largeurs pilotent la répartition. Le nombre de débordements est passé de 63, dont un de 116 points, à zéro.

Ce que l'équipe a validé. Le rendu, par relecture visuelle page par page. Trois défauts invisibles dans le journal de compilation ont été trouvés à cette occasion, listés en section 4.

3.3 Session 3, 18 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Évaluation du dépôt `affaan-m/ECC`, proposé comme outil candidat pour la section des cinq outils novateurs.

Mesures exécutées. Licence, nombre de contributeurs, cadence des publications, étoiles, forks, téléchargements npm, contenu de `install.sh` et de `.env.example`.

Résultats retenus. Projet sain : licence MIT, 336 contributeurs, publications régulières. Mais 261 879 étoiles pour seulement 8 840 téléchargements npm hebdomadaires, alors que des bibliothèques comparables en font plusieurs millions. Conclusion transmise à l'équipe : cet outil ne nous distinguera pas, puisqu'il est au 16e rang mondial des dépôts les plus étoilés et que ses voisins immédiats au classement sont deux concurrents du même créneau. Ce qui distinguera notre rapport est la qualité de la critique, non le choix de l'outil.

Décision de l'équipe. Report du choix du panier d'outils, qui n'est pas un attendu du jalon J2.

3.4 Session 4, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Instruction des décisions du jalon J2, puis rédaction du rapport.

Produit. `04_JALON_J2_DECISIONS.md` (6 703 mots), `05_RAPPORT_J2.md` (4 104 mots) et son PDF de 12 pages.

Mesures exécutées.

Mesure	Méthode	Résultat retenu
Faisabilité de l'exécution navigateur	page statique servie en local, Chromium piloté par Playwright, 20 passes après chauffe	19,8 ms par requête, 3 052 ms au premier chargement, 568 ms en cache, 135,6 Mio de charge utile
Empreinte mémoire des modèles locaux	calcul du cache KV à partir des fichiers de configuration officiels	Qwen2.5-7B à 56,0 Kio par token, soit 2,3 à 3,4 fois moins que les autres candidats
Recherche de corpus	interrogation des API Hugging Face et data.gouv.fr, contrôle d'accessibilité de dix sources	`AgentPublic/travail-emploi`, 5 702 passages, 29,6 Mio, licence Etalab 2.0
Dimensionnement du jeu de référence	calcul de puissance statistique	60 questions donnent un intervalle de plus ou moins 10,1 points, insuffisant pour distinguer 0,80 de 0,85

Apport le plus net. La recherche de corpus. Dix sources publiques ont été testées pour leur accessibilité réelle, leur volumétrie, leur licence et leur fraîcheur, en quelques minutes. Cette recherche a écarté les documents internes de la formation, absents du sitemap public, et fait émerger un jeu de données administratif français dont la structure correspond exactement aux besoins du cas A3.

Ce que l'équipe a validé. Le corpus, le modèle du volet B, la machine cible, le protocole d'évaluation et la répartition des tâches, après discussion point par point.

3.5 Session 5, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Vérification en lecture seule de l'état réel du dépôt GitHub, avant envoi du rapport.

Résultats. Organisation et dépôt créés, cinq membres inscrits, enseignant collaborateur en lecture, six tickets ouverts et assignés. En revanche, aucun milestone n'existe et un seul label personnalisé est défini, alors que le rapport en annonçait respectivement trois et dix.

Conséquence. La section 2 du rapport a été reprise pour décrire l'état vérifié, et la structure du board y figure désormais comme structure retenue et non comme état de fait. Une procédure de création des milestones et des labels a été établie.

Enseignement. C'est la vérification qui a évité d'envoyer un document contenant deux affirmations que l'enseignant aurait pu infirmer en un clic.

3.6 Session 6, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Création des milestones et des labels du board, en écriture sur le dépôt.

Vérification préalable. L'identité du jeton a été contrôlée avant toute écriture : compte `mahebegnis`, aucune variable d'environnement ne la surchargeant. Les opérations passent par l'API et non par des commits, donc sans attribution de co-auteur.

Produit. Quatre milestones, un par jalon noté, avec échéance et barème. Onze labels de projet répartis sur trois axes indépendants. Six tickets rattachés et étiquetés. Le label `Jalon 2`, rendu redondant par le milestone du même nom, a été retiré.

Difficulté rencontrée, et ce qu'elle apprend. Deux pièges se sont présentés.

Le premier : après le retrait d'un label, la requête de contrôle a renvoyé un état périmé indiquant que deux tickets le portaient encore. Un garde-fou conditionnait la suppression du label à un décompte nul, et a donc refusé d'agir. Une lecture directe a montré que le retrait avait bien eu lieu. **Une lecture immédiatement consécutive à une écriture n'est pas fiable sur cette API**, et une condition de sécurité doit échouer vers l'inaction, ce qui a été le cas.

Le second : la commande `gh api` bascule silencieusement de GET en POST dès qu'un champ `-f` est fourni. Une requête destinée à lire les tickets d'un label a donc tenté d'en créer un, et n'a échoué que parce que le titre manquait. **Ce comportement n'est pas signalé à l'usage**, et il aurait pu écrire dans le dépôt sans intention. À retenir pour la section des outils novateurs.

Ce que l'équipe a validé. La liste des milestones, celle des labels, et le choix de réutiliser le label `documentation` existant plutôt que d'en créer un doublon.

Temps d'appropriation. Quelques minutes pour la syntaxe, vérifiée sur l'aide en ligne avant exécution. L'essentiel du temps est allé aux contrôles après écriture.

3.7 Session 7, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Mise en place de la structure du dépôt, publication des livrables du jalon J2.

Vérification préalable. Identité du jeton contrôlée avant toute écriture. Les commits portent l'auteur et le validateur Mahé Begnis, avec l'adresse sans réponse du compte GitHub, ce qui les rattache au compte sans exposer d'adresse personnelle. L'identité a été passée commande par commande, sans modifier la configuration git de la machine.

Produit. Répertoire `docs/` organisé en jalons, journal, suivi, études et chaîne LaTeX. Fichier `README.md` décrivant l'organisation, les branches et les conventions de commit. Trois branches publiées, `main`, `dev` et `docs/5-rapport-jalon-j2`, et le tag `jalon-j2`.

Deux difficultés rencontrées.

Le système de fichiers de macOS est insensible à la casse. La commande destinée à supprimer l'ancien `readme.md` a détruit le `README.md` écrit quelques secondes plus tôt, les deux noms désignant le même fichier. Détecté par le contrôle systématique qui suit chaque écriture, le fichier a été réécrit, et le changement de casse forcé en deux étapes avec `git mv`, seule méthode fiable sur ce type de système.

Le clone local pointait encore vers l'ancienne adresse personnelle du dépôt, périmée depuis son transfert à l'organisation. GitHub redirige silencieusement, ce qui rend l'erreur invisible à l'usage. L'adresse a été corrigée avant toute publication.

Ce que l'équipe a validé. La structure du dépôt, la stratégie de branches, et le choix de ne pas créer de branche de documentation permanente.

Temps d'appropriation. Faible pour les commandes, l'essentiel du temps allant aux contrôles après chaque écriture.

3.8 Session 8, 19 septembre 2026, Mahé BEGNIS, Claude Opus 5 via Claude Code

Objet. Deux questions soulevées par l'équipe à la relecture du rapport. Le sujet valorise un modèle entraîné par nous, or le volet A repose sur un encodeur préexistant. Et l'équipe souhaite intégrer un modèle français au volet B.

Mesure exécutée. Faisabilité d'un ajustement fin contrastif de l'encodeur sur la machine de référence. Chargement du modèle, construction d'un lot de 32 paires question-passage, passe avant et arrière avec optimiseur, dix pas chronométrés après chauffe, sur le processeur graphique.

Résultat. Un pas prend 89 ms. Trois époques sur 17 106 paires demandent 2,4 minutes. Le coût de calcul ne fait pas obstacle, ce qui ouvre une voie que nous pensions fermée. Le relevé confirme au passage un calcul antérieur : 117,7 millions de paramètres mesurés contre 117,3 prédits, soit 0,3 pour cent d'écart.

Second point, le modèle français. Quatre modèles Mistral ont été comparés sur leur licence, leur taille quantifiée et leur cache par token. `Mistral-7B-Instruct-v0.3` est retenu comme second modèle : même classe de taille que le principal, ce qui rend la comparaison valide, et tient dans le budget mémoire à toutes les longueurs de contexte. `Mistral-Nemo-Instruct-2407`, au français probablement meilleur, atteint 12,6 Gio à 32 768 tokens et sort du budget.

Difficulté rencontrée. Le premier lancement du banc d'essai s'est terminé sans aucune sortie, le tube vers une commande de filtrage ayant retenu l'affichage jusqu'à la fin du processus, lequel a été interrompu. Relancé en écriture directe vers un fichier, avec vidage explicite du tampon, il a produit le résultat. **Un banc d'essai long ne doit jamais écrire à travers un tube.**

Ce que l'équipe a validé. L'ajustement fin comme réponse à la valorisation du sujet, et l'ajout du modèle français en comparaison.

3.9 Session 9, 25 septembre 2026, Remy RAYANE, Google Antigravity

Objet. Élaboration du plan d'action opérationnel pour le Domaine 2 (Encodeur et Indexation) dans le cadre de la résolution de l'Issue #30 (milestone Mi-parcours), ciblant l'indexation vectorielle sur le corpus réduit de référence PIAF.

Produit. `Plan_Action_Index.md` (286 lignes, ~2 400 mots) détaillant les spécifications techniques, les fondements NLP (asymétrie E5, normalisation L2), l'architecture de découplage binaire/JSON, ainsi que l'architecture des scripts du pipeline décrits dans le plan d'action : préparation du corpus (`prepare_piaf_corpus.py`), encodage et export binaire (`build_vector_index.py`), recherche dense (`src/retrieval/dense_search.py`) et banc d'évaluation comparatif (`evaluate_benchmarks.py`).

Mesures exécutées.

- Analyse du jeu de données Hugging Face `AgentPublic/piaf` : 3 835 questions, 761 contextes uniques (paragraphes Wikipédia francophones), 191 articles distincts. Longueur moyenne de 688,4 caractères par contexte (~130 à 150 sous-mots).
- Calcul théorique de l'empreinte de la matrice d'embeddings pour 761 passages en dimension 384 : 761 × 384 × 4 octets = 1 168 896 octets (1,11 Mio en float32, 285 Kio en int8), respectant strictement le budget réseau et mémoire du navigateur (< 5 Mio).
- Contrôle de la complexité algorithmique côté client : la normalisation L2 appliquée dès l'indexation permet de réduire la similarité cosinus à un simple produit scalaire en O(d) opérations, vectorisable en WebAssembly / SIMD sans surcoût.

Résultats retenus.

- Choix de PIAF comme jeu réduit de calibration grâce à la présence d'une vérité terrain humaine (*Ground Truth* paires questions-contextes).
- Adoption stricte des préfixes asymétriques E5 (`passage:` pour les contextes, `query:` pour les requêtes) pour prévenir la dégradation de Recall@k documentée par les auteurs sur les tâches de recherche asymétrique (Wang et al., 2022, arXiv :2212.03533).
- Découplage strict entre la matrice dense brute (`piaf_reduced_index.bin`) et les métadonnées (`piaf_reduced_meta.json`) pour éviter la surcharge de sérialisation JSON en mémoire navigateur.
- Définition d'un protocole d'évaluation quantitatif objectif fondé sur Recall@k (k=1, 3, 5, 10), MRR et latence d'inférence.

Ce qui a été écarté, et pourquoi.

- Stockage de l'index dans un JSON monolithique incluant texte et vecteurs : écarté car l'encodage de tableaux de flottants en texte alourdit la charge utile d'un facteur 2,5 à 3 et bloque le thread principal du navigateur lors de l'exécution de `JSON.parse()`.
- Démarrage direct sur le corpus final volumineux sans passage par un corpus réduit contrôlé : écarté afin de valider et figer les formats d'échange et la chaîne d'évaluation avant le passage à l'échelle.

Ce que l'équipe a validé, et par qui.

- Soumis à la relecture de Mahé Begnis (binôme sur le Domaine D2 Encodeur et Index).

Temps d'appropriation constaté.

- 30 minutes pour formaliser l'architecture de stockage binaire Float32 et valider la compatibilité avec l'API `TypedArray` (`Float32Array`) côté navigateur.

Difficultés rencontrées.

- Format binaire multi-plateforme : obligation de spécifier explicitement l'ordre des octets en Little-Endian (standard x86/ARM/WebAssembly) pour permettre un mapping mémoire direct sans réordonnancement d'octets.

3.10 Session 10, 3 octobre 2026, Remy RAYANE, Google Antigravity & Gemini 3.8 Flash

Objet. Résolution intégrale de l'Issue #45 (milestone J3 / mi-parcours) : implémentation, test unitaire et exécution du banc d'évaluation comparatif (Aléatoire vs BM25 vs Dense E5) sur le jeu public français PIAF (`AgentPublic/piaf`), avec test de significativité statistique apparié (McNemar).

Produit.

- `scripts/evaluation/metrics.py` (190 lignes) : module autonome de métriques IR (`recall_at_k`, `reciprocal_rank`, `evaluate_retrieval`, `compute_mcnemar_test`) incluant un banc de tests unitaires par assertions.
- `scripts/evaluation/01_valider_sur_piaf.py` (220 lignes) : pipeline d'évaluation reproductible de bout en bout avec sauvegarde des résultats structurés dans `data/evaluation/piaf/`.
- `docs/etudes/evaluation/01_validation_metriques_piaf.md` : note de synthèse méthodologique, tableau comparatif, analyse qualitative et guide de réutilisation pour le Notebook 03.

Mesures exécutées.

- Extraction déterministe de 761 contextes uniques (passages Wikipédia) et 3 835 questions annotées depuis `AgentPublic/piaf` (révision figée `bda8c063bc7297180796cd835d1974c0bc71c521`).
- Encodage normalisé L2 avec `intfloat/multilingual-e5-small` (préfixes `passage: ` et `query: `) et calcul de similarité cosinus par produit scalaire matriciel (3 835 × 761).
- Calcul des métriques globales :
- **Aléatoire :** Recall@1 = 0,08 %, Recall@5 = 0,76 %, MRR = 0,0036
- **BM25 (`rank_bm25`) :** Recall@1 = 64,25 %, Recall@5 = 81,07 %, MRR = 0,7147
- **Dense E5 :** Recall@1 = 66,78 %, Recall@5 = 87,20 %, MRR = 0,7567 (+6,13 points de Recall@5 face à BM25).
- Test de McNemar sur le Recall@5 : 438 victoires exclusives E5 contre 203 pour BM25 sur 641 paires discordantes, chi2 = 85,42, p = 8,84e-21 (gain hautement significatif).
- Temps d'inférence CPU moyen mesuré : 6,08 ms par requête pour E5 contre 0,37 ms pour BM25.

Résultats retenus.

- Validation mathématique complète de la chaîne de métriques via assertions sur calculs manuels préalables.
- Le module `metrics.py` est certifié prêt pour l'évaluation sur le corpus SocialGouv (Notebook 03).

Ce qui a été écarté, et pourquoi.

- Généralisation hâtive des performances au corpus réglementaire : explicitement rejetée dans le rapport, PIAF étant encyclopédique et ne reflétant pas la complexité des articles de loi ni des sigles métiers (CDI, CDD).

Ce que l'équipe a validé, et par qui.

- Soumis à la relecture de Mahé BEGNIS (binôme Domaine D2).

Temps d'appropriation constaté.

- 20 minutes pour formaliser le module de métriques pures et le test exact de McNemar.

Difficultés rencontrées.

- Gestion des versions de paquets : installation et configuration requises de `transformers`, `sentence-transformers` et `rank-bm25` dans l'environnement local.

3.11 Session 11, 4 octobre 2026, Remy RAYANE, Google Antigravity & Gemini 3.8 Flash

Objet. Résolution intégrale de l'Issue #47 (milestone J3) : conception, implémentation et benchmarking des références lexicales TF-IDF et BM25 sur les 4 240 passages M2 du corpus travail-emploi SocialGouv, étude de 5 variantes de prétraitement et évaluation du portage client.

Produit.

- `scripts/evaluation/lexical_baselines.py` (220 lignes) : module modulaire et typé contenant les classes `LexicalTokenizer`, `BM25Retriever` et `TfidfRetriever`, supportant les variantes de stopwords (Snowball avec et sans négations), le stemming français et les exports web.
- `scripts/evaluation/02_references_lexicales.py` (215 lignes) : banc d'expérimentation complet, mesure des vocabulaires, latences, empreinte mémoire d'export et validation qualitative sur requêtes types.
- `docs/etudes/evaluation/02_references_lexicales_tfidf_bm25.md` : rapport complet d'analyse comparative, étude des négations en droit et proposition d'arbitrage pour le site web.

Mesures exécutées.

- Indexation des 4 240 passages M2 sous 5 variantes (V0 brute, V1 standard, V2 sans négations, V3 stemming + sans négations, V4 filtrage fréquentiel).
- Contraction du vocabulaire par racinisation (V3) : passage de 15 440 à 8 695 termes uniques (-43,6 %).
- Préservation des négations (V2 vs V1) : surcoût marginal négligeable (+2 mots au vocabulaire, +0,01 Mio en gzip), crucial pour l'intégrité juridique des clauses restrictives.
- Poids de l'index BM25 optimisé pour le navigateur : 2,32 Mio brut / 0,74 Mio en gzip (face aux 112,8 Mio du modèle ONNX).
- Latences moyennes mesurées : ~8 ms par requête pour BM25, ~2 ms pour TF-IDF.

Résultats retenus.

- La variante V3 (Stemming + Snowball sans négations) est retenue comme référence optimale pour le benchmark du Notebook 03.
- Recommandation pour le Weekly : intégration possible de BM25 en JavaScript pour un moteur de recherche léger, instantané et sans dépendance ONNX.

Ce qui a été écarté, et pourquoi.

- Suppression aveugle des mots vides usuels : rejetée car elle élimine « ne », « pas », « sans », « aucun », inversant le sens des interdictions dans les textes de loi.

Ce que l'équipe a validé, et par qui.

- Soumis à la relecture de Mahé BEGNIS (binôme Domaine D2).

Temps d'appropriation constaté.

- 25 minutes pour formaliser le tokenizer juridique et l'estimation de l'index inversé Web.

Difficultés rencontrées.

- Prise en charge des dépendances spécifiques : installation et configuration requises de `nltk` pour les ressources Snowball françaises.

3.12 Session 12, 4 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Consignée le 6 octobre 2026, deux jours après la session : la règle de tenue du jour même (section 5) n'a pas été respectée.

Objet. Relecture de la validation des métriques sur PIAF (#45, PR #55), puis analyse du jeu de questions de l'équipe (#44) et des jeux de questions externes.

Produit.

- Corrections poussées sur la PR #55 : module de métriques, script de validation sur PIAF, rapport et PDF.
- Issue #56 (complément CDTN), mise à jour de #46, commentaires sur la PR #54 et sur l'issue #47.

Mesures exécutées.

- Reproduction des chiffres de la première version et recalcul des rangs sans tri, sur les 3 835 questions de PIAF.
- Quatre variantes de BM25 sur PIAF ; tests appariés avec questions groupées par paragraphe et par article.

- Appariement des requêtes du CDTN aux passages M2 ; contrôle des extraits du jeu de l'équipe contre les passages M2.

Résultats retenus.

- Recall@k aligné sur la convention de l'équipe (au moins un passage pertinent dans le top k), entrées invalides refusées.
- Sur PIAF, l'avantage de l'encodeur sur BM25 dépend du réglage de BM25 : de 6,1 à 2,3 points de Recall@5. PIAF ne sert qu'à valider le code.
- Jeu de l'équipe en analyse principale, CDTN en analyse secondaire, variantes groupées par requête.

Ce qui a été écarté, et pourquoi.

- La valeur p calculée en supposant les questions indépendantes : elles sont groupées par paragraphe et par article, ce qui la rend trop optimiste.

Ce que l'équipe a validé, et par qui.

- Le complément CDTN, demandé par Jibril BENSALEM, Vaneck DAGAR et Maïmouna SIGNATE, validé par Mahé BEGNIS. La PR #55, fusionnée par Remy RAYANE le 6 octobre.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- La chaîne `docs/latex` n'affiche ni les formules, ni les liens Markdown, ni les listes imbriquées dans une liste numérotée : documents réécrits en conséquence.

3.13 Session 13, 6 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. Audit de l'état du dépôt et du jeu de questions, remise au propre des pull requests et des tickets, correction de la PR #58 (#47).

Produit.

- PR #59, qui reporte le notebook 02 dans `dev` ; corrections poussées sur la PR #58 : module et script des références lexicales, rapport et PDF, PDF du journal.
- Index des réunions complété (PR #36) ; comptes rendus de #6 et #26 rétablis, dates des Weekly et jalons corrigés, branches fusionnées supprimées.

Mesures exécutées.

- Reproduction du script de la PR #57, comparaison des listes de mots vides, mesure réelle du poids de l'index, recoupement avec `rank_bm25`.
- Contrôle du jeu de questions contre les règles de son README et contre les passages M2.
- Recherche de secrets dans l'historique du dépôt, audit des dépendances (`npm audit`, `pip-audit`).

Résultats retenus.

- Le notebook 02 n'était pas dans `dev` : la PR #40 avait été fusionnée dans une branche déjà intégrée.
- Références lexicales sur la liste Snowball figée, BM25 avec la formule de Lucene par défaut, poids mesuré (0,65 Mio en gzip pour V3).
- Avant le gel du jeu : 57 pré-annotations à valider et 21 doubles annotations à faire.

Ce qui a été écarté, et pourquoi.

- Les comparaisons entre BM25 et l'encodeur du premier rapport lexical : non mesurées, et contredites sur deux requêtes.

Ce que l'équipe a validé, et par qui.

- Les PR #55, #58 et #59, fusionnées par Remy RAYANE le 6 octobre.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- L'assistant ne peut ni fusionner une PR sans relecture, ni approuver une PR qui contient ses propres commits : ces actions reviennent à un autre membre.

3.14 Session 14, 6 octobre 2026 (après-midi), Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. Audit du jeu de questions fusionné (#44), gel du jeu, règle de pertinence et dossier du Weekly 4.

Produit.

- `scripts/evaluation/controle_jeu.py` (contrôle du jeu et accord entre annotateurs) ; règle de pertinence D4 amendée et protocole mis à jour (PR #62).
- Tag `jeu-questions-v1`, posé avec l'accord de Mahé ; audit publié en commentaire de la PR #54 ; dossier du Weekly 4.

Mesures exécutées.

- Contrôles du jeu sur les cinq découpages, accord calculé sur l'annotation d'avant l'arbitrage de Q062.
- Règle de pertinence vérifiée par trois implémentations sur 470 couples découpage et extrait.

Résultats retenus.

- Accord sur le type 20 fois sur 21 (kappa 0,88) ; mêmes passages pertinents 7 fois sur 15.
- Avec la règle initiale, deux réponses en liste (Q046, Q052) n'avaient aucun passage pertinent possible dans les petits découpages.

Ce qui a été écarté, et pourquoi.

- La lecture des résultats de la PR #63 sur le lot de test : le protocole devait rester indépendant de ces chiffres.

Ce que l'équipe a validé, et par qui.

- Le gel du jeu par Mahé BEGNIS ; la règle amendée au Weekly 4.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- Le dossier temporaire de l'assistant a été vidé : environnement d'exécution à reconstruire depuis le fichier figé.

3.15 Session 15, 7 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. Préparation et suivi du Weekly 4 (#10).

Produit.

- Synthèse des sept décisions à prendre, avec leurs options et une recommandation ; message de répartition des tâches pour l'équipe.

Résultats retenus.

- Les sept recommandations ont été validées par l'équipe ; échéance du volet A fixée au 18 octobre.

Ce que l'équipe a validé, et par qui.

- Les décisions, par l'équipe réunie au Weekly 4.

Temps d'appropriation constaté.

- Non relevé sur le moment.

3.16 Session 16, 10 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. État des lieux du dépôt, application des décisions du Weekly 4, préparation de la mesure du notebook 03 (#46).

Produit.

- Décisions du Weekly 4 publiées sur `#10` ; protection de `dev` et `main` (une approbation requise) ; quatre branches fusionnées supprimées.
- `scripts/evaluation/cdtn_seuil.py` : seuil d'abstention tiré du CDTN ; protocole figé ; empreintes et verrou dans le notebook ; générateur des tableaux du rapport (PR #62).
- Audit statistique du protocole par simulation, test de non-infériorité de Tango corrigé de l'effet de plan (`03_audit_statistique.md`) ; jeu complémentaire du CDTN et sa règle figée (`04_cdtn.md`, #56) ; proposition de protocole pour l'encodeur ajusté (`05_protocole_ajustement.md`, #49) (PR #62).
- Moteur de recherche du site, avec tests et parité (PR #67, #48) ; fiches d'outils Transformers.js, ONNX Runtime et `uv` (PR #68, #25).

Mesures exécutées.

- Seuil calculé avant la mesure (0,8560, sur 479 variantes du CDTN), recalculé de façon indépendante ; fidélité des vecteurs du navigateur au fp32.
- Verrou testé : mesure refusée si le jeu, le protocole ou le seuil est modifié d'un octet.
- Simulation de 10 000 tirages par scénario sur la structure du lot de test (73 questions, 61 fiches), sans aucune donnée de mesure.
- Parité du moteur du site sur les 24 requêtes du contrôle, en Node puis dans le navigateur.

Résultats retenus.

- Aucun calcul sur le lot de test : la mesure attend la relecture de la PR #62.
- La règle figée du critère du J2 conclut à tort dans 3,0 à 5,2 % des cas à la marge, au lieu de 2,5 % ; le score de Tango corrigé tient 1,9 à 2,5 %. Amendement proposé, à décider avant la mesure.
- CDTN : 155 requêtes et 607 formulations appariées ; moteur du site identique à la page de contrôle sur 24 requêtes sur 24.

Ce que l'équipe a validé, et par qui.

- Relecture de la PR #62 demandée à Remy RAYANE.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- Données du CDTN sans licence : lues au commit figé dans `data/`, jamais versionnées.

3.17 Session 17, 11 octobre 2026, Jibril BENSALEM, Codex dans ChatGPT Work

Objet. Reporter les charges de #27, #29 et #44 et préparer la relecture CDTN de Jibril.

Produit.

- Lignes de suivi : #27, 8 h estimées et 10 h réelles, du 26 au 28 septembre ; #29, 3 h estimées et 1 h 30 réelle, le 30 septembre. Données déclarées par Vaneck et transmises par Jibril ; soutien de Jibril sur #27.
- #44 : 18 h cumulées pour Jibril, Maïmouna et Vaneck, sans répartition individuelle. Dates du 03/10 au 07/10 et mention « non estimée » reprises le 13/10 selon la demande de Jibril et la revue de Mahé.
- Extraction locale hors du dépôt de 52 requêtes et 232 formulations CDTN attribuées à JIBZZOU. Aucun texte CDTN ajouté au dépôt.
- Note initialement consignée le 11/10 dans un fichier séparé, transférée ici le 13/10 à la demande de Mahé.

Mesures exécutées.

- Tickets et références relus ; écarts vérifiés : +2 h pour #27 et -1,5 h pour #29.
- Source CDTN au commit figé et empreinte SHA-256 vérifiés ; sélection depuis les identifiants de la PR #62.
- Aucun modèle exécuté, aucune mesure sur le lot de test, aucun verdict CDTN produit par cette extraction.

Résultats retenus.

- Charges déclarées conservées, sans estimation initiale reconstruite.
- Dépassement de #27 attribué par Vaneck au mauvais découpage du corpus source (#35, PR #39).

Ce qui a été écarté, et pourquoi.

- Publication de textes CDTN : données sans licence, fiche destinée à un échange privé.
- Modification du jeu figé : le tag `jeu-questions-v1` reste la référence ; la discussion rapportée par Jibril sur la PR #65 ne vaut pas approbation GitHub d'un autre membre.

Ce que l'équipe a validé, et par qui.

- PR #69 relue et approuvée par Vaneck le 11/10 ; Mahé a demandé les corrections de dates, de mention et de journal. Jibril a demandé leur application et la fusion le 13/10.
- Relecture CDTN annoncée complète et exploitable dans le message de Mahé transmis par Jibril le 13/10. Jibril confirme ensuite, le même jour, avoir envoyé la fiche en privé à Mahé par Discord le dimanche 11/10 et supprimé le commentaire public de #56. Suppression vérifiée dans la liste des commentaires ; envoi privé déclaré par Jibril, sans lecture de Discord.

Temps d'appropriation constaté.

- Non relevé ; aucun temps reconstruit.

Difficultés rencontrées.

- Note séparée absente du PDF du journal : intégration en session selon le modèle de la section 5.
- Estimations initiales manquantes : conserver « non estimée » pour les travaux déjà commencés.

3.18 Session 18, 13 octobre 2026, Jibril BENSALEM, Codex dans ChatGPT Work

Objet. Terminer la PR #38 après ses revues et inscrire une estimation provisoire de #53.

Produit.

- Inventaire de 46 issues, séparé des dates et charges de travail ; jalons et réunions actualisés dans `docs/suivi/SUIVI.md`.
- Estimation de planification de #53 : 16 h cumulées pour Vaneck et Jibril, à la demande de Jibril, explicitement provisoire et à réviser.
- Conservation des charges déclarées de #25, #27, #29, #44, #45 et #47, et des estimations documentées de #31 et #51.

Mesures exécutées.

- Lecture des issues et de leurs commentaires, comparaison des références de dev et de la PR #38, contrôle des lignes et calcul des écarts connus.
- Vérification de l'absence du commentaire public contenant la fiche CDTN sur #56. Envoi privé le 11/10 déclaré par Jibril, sans lecture de Discord.
- Aucun moteur, modèle ou lot d'évaluation exécuté.

Résultats retenus.

- Les réunions du 19/09 et du 23/09 restent distinctes ; participants non documentés laissés NR.
- Dates GitHub converties à l'heure de Paris ; elles ne remplacent pas les dates de travail.
- Charges historiques absentes laissées NR ; une issue fermée ne prouve ni validation du dernier livrable ni statut Done du board.

Ce qui a été écarté, et pourquoi.

- Reconstitution des charges ou des comptes rendus manquants.
- Publication de textes CDTN et modification du jeu ou du protocole.
- Modification implicite des échéances : les contradictions sont signalées aux responsables.

Ce que l'équipe a validé, et par qui.

- Jibril a demandé de terminer #38 et autorisé une estimation plausible, révisable, pour #53.
- Les revues antérieures de Mahé sont prises en compte. Relecture indépendante du dernier diff attendue avant fusion.
- La session 17 reste portée par la PR #69 ; le numéro 18 évite de remplacer cette entrée encore en attente d'intégration.

Temps d'appropriation constaté.

- Non relevé ; aucun temps déduit de la durée de l'échange.

Difficultés rencontrées.

- Le PDF du journal ne peut pas encore être régénéré dans cet environnement : la chaîne du dépôt exige le support LaTeX français et des polices absents. Aucun PDF incomplet publié.
- Le statut du Project Board n'est pas consulté ; les états d'issues sont explicitement distingués.
- Les corps de certains tickets gardent des dates historiques malgré des plannings récents différents.

3.19 Session 19, 13 octobre 2026, Jibril BENSALEM, Codex dans ChatGPT Work

Objet. Résoudre le blocage de compilation du PDF du journal pour les PR #69 et #38.

Produit.

- Environnement LaTeX local complété : Babel français, règles de césure françaises, polices Libertinus, Inter, Fira Mono et Font Awesome 5.
- Format XeLaTeX local reconstruit avec la césure française ; chaîne `docs/latex` du dépôt inchangée.
- Journal de #69 synchronisé avec dev : sessions 14 à 16 préservées, session 17 ajoutée. La session 18 est portée par #38.
- PDFs du journal régénérés avec les entrées propres à chaque branche.

Mesures exécutées.

- Archives locales contrôlées avant extraction ; contrôles de compilation : erreurs, débordements, caractères manquants et règles de césure.
- Relecture du rendu des pages et contrôle de présence des entrées ajoutées dans le PDF.
- Aucun calcul de modèle ou résultat d'évaluation.

Résultats retenus.

- Le défaut provenait des dépendances de l'environnement ; les polices et la mise en page du dépôt sont conservées.
- La césure française supprime le débordement observé après la première compilation.

Ce qui a été écarté, et pourquoi.

- Archives de paquets volumineux téléchargées incomplètement, rejetées au contrôle d'intégrité ; composants ciblés récupérés depuis CTAN.
- Remplacement des polices ou modification du préambule pour contourner les dépendances.

Ce que l'équipe a validé, et par qui.

- Jibril a demandé la résolution du blocage. La fusion de #69 était déjà autorisée ; #38 attend la relecture indépendante de sa nouvelle version.

Temps d'appropriation constaté.

- Non relevé ; aucun temps reconstruit.

Difficultés rencontrées.

- Installation système empêchée par les permissions ; installation dans un TEXMF local.
- Format XeLaTeX initial sans césure française : reconstruction locale nécessaire, en plus du module de langue.

Sessions 20 à 27. Réservées aux huit sessions de Vaneck DAGAR, transmises dans sa fiche d'usage, que sa PR #72 cite déjà (sessions 26 et 27, du 11 octobre). Elles seront reportées ici depuis cette fiche.

Sessions 28 à 31, consignées a posteriori. Contrairement à la règle de la section 5, ces sessions de Mahé BEGNIS n'ont pas été consignées le jour même. Elles l'ont été le 17 octobre, à partir de l'historique de la conversation avec l'assistant et des commits, pull requests et tickets datés. Le temps d'appropriation n'a pas été relevé sur le moment.

3.20 Session 28, 11 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. Demande de Vaneck sur les fichiers de l'index du site (#48), et pull requests en attente de Mahé.

Produit.

- PR #70 : index de recherche versionné dans `front/public/index/` (option A), avec `SOURCES.md` (source, licence, date) et une règle `.gitattributes` qui interdit la conversion des fins de ligne.
- Fusion des PR #66 (journal, sessions 14 à 16) et #67 (moteur du site), approuvées par Maïmouna sur leur dernier commit ; commentaire de revue sur la PR #69 de Jibril.

Mesures exécutées.

- Licence vérifiée sur la carte du jeu Hugging Face, au commit `98744a6` : Licence Ouverte Etalab 2.0, qui autorise la rediffusion en citant la source.
- Recherche de données personnelles dans les passages : les adresses et les sept numéros trouvés sont ceux d'organismes cités par le ministère.
- Clone simulé avec `core.autocrlf=true` : avec la règle `.gitattributes`, les trois empreintes de l'index sont retrouvées à l'identique ; sans elle, 34 retours chariot s'inséraient dans l'en-tête.

Résultats retenus.

- Le site sert l'index mesuré au notebook 03 (empreinte `2ec45586…`), et non un index reconstruit sur une autre machine.

Ce qui a été écarté, et pourquoi.

- Transmettre les fichiers à Vaneck pour qu'il les intègre : reconstruit chez lui, sous Windows, l'index aurait pu différer de l'index mesuré ; la relecture de la PR #39 avait déjà montré des empreintes différentes sous Windows.

Ce que l'équipe a validé, et par qui.

- PR #70 approuvée et fusionnée par Vaneck DAGAR, le 11 octobre.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- Un commentaire publié sous le compte de Mahé parlait de lui à la troisième personne ; corrigé aussitôt, la première version restant visible dans l'historique des modifications de GitHub.

3.21 Session 29, 13 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. Amendement statistique du critère du J2, mesure unique du notebook 03 (#46) et son rapport, audit de l'ajustement de Remy (#49), seuil d'abstention du moteur (#53).

Produit.

- Protocole du notebook 03 amendé et figé à nouveau : verdict du critère du J2 par le score de Tango corrigé de l'effet de plan, nouvelle empreinte inscrite dans le notebook (PR #62, commits `a7ab3af` et `45355fb`).
- Mesure unique du notebook 03 sur le lot de test (`f1044e0`) et rapport `docs/etudes/evaluation/03_evaluation.md` (`23efdb0`), PR #73.
- Protocole de la mesure de l'encodeur ajusté complété avant son gel : recette d'export, témoin, encodage dans le navigateur (`44152df`, PR #75).
- Seuil d'abstention dans le moteur du site, appliqué seulement au modèle et à l'index pour lesquels il a été calculé (`24c2707`, PR #76).

Mesures exécutées.

- Notebook 03 exécuté une fois en mode mesure, après contrôle des empreintes du protocole, du jeu et du seuil ; une seconde exécution a donné des résultats identiques octet par octet.
- Audit du q8 de Xenova et de la recette d'export de Remy : 72 poids MatMul en int8 par canal, tables des mots en uint8 symétrique ; avec `ActivationSymmetric`, la recette redonne 74 des 75 tenseurs quantifiés. La quantification dynamique calcule son échelle sur tout le lot : les contrôles de fidélité se font requête par requête. En Python, le résultat dépend du processeur (791 et 762 sur 822 pour le même fichier) ; dans le navigateur, il est identique entre les machines.

Résultats retenus.

- Critère du J2 satisfait : Recall@5 de 43,8 % pour l'encodeur servi contre 42,5 % pour BM25 de référence, écart de +1,4 point, intervalle à 95 % de -11,5 à +14,3 points ; aucun des deux n'est démontré meilleur (McNemar, p = 1,000).
- Abstention : AUC de 0,841 ; le seuil garde 72 des 73 questions du corpus et n'écarte que 9 des 24 questions hors corpus.

Ce qui a été écarté, et pourquoi.

- La règle de Wald du 10 octobre : la simulation de la session 16 la montrait trop permissive. L'amendement, décidé avant la mesure et sans aucune donnée du lot de test, rend la conclusion plus difficile à obtenir, jamais plus facile.

Ce que l'équipe a validé, et par qui.

- PR #62 approuvée et fusionnée par Remy RAYANE ; PR #73 approuvée par Remy RAYANE ; PR #76 approuvée et fusionnée par Vaneck DAGAR, le 14 octobre.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- Le fichier de sauvegarde des vecteurs du navigateur portait un nom couvert par le motif des fichiers de mesure, et il apparaît dans la sortie du notebook : déclaré dans le commit, la PR et le rapport, sans retouche du notebook.

3.22 Session 30, 14 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. Intégration avant le Weekly 5 : licence du CDTN (#56), modèle élagué servi par le site (#50), vérification de l'encodeur ajusté livré par Remy et gel du protocole 05 (#49), relectures et import du CDTN, QCM du Weekly.

Produit.

- PR #73 fusionnée (mesure du notebook 03).
- PR #77 : licence du CDTN corrigée, Apache-2.0, avec les conditions de redistribution et la portée du contrôle des données personnelles.
- PR #78 : élagage sans perte du vocabulaire (`scripts/allegement/`) et modèle de 65,7 Mio servi par le site, à la place des 112,8 Mio téléchargés depuis Hugging Face.
- PR #75 : protocole 05 complété (fidélité de l'ajusté livré, reproductibilité, empreintes), puis figé après le Weekly (`75a39bd`, empreinte `f2c8169d`…) : tokeniseur de l'encodeur de base, aucune dérogation au calendrier.
- PR #79 : import des trois relectures du CDTN (`evaluation/cdtn/jugements.csv`), fusionnée le 17 octobre.
- Revues : approbation de la PR #63 de Remy, sans lecture des chiffres exploratoires du lot de test, réservée à l'après-mesure ; revues de la PR #72 de Vaneck.
- Hors dépôt : QCM de 20 questions du Weekly 5 (page privée, et classeur importable dans Kahoot) ; décisions non arbitrées en séance consignées sur #11.

Mesures exécutées.

- Élagage : 121 271 pièces gardées sur 250 002 ; q8 ramené de 118 308 185 à 68 862 041 octets ; découpage identique sur les 822 requêtes de contrôle, les 113 textes de la mesure, les 5 433 textes du CDTN et les 4 240 passages ; 822 vecteurs sur 822 identiques bit à bit dans le navigateur.
- Encodeur ajusté de Remy : fichiers conformes à son manifeste, réexport bit à bit depuis les poids, parité fp32 (cosinus minimal de 1,00000000) ; fidélité du q8 livré dans le navigateur : 769 sur 822, contre 761 pour le témoin (McNemar exact, 53 contre 45, p = 0,48).
- Licence du CDTN lue dans le `package.json` de la source et dans le paquet npm 2.20.0, qui contient le même fichier de requêtes.
- Fiches de relecture : format, identifiants et valeurs contrôlés ; deux verdicts « Oui » ramenés à « oui », avec l'accord de Jibril ; import simulé puis réel : 182 jugements, 155 requêtes, dont 131 jugées « oui » ou « partiel ».
- Site en ligne : avant la #78, la recherche échouait si Hugging Face était bloqué, même avec le modèle en cache ; après la #78, aucune requête vers Hugging Face.
- Serveur de contrôle de la PR #63, lancé dans un dossier isolé : 11 essais sur l'en-tête Host, l'origine et le type de contenu, tous conformes.

Résultats retenus.

- Le site sert lui-même un modèle de 65,7 Mio, aux mêmes vecteurs que le q8 d'origine.
- La fidélité de l'ajusté livré ne s'écarte pas significativement de celle du témoin.

Ce qui a été écarté, et pourquoi.

- Héberger l'encodeur ajusté sur le Hub de Hugging Face : remplacé par l'élagage sans perte, qui garde le modèle dans le dépôt.
- Lire les chiffres du lot de test de la PR #63 avant la mesure : la mesure de l'ajusté doit rester en aveugle.

Ce que l'équipe a validé, et par qui.

- PR #77 et #79 approuvées par Jibril BENSALEM ; PR #78 par Vaneck DAGAR ; PR #75 approuvée et fusionnée par Remy RAYANE ; PR #63 fusionnée par Remy après l'approbation de Mahé.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- Repointer la PR #78 sur `dev` a invalidé ses deux approbations, ce que la documentation de GitHub ne signale pas.
- Une partie des actions de l'assistant sur GitHub (fusions, commentaires) a été refusée par son contrôle des permissions ; Mahé les a lancées lui-même.

3.23 Session 31, 17 octobre 2026, Mahé BEGNIS, Claude Opus 5.5 via Claude Code

Objet. État des lieux du dépôt avant la fin du volet A, revue de la PR #80 de Vaneck (#53), documentation de clôture et jalon de mi-parcours (#43).

Produit.

- Revue de la PR #80, interface finale du site : approuvée, puis remplacée par une demande de modification après la vérification de Jibril (voir les difficultés).
- PR #81 : moteur d'exécution d'ONNX Runtime Web servi par le site, et non plus par jsDelivr.
- README du dépôt réécrit : adresse du site, chaîne de traitement, résultats, arborescence réelle, licences, branches et tags.
- Tag annoté `mi-parcours`, posé a posteriori sur la version en ligne au mi-parcours (`ac84ed3`, déployée le 30 septembre), et branche d'observation `observation/mi-parcours`.
- Journal : sessions 28 à 31, erreurs de la période en section 4, outils de la section 2 complétés.

Mesures exécutées.

- PR #80 construite (`npm ci --ignore-scripts`, `npm run build`) et parcourue dans Chromium : 5 passages ordonnés avec score, section et lien ; question gardée pendant un chargement retardé, puis traitée ; message hors périmètre pour « azerty » ; aucune requête vers Hugging Face ni Google Fonts ; aucun débordement à 375, 768 et 1 280 px ; aucune erreur dans la console.
- Essai décisif, cache vidé et jsDelivr bloqué au niveau du contexte du navigateur : la version de `dev` échoue (« Le modèle n'a pas pu être téléchargé ») ; avec la correction de la PR #81, jsDelivr et Hugging Face bloqués, le moteur démarre, aucune requête n'est tentée hors du site, et le classement est inchangé ; 15 tests sur 15.
- Audit du dépôt : aucun secret trouvé ; un seul fichier de plus de 10 Mio, le modèle servi ; 62 commits de `dev` portent une adresse e-mail personnelle, tous antérieurs au 13 octobre.

Résultats retenus.

- La mesure de l'encodeur ajusté n'a pas été faite avant le 16 octobre : le notebook 05 n'était pas construit, et l'import des relectures n'a été fusionné que le 17 octobre. La règle de repli du protocole 05 s'applique : le site sert l'encodeur de base pour la fin du volet A. La mesure reste possible après, à titre descriptif, pour le rapport.
- La branche principale avait 175 commits de retard, et aucun tag de mi-parcours n'était posé ; Jibril a mis `main` à jour le jour même (PR #74).

Ce qui a été écarté, et pourquoi.

- Écrire le résultat dans le protocole 05 : son empreinte, que le notebook de mesure doit contrôler, aurait changé ; le résultat est consigné dans le README, dans ce journal et dans le classeur de suivi.

- Poser `mi-parcours` sur l'état actuel du dépôt, qui ne représente pas le jalon ; nommer la branche d'observation comme le tag, ce que git signale comme ambigu.
- Réécrire l'historique pour retirer les adresses : interdit sur une branche partagée ; chaque membre règle son compte GitHub pour éviter de nouvelles expositions.

Ce que l'équipe a validé, et par qui.

- PR #74 approuvée et fusionnée par Jibril BENSALEM ; documentation de clôture et PR #81 soumises à la relecture de Jibril BENSALEM et Vaneck DAGAR.

Temps d'appropriation constaté.

- Non relevé sur le moment.

Difficultés rencontrées.

- `git log --since` arrête le parcours au premier commit plus ancien que la date : un premier audit des adresses a conclu à tort qu'il n'y en avait aucune.
- Mon test de la PR #80 écoutait les requêtes au niveau de la page : celles du moteur d'exécution vers jsDelivr n'y apparaissaient pas. Jibril l'a relevé dans sa vérification ; l'essai avec le CDN bloqué l'a confirmé.

4 Erreurs détectées par la vérification

Cette section est tenue volontairement. Elle documente ce que la relecture systématique a permis de rattraper, et constitue le principal argument en faveur de notre méthode.

Date	Erreur	Détection	Correction
18/09	Comptage des notions faussé par une recherche en sous-chaîne, qui comptait « rag » dans « paragraphe »	incohérence des ordres de grandeur	comptage refait avec frontières de mots
18/09	Expression régulière renvoyant zéro occurrence de LSTM alors qu'il y en avait 133	contradiction avec un autre compteur	passage à une implémentation Python vérifiée
18/09	Nombre de fichiers audités annoncé à 12, réel 14 dont 3 quasi-doublons	recomptage explicite	corpus de référence ramené à 11 fichiers dédoublonnés
18/09	Classification des paquets Python ignorant les roues `universal2`, donc deux paquets déclarés à tort incompatibles	contrôle manuel des étiquettes	reclassement complet
18/09	Rang mondial du dépôt ECC annoncé au 13e, réel 16e	comptage des dépôts plus étoilés	corrigé, et l'argument en est sorti renforcé
18/09	Tirets cadratins rendus en « --- » dans les tableaux du PDF	relecture visuelle du rendu	caractères Unicode utilisés directement
19/09	Taille d'un modèle annoncée par l'API à 0,5 Mio, réelle 294,6 Mio, les poids étant dans des fichiers externes	invraisemblance pour un modèle de 300 millions de paramètres	mesure des fichiers externes
19/09	Charge utile du navigateur relevée à 5,5 Mio pour un modèle de 112,8 Mio	invraisemblance	les ressources d'origine tierce ne déclarent pas leur taille, mesure refaite fichier par fichier, résultat 135,6 Mio
19/09	Seuil de réussite Recall@5 proposé à 0,80 sans fondement	recherche des résultats publiés du modèle : 23 mesures de récupération, toutes en anglais	seuils reformulés en écarts appariés face à une baseline
19/09	Conclusion hâtive sur l'absence de board, tirée d'une sortie vide	la sortie vide masquait une erreur de périmètre d'autorisation	aucune conclusion tirée, limite déclarée dans le rapport
19/09	Rapport annonçant trois milestones et dix labels inexistants	consultation du dépôt	section 2 alignée sur l'état vérifié

Date	Erreur	Détection	Correction
19/09	Lecture immédiatement consécutive à une écriture renvoyant un état périmé	garde-fou conditionnant la suppression à un décompte nul	suppression refusée puis reprise après contrôle direct
19/09	`gh api` basculant de GET en POST dès qu'un champ `-f` est fourni	échec en 422 sur un titre manquant	requêtes de lecture écrites sans `-f`
19/09	Suppression de `readme.md` détruisant le `README.md` écrit juste avant, le système de fichiers étant insensible à la casse	contrôle systématique après écriture	fichier réécrit, casse forcée en deux étapes avec `git mv`
19/09	Clone local pointant vers l'ancienne adresse du dépôt, périmée depuis son transfert à l'organisation	lecture de l'adresse distante avant publication	adresse corrigée avant tout envoi
19/09	Banc d'essai terminé sans aucune sortie, le tube de filtrage retenant l'affichage	fichier de sortie vide alors que le processus était terminé	écriture directe vers un fichier, tampon vidé explicitement
04/10	Test de McNemar pour questions groupées attribué à Durkalski (2003), alors que la formule employée est celle d'Obuchowski (1998)	lecture du code source d'une implémentation publiée	attribution et formule corrigées avant publication
04/10	Appariement du CDTN à nos passages : 189 requêtes le matin, 175 l'après-midi, selon la règle employée	recalcul indépendant	règle d'appariement à écrire et figer avant la mesure (#56)
06/10	Aperçu des résultats de l'encodeur calculé sur le jeu de test avant l'écriture du protocole, puis un commentaire affirmant qu'aucune mesure n'avait été faite	relecture de la méthode, puis du commentaire avant envoi	aperçu ni utilisé ni diffusé aux annotateurs, phrase corrigée avant envoi, protocole à écrire avant toute mesure
06/10	Règle de pertinence proposée qui excluait par construction les réponses en liste des petits découpages	audit du jeu final contre les cinq découpages	seconde condition ajoutée avant la validation du protocole, d'après les seules annotations
10/10	Nombre de fiches visées par le seuil du CDTN annoncé à 61 au lieu de 50, compté sur toutes les requêtes appariées	recomptage avant le commit	corrigé avant le gel du protocole
10/10	Empreinte SHA-256 débordant de 254 points dans la marge du PDF du protocole	journal de compilation	empreintes regroupées dans un bloc de code
10/10	Chiffres de l'audit statistique tirés d'un essai préliminaire, à une autre graine, et non du script versionné	réexécution du script avant le commit	chiffres alignés sur la sortie reproductible
13/10	Recalcul indépendant de l'effet de plan différent de celui du module de métriques	écart entre les deux calculs	écart dû au degré de liberté de l'estimateur ; avec `ddof=1`, accord à 1e-14, le module était juste
14/10	Fidélité de l'encodeur ajusté publiée à 753 sur 822, mesurée sur un export q8 antérieur, quantifié sans `ActivationSymmetric`	nouvelle mesure du q8 livré, dans le navigateur	769 sur 822 ; protocole 05 et rapport de Remy corrigés
14/10	Données du CDTN déclarées « sans licence » le 10/10, faute de fichier LICENSE, alors que leur `package.json` déclare Apache-2.0	relecture de la source et du paquet npm	`04_cdtn.md` corrigé (PR #77) ; l'alerte et la demande au support de GitHub du 13/10 reposaient sur cette erreur
14/10	Première règle d'élagage qui retirait les diacritiques combinants et la lettre µ : un passage sur 4 240 changeait de découpage	comparaison du découpage sur tous nos textes	diacritiques et lettres grecques gardés ; découpage identique partout
14/10	Taille du q8 de Xenova écrite 112,9 Mio au lieu de 112,8 dans la PR #78 et trois de ses fichiers	recalcul depuis le nombre d'octets	corrigé (`a9a71c5`) ; 112,9 Mio est la taille du témoin de Remy
14/10	`.gitignore` de la PR #63 ignorant tous les fichiers `.onnx`, donc le modèle servi par le site	test des règles d'exclusion, puis essai dans un dépôt jetable : `git add` d'un dossier l'omettait sans avertissement	ligne retirée par Remy avant la fusion
14/10	Premier test de ces règles invalide : option non reconnue, erreurs masquées, donc aucune détection	listes vides jugées suspectes, règle témoin ajoutée	test refait avec `core.excludesFile`
14/10	Cache du navigateur attribué à IndexedDB, alors que Transformers.js 4.3.0 utilise l'API Cache	lecture du code source de la bibliothèque	`caches.delete` à la place de `indexedDB.deleteDatabase` (PR #63)
14/10	Hypothèse de l'assistant, publiée dans une revue de la PR #72 : avec le modèle en cache, bloquer Hugging Face par `page.route()` n'empêcherait pas le chargement	essai sur le site en ligne : le chargement échoue	hypothèse retirée dans un commentaire de suivi ; Vaneck a mesuré le cas réel et corrigé sa fiche

Date	Erreur	Détection	Correction
14/10	QCM du Weekly : la bonne réponse était la plus longue dans 13 questions sur 20	script de contrôle des longueurs	réponses rééquilibrées, 3 cas sur 20
17/10	Audit des adresses e-mail concluant à zéro exposition, `git log --since` ayant arrêté le parcours trop tôt	contradiction avec un commit connu	historique parcouru en entier : 62 commits concernés
17/10	Revue publiée de la PR #80 affirmant « aucune requête vers jsDelivr », les requêtes ayant été écoutées au niveau de la page seulement	vérification de Jibril, puis essai avec le CDN bloqué : la recherche échoue	revue corrigée en demande de modification ; moteur d'exécution servi par le site (PR #81)

Bilan intermédiaire. Seize erreurs ou pièges détectés et traités en deux jours. **Cinq d'entre elles figuraient déjà dans un livrable rédigé** et ont été rattrapées avant l'envoi : le nombre de fichiers audités, le rang du dépôt ECC, le seuil de réussite sans fondement, les milestones et labels inexistants, et le rendu des tirets dans le PDF composé.

Aucune n'a été trouvée par simple relecture du texte. Toutes l'ont été par confrontation à une mesure, à un calcul indépendant ou à l'inspection visuelle du rendu. C'est la méthode qui les a fait apparaître, pas l'attention.

Bilan du 11 au 17 octobre. Douze erreurs ou pièges détectés et traités. **Sept figuraient déjà dans une pull request, une revue ou un document publiés** : la licence du CDTN, la fidélité de l'ajusté, la taille du q8, le `.gitignore` de la PR #63, l'attribution du cache à IndexedDB, l'hypothèse sur `page.route()` et la revue de la PR #80. Deux ont été trouvées par un relecteur de l'équipe, Jibril, et non par l'assistant. Comme les précédentes, toutes ont été trouvées par une mesure, un essai ou la lecture d'une source primaire.

5 Modèle de saisie

Chaque membre ajoute ses sessions selon ce modèle, le jour de l'usage. Les éléments ne se reconstituent pas après coup.

```
### Session N, date, prénom NOM, outil et modèle

**Objet.**
**Produit.**
**Mesures exécutées.**
**Résultats retenus.**
**Ce qui a été écarté, et pourquoi.**
**Ce que l'équipe a validé, et par qui.**
**Temps d'appropriation constaté.**
**Difficultés rencontrées.**
```

Deux règles de tenue :

1. Une session non consignée le jour même est considérée comme non consignée. Le sujet valorise le temps d'appropriation constaté et les conditions dans lesquelles un outil échoue, qui sont les premiers éléments oubliés.
2. Toute production assistée porte le nom de son relecteur. Sans relecteur nommé, elle n'entre pas dans un livrable.

6 Ce que ce journal alimentera

Trois sections du rapport final s'appuieront directement sur ce document.

- **Analyse technique.** Les mesures consignées ici fournissent les chiffres de coût, de latence et de qualité demandés.
- **Retour d'expérience.** La section 4 documente les difficultés réelles et leur résolution, que le sujet demande de traiter de façon factuelle.
- **Cinq outils novateurs.** Les temps d'appropriation, les échecs et les comparaisons entre outils consignés au fil de l'eau constituent la matière de cette section, qui vaut jusqu'à trois points et dont la grille valorise au moins une critique argumentée.