Rapport du projet

Équipe Data Tigers • NLP 2 • M2 Data & IA • FGES

Version 0 du 19 octobre 2026, à compléter jusqu'à la V1

Équipe	Data Tigers
Membres	Mahé BEGNIS, Remy RAYANE, Jibril BENSALEM, Vaneck DAGAR, Maïmouna SIGNATE
Module	NLP 2, projet de fin de module
Formation	Master 2 Data & IA, FGES, Université Catholique de Lille
Année universitaire	2026-2027
Enseignant	Adrian ROSARI
Version	Vo du 19 octobre 2026, à compléter jusqu'à la V1, à remettre strictement avant le jalon J4

Objet. Ce rapport suit la section 11 du sujet : analyse technique, retour d'expérience, axes de progression et cinq outils novateurs. Cette Vo est écrite à la fin du volet A. Elle rédige ce qui est déjà établi et signale explicitement ce qui reste à mesurer ou à rédiger, principalement le volet B et les axes de progression individuels.

Sources. Tous les chiffres proviennent du dépôt (`datatigersNLP/data_tigers_nlp`) : études, protocoles, mesures, classeur de suivi, journal d'usage de l'IA, historique Git et tickets GitHub. L'annexe relie chaque chiffre à sa source. Les mesures du site en ligne datées du 19 octobre 2026 ont été faites sur la version `7e2ce07`.

Ce document a été produit avec l'assistance d'outils d'intelligence artificielle. Les usages sont consignés dans le journal prévu par le sujet ; chaque chiffre a été recoupé avec sa source avant publication.

Table des matières

1 Le projet en bref . . . **3**

2 Analyse technique . . . **3**

2.1 Ce que chaque volet met en œuvre . . . 3
2.2 Comparaison sur les six dimensions du sujet . . . 4
2.3 Ce que les mesures ont appris . . . 4
2.4 À compléter pour la V1 . . . 5

3 Retour d'expérience . . . **5**

3.1 Méthodologie . . . 5
3.2 Outillage . . . 6
3.3 Difficultés . . . 7
3.4 Enseignements . . . 8

4 Axes de progression **8**
4.1 Mahé BEGNIS 8
4.2 Remy RAYANE 8
4.3 Jibril BENSALEM 10
4.4 Vaneck DAGAR 10
4.5 Maïmouna SIGNATE 11
5 Cinq outils novateurs **11**
5.1 Transformers.js 12
5.2 ONNX Runtime, en Python et sur le Web 12
5.3 Playwright 12
5.4 GitHub CLI 12
5.5 Assistants de développement par IA 13
6 Ce qui reste avant la V1 . . . . . **13**
Annexe. Chiffres et sources **13**

1 Le projet en bref

Volet	Cas	Ce qui est livré
A, application en ligne	A3, recherche sémantique en corpus fermé	site public https ://datatigersnlp.github.io/data_tigers_nlp/, inférence dans le navigateur, aucun serveur
B, application locale	B1, assistant réglementaire sourcé, avec abstention	chaîne RAG locale avec Qwen2.5-7B-Instruct, en cours (PR #85)

Le corpus est commun : les 261 fiches pratiques du ministère du Travail, découpées en 4 240 passages, instantané SocialGouv du 11 septembre 2026, sous Licence Ouverte Etalab 2.0. Le cas A3 constitue la couche de récupération du cas B1 : le découpage, l'encodage et l'index sont écrits une fois et servent aux deux volets.

La fin du volet A est marquée par le tag annoté `volet-a-v1`, posé le 18 octobre 2026 sur `main` (8955962). Le site en ligne est déployé depuis `dev` ; il intègre depuis le 19 octobre deux changements postérieurs au tag (PR #88 et #102).

2 Analyse technique

2.1 Ce que chaque volet met en œuvre

	Volet A	Volet B
Modèle	`multilingual-e5-small`, encodeur de phrases	`Qwen2.5-7B-Instruct`, modèle génératif
Forme servie	q8 (entiers sur 8 bits), vocabulaire élagué sans perte : 65,7 Mio	GGUF Q4_K_M : 4,36 Gio
Exécution	navigateur du visiteur, Transformers.js 4.3.0 et ONNX Runtime Web	PC portable, Ollama, GPU NVIDIA RTX 5070 Laptop (8 Gio de VRAM)
Sortie	5 passages réels, ordonnés, avec score, section et lien	réponse rédigée, citant les passages fournis
Entraîné par l'équipe	non : encodeur pré-entraîné ; ajustement étudié (#49), non servi	non : adaptation à engager (section 6)

Un point à dire d'emblée. Le sujet oppose un modèle « de faible capacité, long à entraîner, entièrement maîtrisé » (volet A) à un modèle « performant, immédiatement disponible, dont la composition n'est pas connue » (volet B). Il précise que le modèle servi du volet A « doit préférentiellement être celui que vous avez entraîné ». Ce n'est pas notre cas. Le site sert un encodeur pré-entraîné ouvert, dont les poids, le tokeniseur et la licence (MIT) sont connus. Nous l'avons quantifié, élagué, indexé et servi nous-mêmes, mais pas entraîné.

L'équipe a tenté de l'adapter (#49) : apprentissage contrastif sur 109 paires question-passage générées en local avec Qwen, 2 époques, 185,5 secondes sur processeur. Le protocole 05, figé avant toute mesure, ne servait l'encodeur ajusté qu'à trois conditions : sa parité entre Python et navigateur vérifiée, un écart de Recall@5 avec la base positif ou nul sur les deux jeux d'évaluation, et un hébergement possible avant le 17 octobre. Il gardait la base si une condition manquait le 16 octobre. La mesure n'ayant pas été faite à temps, cette règle écrite d'avance s'est appliquée : le site sert l'encodeur de base.

La maîtrise porte donc sur l'exécution, pas sur l'apprentissage :

- chaque octet servi est versionné et vérifié par empreinte ;

- les vecteurs du navigateur sont contrôlés contre ceux de Python ;
- à l'exécution, rien ne dépend d'un service tiers.

2.2 Comparaison sur les six dimensions du sujet

Les mesures du volet B sont celles des essais réels consignés à ce jour ; la mesure systématique relève de #52.

Dimension	Volet A, mesuré	Volet B, état au 19 octobre
Coût	aucun coût de service : GitHub Pages, fichiers statiques. Le coût est reporté sur le visiteur : 61,3 Mio transférés à la première visite, puis mise en cache	aucun coût de service, mais un matériel dédié : modèle de 4,36 Gio, 5 694 Mio de VRAM occupés après le premier appel (1 036 Mio avant)
Latence	recherche : 21 ms en médiane sur 10 questions (19 à 24 ms), 46 ms pour la première ; premier résultat 20,1 s après l'ouverture d'une page jamais visitée, sur la connexion de mesure	premier appel 37,7 s, dont 19,1 s de chargement ; génération de 47 à 67 tokens par seconde. Chaîne RAG, question Q036 : 46,2 s au total, dont 21,9 s de chargement, 18,5 s de lecture du prompt et 5,8 s de génération
Qualité	Recall@5 de 43,8 % sur 73 questions du corpus (IC 95 % : 32,9 à 55,4), contre 42,5 % pour BM25 ; non-infériorité démontrée (marge de 15 points), supériorité non démontrée. La bonne fiche est dans les 5 résultats pour 83,6 % des questions	non mesurée. Deux essais : Q036, réponse citée mais conditions d'application omises ; Q003, abstention correcte
Contrôle	tout est figé et vérifiable : modèle, index et passages par empreinte SHA-256, versions épinglées, vecteurs identiques bit à bit entre q8 d'origine et q8 élagué (822 sur 822)	poids et gabarit figés par empreinte, température 0, graine fixée ; mais le comportement du modèle dépend de données d'entraînement inconnues
Explicabilité	chaque résultat est un passage réel, avec son score de similarité, sa section et le lien vers la fiche ; rien n'est généré. Limite : le score ne se lit qu'en relatif ; les cinq passages de la question sur les congés payés vont de 0,895 à 0,889	la réponse cite ses passages ; une citation existante ne prouve ni sa justification ni la couverture de chaque affirmation
Dépendance à un fournisseur	à l'exécution, aucune : seul le site est contacté, vérifié sous Chromium, Firefox et WebKit. À la construction : GitHub (Pages, Actions), npm, et Hugging Face pour l'origine du q8, recopié dans le site	Ollama, poids publiés par l'équipe Qwen (Apache 2.0), pilote et GPU NVIDIA ; aucune API distante à l'exécution

Abstention. Le volet A signale les questions hors du périmètre par un seuil de similarité, fixé sur un jeu externe (CDTN) avant la mesure. Le score sépare assez bien les questions hors corpus (AUC 0,841, IC 95 % : 0,747 à 0,921). Mais le seuil conserve 72 des 73 questions du corpus et ne rejette que 9 des 24 questions hors corpus. Il repère surtout les saisies sans rapport avec le droit du travail, et l'interface ne promet pas davantage.

2.3 Ce que les mesures ont appris

- **Mesurer là où le modèle est servi.** Le q8 exécuté dans le navigateur ne calcule pas exactement comme le même q8 en Python. Il donne le même premier résultat que le calcul exact pour 91,8 % des requêtes, contre 96,5 % prévus par la simulation Python. Le premier résultat reste toutefois dans les 5 premiers pour 99,9 % d'entre elles. Seule la mesure dans le navigateur a révélé l'écart.
- **L'essentiel du poids était inutile.** La table des mots représente 81,6 % des paramètres de l'encodeur et couvre 250 037 pièces d'une centaine de langues. Retirer celles qui contiennent une lettre étrangère aux alphabets latin et grec ramène le q8 de 112,8 à 65,7 Mio (−42 %), avec des sorties identiques bit à bit. Le modèle passe ainsi sous la limite de 100 Mio par fichier de GitHub et peut être servi par le site lui-même.
- **Une dépendance invisible.** À son import, Transformers.js fait télécharger le moteur d'exécution ONNX Runtime depuis le CDN jsDelivr. Le site semblait autonome, et seul un essai avec ce CDN bloqué l'a montré. Le moteur est servi par le site depuis la PR #81.
- **Le parcours au clavier dépend du système.** Sur macOS, où la navigation au clavier est désactivée par défaut, Tab ne passe pas par les boutons. Dans le menu sur téléphone, le focus quittait alors le panneau. La tabulation y est désormais entièrement gérée par le code (PR #102), et vérifiée sous trois moteurs.

- **Le contrôle a priori a tenu.** Le protocole d'évaluation du notebook 03 a été figé, avec son empreinte, avant la mesure unique du 13 octobre, et la règle de repli de l'encodeur ajusté avait été écrite d'avance. Les deux décisions qui en découlent, le verdict du critère du J2 et le choix de l'encodeur servi, résultent de l'application de règles fixées avant les résultats.

2.4 À compléter pour la V1

- Mesures du volet B avant et après adaptation (#52), sur le jeu humain et dans les conditions du volet A pour la récupération.
- Comparaison finale des deux volets sur les six dimensions, avec les mêmes questions.
- Coût réel en temps de calcul de l'adaptation du volet B.

3 Retour d'expérience

Cette partie porte sur la conduite du projet. Les faits ci-dessous sont communs et recoupés avec le dépôt ; les analyses personnelles figurent dans la section 4.

3.1 Méthodologie

Organisation et décisions. Les rôles ont été fixés à la réunion de cadrage du 19 septembre :

- Mahé, responsable technique et tenue du journal d'usage de l'IA ;
- Jibril, gestion du board, du classeur de suivi et des comptes rendus ;
- cinq domaines, chacun avec une personne principale et un soutien.

Domaine	Principal	Soutien
D1, corpus et segmentation	Maïmouna, Vaneck	Jibril
D2, encodeur et index	Remy	Mahé
D3, front et déploiement du volet A	Maïmouna, Vaneck	Remy, Mahé
D4, socle RAG et inférence locale	Jibril	Remy
D5, adaptation et évaluation du volet B	Mahé	Jibril

Les décisions se prennent en Weekly. Quand un compte rendu ne rapporte pas d'arbitrage, le responsable technique consigne les décisions par écrit dans le ticket (Weekly 4), ou les arrête après la séance en indiquant qu'elles restent discutables (Weekly 5). Les mesures ont été encadrées par des protocoles figés avant toute mesure (notebook 03, protocole 05), avec leur empreinte.

Réunions. Six réunions sont documentées entre le 14 septembre et le 14 octobre, en général une par semaine :

Date	Réunion	Compte rendu
14/09	Weekly 1, #2	lancement et lecture du sujet ; présence non documentée
19/09	Weekly 2, cadrage, #6	complet : cas A3 et B1, corpus, modèles, domaines ; support versé
23/09	réunion d'avancement, #26	complet : cinq actions, responsables et échéances

Date	Réunion	Compte rendu
30/09	Weekly 3, #9	resté au stade du modèle : décisions non renseignées
07/10	Weekly 4, #10	décisions consignées en commentaire par le responsable technique
14/10	Weekly 5, #11	partiel : avancement rapporté, présents non renseignés ; décisions arrêtées après la séance

Supports de documentation. Le dépôt réunit plusieurs types de documents :

- une étude par étape de la chaîne (découpage, indexation, évaluation, allègement, ajustement, inférence locale) ;
- les protocoles et l'audit statistique de l'évaluation ;
- le classeur de suivi, le journal d'usage de l'IA et une fiche par outil ;
- les rapports de jalon.

Leur utilité constatée est surtout de deux ordres :

- **Décider sans débat a posteriori** : les protocoles figés ont permis d'appliquer la règle de repli.
- **Rattraper des erreurs** : le journal recense 68 erreurs ou pièges détectés par la vérification au 18 octobre, dont 32 du 11 au 18 octobre.

Les PDF sont produits depuis le Markdown par une chaîne LaTeX commune (`docs/latex`).

3.2 Outillage

Dépôt Git.

- **Branches** : `main` reçoit l'état livrable, `dev` l'intégration (le site est déployé depuis `dev`), et chaque ticket a sa branche `feat/`, `fix/` ou `docs/` suivie de son numéro.
- **Jalons** : ils sont marqués par des tags annotés (`jalon-j2`, `jeu-questions-v1`, `mi-parcours`, `volet-a-v1`) et une branche d'observation (`observation/mi-parcours`).
- **Protection** : `dev` et `main` exigent depuis le 10 octobre une approbation, y compris pour les administrateurs, et un nouveau commit annule les approbations antérieures.

Indicateur, au 19 octobre	Valeur
Pull requests	50 : 42 fusionnées, 6 ouvertes, 2 fermées sans fusion
Fusionnées avec l'approbation d'un autre membre	34 sur 42
Revues déposées	61 : 38 approbations en vigueur, 6 demandes de modification, 11 commentaires, 6 revues annulées par un commit ultérieur
Commits hors fusion sur `dev`	174 ; 173 suivent le format `type(portée): sujet` (99 %)

Les 8 PR fusionnées sans approbation enregistrée se répartissent ainsi :

- cinq, le 6 octobre (#54, #55, #58, #59, #60), avant la mise en place de la protection ;
- une dans une branche de travail (#40) ;
- une après une demande de modification traitée, sans approbation formelle (#32) ;
- une intégrée par une autre PR approuvée (#86, par la #87).

Board de tickets. Le board porte l'état des tickets ; le classeur de suivi le complète par les dates et les charges.

Le pilotage a été réel pour la création des tickets, mais rétrospectif pour les charges :

- **Création préalable** : les 54 tickets ont été créés par vagues de planification (19 le 20/09, 6 le 23/09, 11 le 30/09, 8 le 18/10). Les 25 PR qui citent un ticket dans leur titre ont toutes été ouvertes après la création de ce ticket.
- **Charges rétrospectives** : au 19 octobre, 45 tickets sur 54 n'ont pas d'estimation dans le classeur de suivi.
- **Capture absente** : la capture du board attendue au mi-parcours n'a pas été versionnée.

Relecture par un tiers. La relecture croisée a trouvé des erreurs que l'auteur n'avait pas vues. Sur les 19 erreurs des sessions de Mahé entre le 11 et le 18 octobre, 4 ont été trouvées par Jibril en relecture. Vaneck en a relevé deux dans des PR de Mahé (#76 et #78). Les revues de Jibril sur les PR documentaires (#82, #89, #102) ont vérifié les chiffres contre l'API GitHub et contre le rendu du PDF.

Assistants d'IA. Leur usage est consigné session par session : 37 sessions au 18 octobre, et la session 38 du 19 octobre en relecture (PR #104). Les outils déclarés sont Claude Code, Google Antigravity avec Gemini, ChatGPT et Codex. La règle d'équipe est que tout élément produit avec un assistant soit relu et vérifié par une mesure avant d'être publié. La section 5 en fait le bilan critique.

3.3 Difficultés

Techniques. Les principales, avec leur résolution :

- **Taille du modèle** : le q8 de 112,8 Mio dépassait la limite de 100 Mio par fichier de GitHub. Résolu par l'élagage sans perte.
- **Écart navigateur et Python** : le q8 du navigateur ne donne pas les mêmes résultats que celui de Python. Résolu en mesurant dans le navigateur.
- **CDN caché** : le moteur d'exécution venait de jsDelivr. Résolu en le servant depuis le site.
- **Reproductibilité entre machines** : l'index reconstruit sous Windows diffère de celui de macOS. Le site garde l'index de référence, vérifié par empreinte.
- **Tabulation sous Safari** : résolu en gérant entièrement Tab dans le menu.
- **Mesure de l'encodeur ajusté (#49)** : non faite avant l'échéance. La règle de repli s'est appliquée.

Organisationnelles et de disponibilité.

- **Calendrier non confirmé** : les dates du sujet et celles annoncées oralement divergent, et le calendrier n'est pas confirmé par écrit (#8). L'équipe s'est fixé le 18 octobre pour clore le volet A.
- **Journal en retard** : plusieurs sessions du journal ont été consignées a posteriori (22 à 25, 28 à 31, 33, 34 et 36), à partir des commits et des tickets, alors que la règle est de consigner le jour même.
- **Comptes rendus incomplets** : deux comptes rendus de Weekly sont restés incomplets (#9, #11).
- **Pièges d'intégration** : changer la base d'une PR annule ses approbations (#78), et une PR ouverte vers `main` au lieu de `dev` est entrée en conflit avec `dev` (#86). Les deux ont coûté des relectures supplémentaires.

Écarts entre charge estimée et charge réelle. Seuls 4 tickets ont à la fois une estimation et une charge réelle :

Ticket	Estimé	Réel	Écart
#27, corpus	8 h	10 h	+2 h
#29, première page en ligne	3 h	1 h 30	−1 h 30
#45, validation des métriques	4 h	3 h 30	−30 min
#47, références TF-IDF et BM25	4 h	3 h 30	−30 min

Le seul dépassement (#27) est attribué au mauvais découpage du corpus source, repris ensuite (#35). L'échantillon est trop petit pour analyser les causes de sous-estimation. La cause principale est en amont : les estimations n'ont pas été saisies avant le travail, et une charge réelle ne se reconstitue pas après coup. C'est la lacune de méthode la plus nette du projet à ce stade.

3.4 Enseignements

Propositions communes, à discuter en équipe avant la V1 :

- **Estimer avant de commencer**, dans le ticket, et saisir la charge réelle à la fermeture : c'est la seule façon de produire l'analyse des écarts que demande le sujet.
- **Consigner le jour même** les sessions d'usage de l'IA et les comptes rendus, pendant la réunion.
- **Garder les protocoles figés et les règles de repli écrites d'avance** : ils ont permis de décider sans biais et à l'heure.
- **Mesurer dans les conditions réelles et sur plusieurs plateformes** dès le premier prototype : navigateurs, systèmes, réseau bloqué.
- **Automatiser les contrôles** : depuis le 19 octobre, les tests du moteur passent avant chaque déploiement, et un écart de version d'une dépendance arrête la mise en ligne. Ce garde-fou aurait dû exister dès le premier déploiement.

4 Axes de progression

Le sujet recommande une rédaction individuelle. Chaque membre complète son encadré : compétences techniques acquises, lacunes et points à approfondir, puis positionnement dans l'équipe, délégation, demandes d'aide, arbitrages, délais.

4.1 Mahé BEGNIS

> À rédiger par Mahé.

4.2 Remy RAYANE

Compétences techniques acquises.

- **Architecture d'indexation vectorielle et contraintes Web** : conception et découpage de l'index en format binaire Little-Endian Float32 (`piaf_reduced_index.bin`) et métadonnées JSON (#30), puis intégration de l'index de production `index_m2.f32` (4 240 passages, 6,21 Mio) chargé via l'API `TypedArray` (`Float32Array`) sans blocage de l'interface par `JSON.parse()`. Exploitation de la normalisation L2 pour ramener la similarité cosinus à un produit scalaire en O(d) vectorisable en WebAssembly / SIMD, et respect strict de l'asymétrie d'encodage E5 (`query:` vs `passage:`) pour prévenir la dégradation du Recall@k.
- **Évaluation quantitative en recherche d'information (IR)** : mise en place de la chaîne de métriques sur PIAF (#45) et de références lexicales TF-IDF et BM25 (#47) afin d'objectiver les écarts entre recherche dense et approches par mots-clés (notamment la variante BM25 V3 à racinisation française conservant les négations juridiques, reprise dans la récupération hybride du volet B, #138 / PR #141).

- **Apprentissage contrastif et adaptation d'encodeur** : fine-tuning de `multilingual-e5-small` avec perte contrastive (`MultipleNegativesRankingLoss`) sur 109 paires hors fiches de test (#49, PR #63), avec cloisonnement au niveau des fiches et filtre lexical Jaccard.
- **Portabilité ONNX et quantification INT8** : diagnostic de la divergence arithmétique entre Python et WebAssembly (Transformers.js), puis alignement par quantification symétrique (`ActivationSymmetric`) rétablissant 74 tenseurs sur 75 bit à bit à Xenova sur le témoin et portant la fidélité in-browser de l'ajusté à 93,55 % (769/822 concordances), avec un modèle témoin isolant l'effet de graphe opset 14 (112,9 Mio sur nos exports ; l'élagage sans perte à 65,7 Mio sur la base Xenova a ensuite été conçu et livré par Mahé en #50 / PR #78).
- **Débogage de runtime et contrôles locaux** : identification du cache réel de Transformers.js via l'API Cache (`caches.delete` sur `transformers-cache`, et non IndexedDB), sécurisation des chemins dans `serveur_controle.py`, diagnostic de sérialisation du tokeniseur Unigram sous `transformers` 5.18, et vérification du refus d'adaptateur LoRA (`errAdaptersUnsupported`) dans Ollama `v0.40.5` (#107, session 45).

Lacunes et points à approfondir.

- **Vérification factuelle des productions assistées par IA** : entre le 27 octobre et le 10 novembre, plusieurs erreurs factuelles ou de méthode ont dû être corrigées après revue humaine — numérotation et bilan de section 4 dans la PR #120 (session 45), perte des accents lors d'une réécriture complète (#134), puis en première version des fiches d'outils (#135) : mention d'`uv 0.4.29` alors que `uv` est absent de mon poste, attribution erronée de l'élagage de la PR #78, version d'Ollama non alignée sur l'épinglage officiel `0.40.13` (mon démon local ayant dérivé en mise à jour automatique vers `0.40.15`), et statut fermé attribué à tort au ticket #49. J'ai encore à systématiser la vérification locale de chaque version, script, attribution et statut avant publication.
- **Métrologie et garde-fous des modèles génératifs (Volet B)** : la prise en main de l'inférence locale Qwen 2.5 (#31) et la relecture de la chaîne RAG et de sa récupération v2 (#138, PR #141) ont montré que le contrôle automatique des citations (`[P1]`) porte uniquement sur la syntaxe des identifiants et ne garantit pas la justification sémantique des affirmations ; l'évaluation des réponses reste plus délicate à borner que les métriques déterministes d'embeddings.
- **Portabilité Windows des environnements et tests** : les écarts rencontrés sous Windows 11 — absence de Perl pour `latexmk`, syntaxe PowerShell incompatible avec certains scripts POSIX, variations d'arrondis CPU Python par rapport à macOS, et erreur de privilèges `WinError 1314` sur `os.symlink` relevée lors de l'exécution locale de `test_export.py` (#140, PR #147) — montrent le besoin d'anticiper les contraintes système dans nos suites de tests.
- **Optimisation bas niveau et WebGPU** : le travail est resté centré sur le CPU et WebAssembly ; l'exploitation de WebGPU constitue un prolongement technique à explorer.

Positionnement dans l'équipe, délégation et demandes d'aide.

- **Binôme D2 avec Mahé et coresponsabilité sur #107** : rôle principal sur l'indexation binaire, les références lexicales et l'apprentissage contrastif (#30, #45, #47, #49), en m'appuyant sur les revues exigeantes de Mahé sur les protocoles de mesure et les tests statistiques ; reprise des corrections demandées sur les supports J3 (#112 / PR #134) et les fiches d'outils (#113 / PR #135).
- **Soutien transverse sur D4 et D3** : accompagnement de Jibril sur l'inférence locale (#31) et l'intégration des passages M2 (#51), appui à l'équipe front sur la consommation des index, et contributions aux livrables communs (#105, #112, #113).
- **Relectures et transparence** : pratique des revues croisées (PR #61, #62, #73, #75, #109, #115 et #124), puis préparations des vérifications de J3 pour #141 (19/19 tests unitaires réussis), #147 (8/9 sous Windows) et

la diapositive 7 de #148, en signalant les anomalies observées au fil de l'eau (cache navigateur, divergence tokeniseur, audits de la session 35).

Arbitrages et respect des délais.

- **Application de la règle de repli du protocole 05 et maintien de #49 ouvert** : déploiement de l'encodeur de base élagué (65,7 Mio) pour l'échéance du 18 octobre faute de mesure officielle complète avant le 16 octobre, puis acceptation le 30 octobre de la priorité donnée au volet B dans le calendrier resserré, tout en conservant le ticket **#49 ouvert** sans prétendre à une validation qui n'a pas eu lieu.
- **Estimations, réactivité et rattrapage avant J3** : tenue des charges sur les tâches estimées et clôturées (#45 et #47 à 3 h 30 pour 4 h estimées), mais retards de réponse fin octobre sur les retours de #112 et #115 et dette sur les fiches d'outils ; ces écarts ont été traités le 10 novembre par la reprise complète des demandes de revue de la PR #134 (préparée pour une fusion en squash) et la correction intégrale des fiches de la PR #135.

4.3 Jibril BENSALEM

Compétences techniques acquises. J'ai progressé dans la compréhension et la mise en œuvre d'une chaîne RAG : exécuter Qwen localement, récupérer les passages pertinents, construire le contexte et contrôler les citations. Le développement d'Agento Light m'a aussi permis de travailler sur la génération de questions synthétiques et la traçabilité des essais. Les relectures m'ont appris à confronter les affirmations aux résultats observés : un test réussi ou une citation existante ne garantit pas la qualité d'une réponse.

Points à approfondir. Je dois encore approfondir l'adaptation des modèles, les contraintes de mémoire GPU et l'évaluation des réponses générées. Je souhaite aussi gagner en autonomie dans la compréhension du code produit avec l'assistance de l'IA.

Positionnement et organisation. J'ai partagé mon travail entre le rôle de Scrum Master, les contributions techniques et les relectures. Un axe de progression concerne la régularité du suivi : consigner les décisions au fil de l'eau, renseigner les charges et mieux anticiper les dépendances entre tâches. Lorsqu'une réunion n'est pas nécessaire, un point écrit permet de conserver une visibilité commune sur l'avancement.

4.4 Vaneck DAGAR

Compétences techniques acquises. Avec Maïmouna, j'ai commencé par le corpus (#27). En le contrôlant, nous avons découvert que le jeu publié sur Hugging Face était mal découpé : le texte des fiches débordait d'une section sur l'autre et les intertitres étaient collés aux paragraphes. Nous avons donc refait le découpage à partir de la source officielle de SocialGouv sur GitHub, qui contient le texte complet de chaque fiche, section par section (#35). J'ai ensuite rédigé et annoté des questions pour l'évaluation (#44), puis je me suis surtout occupé de tout ce que voit l'utilisateur. Pour le volet A, j'ai mis le site en ligne sur GitHub Pages, branché la recherche dans l'interface de chat et repris le parcours et l'accessibilité (#29, #48, #53). J'ai appris à tester une interface autrement qu'en cliquant dessus : Playwright sur ordinateur et sur téléphone, Lighthouse pour le contraste, navigation au clavier. Ces tests m'ont fait trouver des défauts que je n'aurais jamais vus seul. Pour le volet B, j'ai écrit le contrat d'interface de la démonstration, puis l'interface et la couche Python qui la relie à la chaîne RAG (#121, #128). Les relectures sur cette couche m'ont rappelé qu'un code qui marche en usage normal doit aussi être éprouvé dans les cas limites.

Lacunes et points à approfondir. Je connais bien la partie applicative du volet B, beaucoup moins la partie modèle. Je n'ai ni Ollama ni Qwen sur ma machine, donc je n'ai jamais lancé la génération moi-même. J'ai compris la chaîne RAG en la relisant avec l'assistant, et l'adaptation comme la mesure ont été faites par d'autres. C'est le point que je dois le plus travailler. Je dois aussi être plus exigeant avec ce que produit

l'assistant d'IA : quelques erreurs de mon travail ont été trouvées par Jibril ou Mahé en relecture, pas par moi.

Positionnement dans l'équipe et délais. J'ai porté le front des deux volets et la démonstration avec Maïmouna, et j'ai relu une quinzaine de PR des autres, parfois en les refaisant tourner sous Windows. Pour tout ce qui demandait le modèle, je dépendais des autres : c'est Maïmouna qui a fait le premier essai réel de la démo, et elle tournera sur la machine de Mahé. J'ai tenu les échéances de la démonstration et de la relecture des données d'adaptation, mais j'ai laissé glisser ce qui était moins technique : le scénario, cette section et ma fiche d'outil sont arrivés en retard.

4.5 Maïmouna SIGNATE

Compétences techniques acquises. Au volet A, avec Vaneck, j'ai travaillé sur la préparation du corpus (#27) : téléchargement d'une version figée, règles de filtrage, contrôle manuel d'un échantillon. J'ai aussi travaillé sur la mise en ligne du site (#29) et l'annotation de questions pour l'évaluation (#44, Q036 à Q070). Au volet B, j'ai appris à lire une chaîne RAG de bout en bout : la récupération des passages par E5, la génération par Qwen et le contrôle des citations. J'ai reproduit cette chaîne sur ma propre machine (#51). Mahé l'a retenue comme la reproduction indépendante du ticket, avec ses écarts déclarés : version d'Ollama et digest différents, calcul sans carte graphique. J'ai découvert à cette occasion comment faire tourner un modèle d'IA comme Qwen directement sur mon ordinateur, avec le logiciel Ollama, et vérifier qu'il s'agit bien du même modèle que celui de Jibril. J'ai surtout appris à juger une réponse en la comparant aux passages : une réponse citée peut être incomplète (Q036), et une abstention peut être injustifiée alors que le bon passage a été trouvé (Q001). Enfin, je me suis familiarisée avec Git et GitHub : branches, commits, résolution de conflits, relectures de pull requests.

Lacunes et points à approfondir. Au début du projet, j'avais du mal à voir comment les différentes parties s'articulaient, du corpus jusqu'à la démonstration. Pour y remédier, j'ai refait moi-même, dans des notebooks, la préparation du corpus et la recherche du site. La lecture du code Python et JavaScript reste un point à approfondir. J'ai aussi appris à ne pas prendre pour acquis ce que me dit l'assistant d'IA : plusieurs de ses affirmations se sont révélées fausses, et je ne les ai corrigées qu'en lui demandant de vérifier. Ces erreurs sont consignées dans le journal. Je souhaite prolonger ce travail dans mon entreprise, où presque tous les membres de l'équipe refont régulièrement les mêmes recherches : j'envisage d'y mettre en place une recherche par le sens sur nos documents, sur le modèle du volet A.

Positionnement dans l'équipe et délais. J'ai travaillé en binôme avec Vaneck sur le volet A (le corpus, la mise en ligne du site et l'évaluation), puis sur la vérification de la chaîne RAG et la démonstration du volet B. Sur les délais, mon journal a été rattrapé avec retard, et une de mes sessions est déclarée comme consignée a posteriori. Je retiens qu'il faut consigner le travail le jour même, tant que les difficultés sont encore en mémoire.

5 Cinq outils novateurs

Présélection proposée, à valider au Weekly 8. La méthode de suivi prévoit de choisir les cinq outils au Weekly 8 (4 novembre). Les cinq ci-dessous sont proposés parce qu'ils répondent aux critères retenus par l'équipe :

- un usage réel et répété, avec des preuves dans le dépôt ;
- au moins une limite observée ;
- un retour que la documentation officielle ne donne pas.

Chaque fiche complète figure dans `docs/suivi/outils/`. Les autres candidats sont Ollama, Sentence Transformers, GitHub Actions et Pages, Vite et `uv`.

5.1 Transformers.js

- **Usage.** Exécution de l'encodeur dans le navigateur, pour le site et pour les pages de contrôle (PR #40, #62, #67).
- **Apport.** Une recherche sémantique sans serveur, en une vingtaine de millisecondes par question.
- **Limite.** Le poids du modèle au premier chargement, que l'élagage a réduit de 42 %.
- **Ce que la documentation ne dit pas.** La précision par défaut change selon le matériel, et l'extracteur ne fait ni moyenne ni normalisation par défaut : sans options explicites, il renvoie un vecteur par token.
- **Ce que la documentation ne dit pas non plus.** À son import, la bibliothèque fait télécharger son moteur d'exécution depuis jsDelivr.

5.2 ONNX Runtime, en Python et sur le Web

- **Usage.** Même fichier de modèle exécuté en Python pour construire l'index, et dans le navigateur pour le site (notebook 02, PR #40 et #81).
- **Apport.** Un format unique entre la préparation et le service.
- **Limite.** Un modèle quantifié ne se comporte pas de la même façon d'un environnement d'exécution à l'autre : critère de parité q8 échoué, puis diagnostiqué.
- **Ce que la documentation ne dit pas.** L'ampleur de l'écart entre le q8 de Python et celui du navigateur : 96,5 % contre 91,8 % de premier résultat identique au calcul exact.

5.3 Playwright

- **Usage.** Mesures de faisabilité du J2, parcours complets du site, contrôles d'accessibilité au clavier, essais avec réseau bloqué, sous Chromium, Firefox et WebKit.
- **Apport.** Rejouer en quelques minutes le parcours complet du site, erreurs réseau comprises.
- **Limite.** Écouter les requêtes au niveau de la page ne montre pas celles du moteur d'exécution ; il faut les écouter au niveau du contexte.
- **Limite.** Sous WebKit, l'interception du réseau capte aussi les URL `blob:` ; les bloquer par erreur fait échouer le site.
- **Limite.** Le comportement de WebKit dépend du système : le défaut de tabulation se reproduit sous macOS, pas sous Linux.
- **Ce que la documentation ne dit pas.** `playwright-core` ne télécharge aucun navigateur : il pilote ceux qui sont déjà installés.

5.4 GitHub CLI

- **Usage.** Toutes les opérations GitHub courantes : PR, revues, tickets, réglages et lectures de l'API, y compris pour les audits de ce rapport.
- **Apport.** Des opérations reproductibles et scriptables, y compris les réglages absents de l'interface en ligne de commande, par `gh api`.
- **Limite.** `gh api` bascule silencieusement de GET en POST dès qu'un champ `-f` est fourni.

- **Ce que la documentation ne dit pas clairement.** Les droits réels exigés par certains réglages : l'environnement `github-pages` est réservé aux administrateurs, et la lecture du board (Projects v2) exige un droit absent du jeton par défaut.

5.5 Assistants de développement par IA

- **Usage.** Claude Code, Google Antigravity avec Gemini, ChatGPT et Codex, sur l'ensemble du projet : 37 sessions consignées au 18 octobre.
- **Apport.** Une capacité de production et de mesure qui a rendu possible le périmètre du projet.
- **Critique argumentée.** L'assistant produit des affirmations plausibles et fausses, y compris dans des documents publiés. Le journal recense 68 erreurs ou pièges détectés par la vérification au 18 octobre. Sur les 19 erreurs des sessions de Mahé du 11 au 18 octobre, 11 figuraient déjà dans une PR, une revue ou un document publiés. Deux exemples : une revue affirmant qu'aucune requête ne partait vers jsDelivr, et une description de PR affirmant que le focus ne sortait jamais du menu. Ces erreurs ont été trouvées par une mesure, un essai, une revue ou la lecture d'une source primaire, et 4 d'entre elles par un relecteur de l'équipe, non par l'assistant. L'assistant ne dispense donc ni de la vérification, ni de la compréhension du code : le sujet rappelle que tout membre peut être interrogé sur n'importe quelle portion du code produit.
- **Ce que la documentation ne dit pas.** La vérification doit être conçue pour échouer quand l'affirmation est fausse. Les essais qui ont laissé passer les erreurs ci-dessus étaient trop permissifs : requêtes écoutées au mauvais niveau, focus sur le document jugé acceptable.

6 Ce qui reste avant la V1

Élément	Responsables	Échéance
Adaptation du modèle du volet B, exigée au jalon J3 : aucun ticket ne la porte encore	Mahé et Jibril (domaine D5), à confirmer	J3
Supports de présentation, exigés au jalon J3 « même incomplets »	toute l'équipe	J3
Mesures du volet B avant et après adaptation (#52), puis comparaison finale des deux volets	Mahé, Jibril	avant la V1
Axes de progression individuels (section 4)	chaque membre	avant la V1
Validation des cinq outils, fiches finalisées	toute l'équipe	Weekly 8, puis avant la V1
Capture du board	Jibril	avant la V1

Annexe. Chiffres et sources

Chiffre	Source dans le dépôt
261 fiches, 4 240 passages, instantané du 11/09/2026	`front/public/index/`, `docs/etudes/decoupage/01_corpus_decoupage.md`

Chiffre	Source dans le dépôt
q8 de 112,8 à 65,7 Mio, 822 vecteurs identiques bit à bit	`scripts/allegement/README.md`
table des mots : 81,6 % des paramètres, 250 037 lignes	`docs/etudes/indexation/01_encodeur_e5_small.tex`
91,8 % (navigateur) contre 96,5 % (Python) de premier résultat identique	`docs/etudes/indexation/02_indexation.md`
Recall@5, IC, non-infériorité, bonne fiche 83,6 %, AUC, seuil	`docs/etudes/evaluation/03_evaluation.md`
ajustement : 109 paires, 2 époques, 185,5 s	`docs/etudes/adaptation/01_ajustement_encodeur_contrastif.md`
volet B : 4,36 Gio, 37,7 s, 19,1 s, 47 à 67 tokens/s, VRAM	`docs/etudes/inference_locale_qwen.md`
chaîne RAG, Q036 et Q003	PR #85 (brouillon), `docs/etudes/rag_51.md` sur sa branche
61,3 Mio, 20,1 s, 21 ms (19 à 24), 46 ms	mesure du site en ligne `7e2ce07`, le 19/10/2026, Chromium, profil neuf
rôles, domaines, réunions, charges	`docs/suivi/SUIVI.md`, `docs/reunions/README.md`, tickets #2, #6, #9, #10, #11, #26
PR, revues, commits	API GitHub et `git log` de `dev`, relevés le 19/10/2026
erreurs détectées	`docs/journal/JOURNAL_USAGE_IA.md`, section 4