# Démonstration

1. **Volet A, en ligne** : datatigersnlp.github.io/data_tigers_nlp
   - « Est-ce légal de travailler 10 heures dans la même journée ? »
   - « Un fonctionnaire peut-il refuser une mutation dans une autre ville ? »
2. **Volet B, sur le Mac, modèle adapté**
   - « Quelle est la durée maximale de la période d'essai d'un cadre en CDI ? »
   - « Comment est calculée la pension de retraite d'un fonctionnaire ? »
3. **La même question au témoin T, puis au modèle adapté** (question retenue à l'essai)

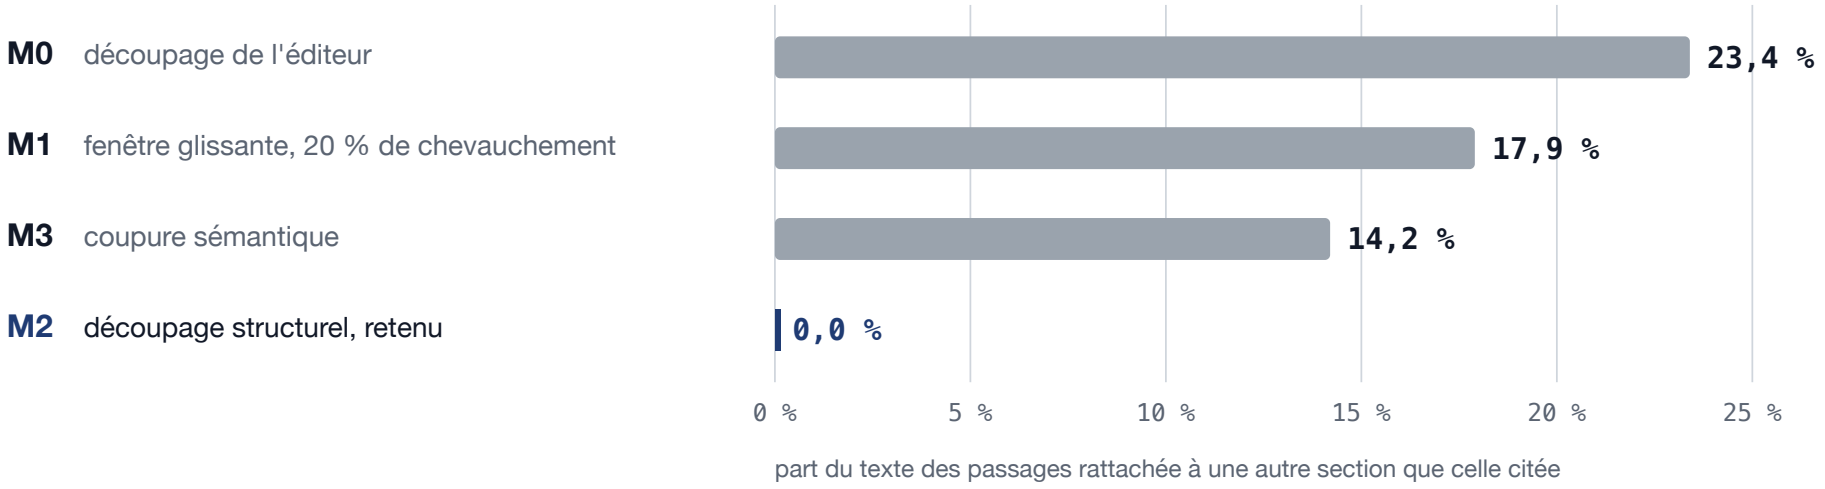
# Une démarche : écrire la règle avant de mesurer




- **Organisation** : un ticket par tâche, les jalons du sujet, et chaque modification passe par une **pull request relue** par un autre membre.
- **Traçabilité** : un journal d'usage de l'IA, **63 sessions** consignées au 13/11.
- **Principe** : pour chaque mesure, un **protocole** fixe d'avance la question, la métrique, le test statistique et la règle de décision ; chaque état n'est mesuré **qu'une fois** sur le jeu de test.

**Pull request** : demande d'intégrer une modification au code commun, relue et approuvée avant d'être acceptée. **Jeu de test** : questions mises de côté, jamais utilisées pour régler le système, pour une mesure non biaisée.

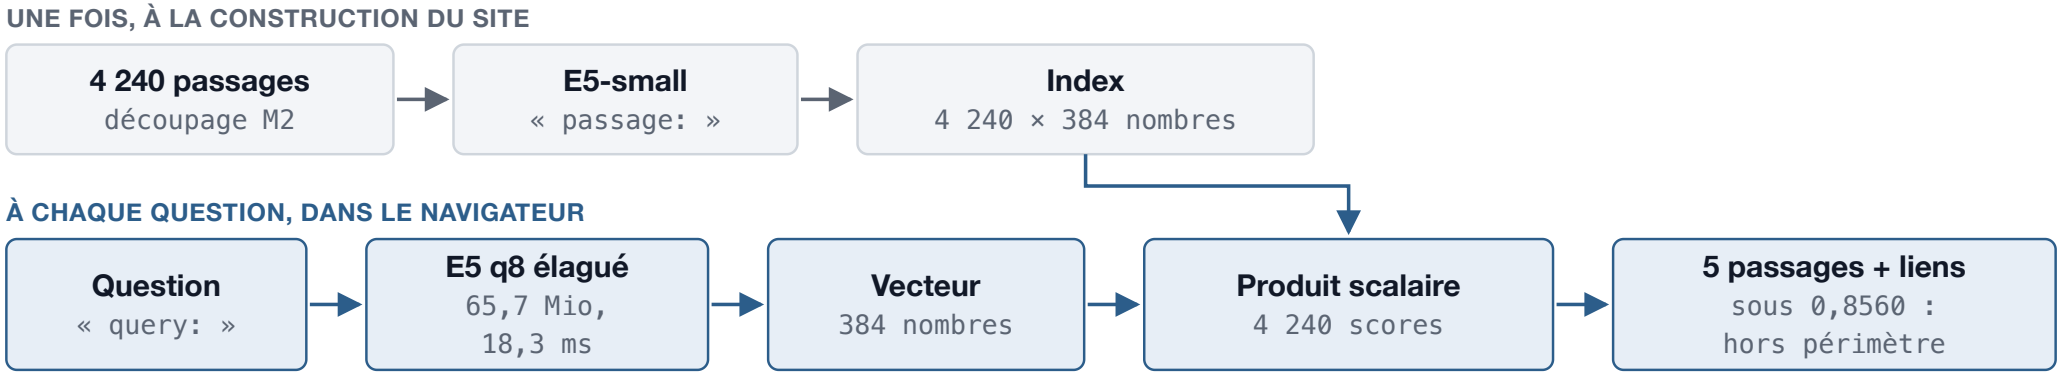
# Un découpage qui respecte la structure des fiches




- Source : instantané **SocialGouv** du 11/09/2026, 261 fiches, extraites depuis le **HTML** : le texte brut déborde d'une section sur la suivante.
- **Découpage M2** : coupure aux titres de section, listes et tableaux gardés entiers, au plus 512 tokens : **4 240 passages**.

**Découpage** : couper les fiches en passages que le moteur compare à une question. **Token** : morceau de mot ; 512 tokens est la limite de lecture de l'encodeur. M0, M1 et M3 ont été calibrés à la même taille moyenne que M2, pour comparer les méthodes et non les tailles.

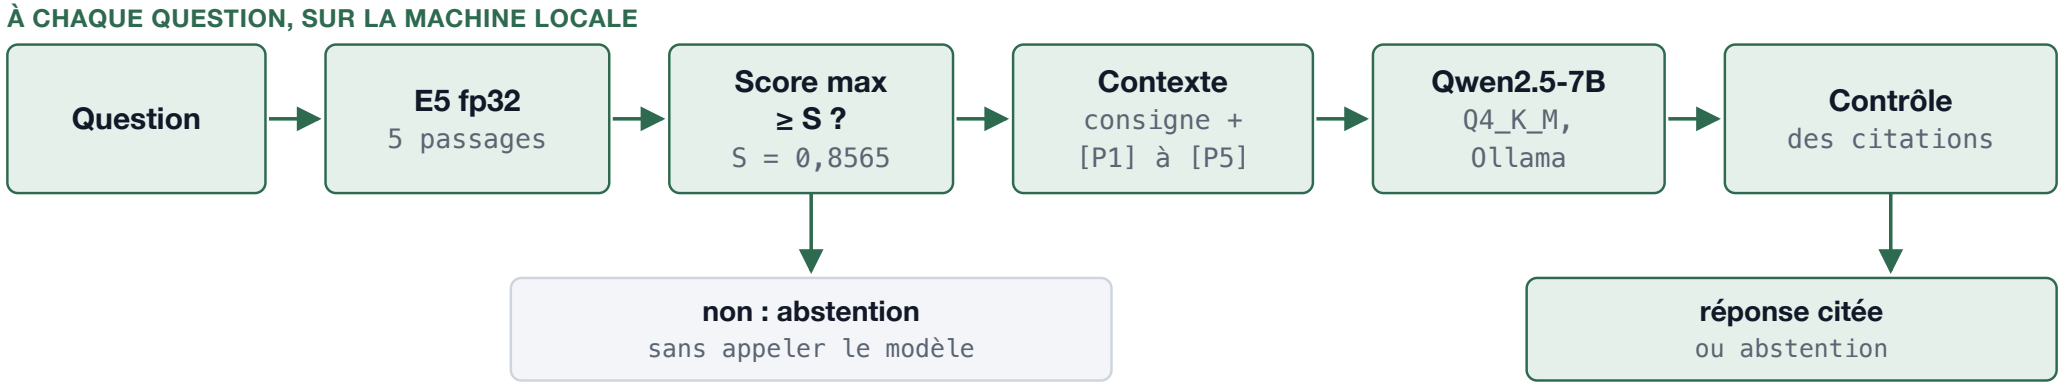
# Volet A : tout se calcule dans le navigateur




- **Allègement** : de 112,8 à **65,7 Mio** en retirant le vocabulaire des alphabets non latins, sans changer un seul résultat (822 requêtes vérifiées).
- **Mesure du 13/10**, 73 questions : le bon passage est dans les 5 premiers pour **43,8 %**, contre 42,5 % pour BM25 ; la bonne fiche pour **83,6 %**.
- **Limite** : le seuil « hors périmètre » ne rejette que **9 questions hors corpus sur 24**.

**Encodeur E5** : modèle qui résume un texte en un **vecteur** de 384 nombres ; deux textes de sens proche ont des vecteurs proches. **Produit scalaire** : mesure de proximité de deux vecteurs (ici égal au cosinus). **Recall@5** : part des questions dont un passage pertinent est dans les 5 premiers résultats.

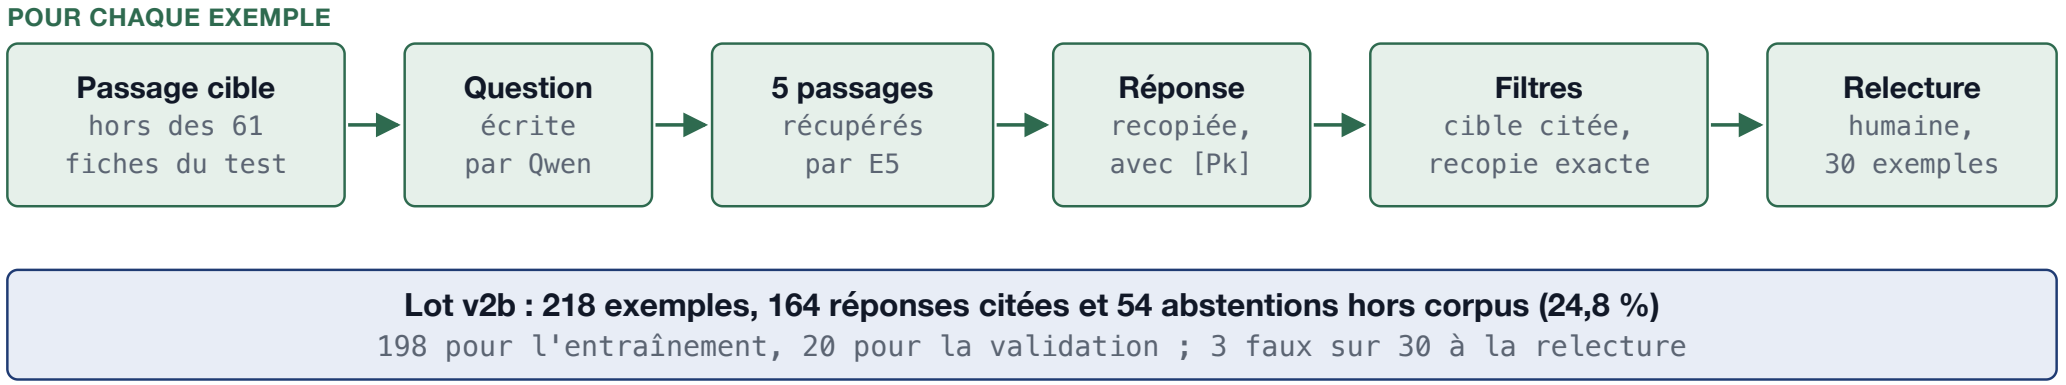
# Volet B : une chaîne mesurée, un défaut identifié




- **Protocole 06**, gelé le 04/11 : 97 questions de test (73 couvertes, 24 hors corpus), 5 configurations, critère principal sur **B2**.
- **Mesure avant** (09/11) : B2 s'abstient à tort sur **45 des 72** questions couvertes (Q088 exclue, erreur technique), dont **17 sur 33** alors que le bon passage était fourni. C'est la cible de l'adaptation.

**RAG** (génération augmentée par récupération) : on fournit au modèle des passages trouvés par recherche, et il doit répondre à partir d'eux. **B2** : la chaîne complète, avec consigne d'abstention et seuil S. **Seuil S** : si même le meilleur passage est trop éloigné de la question (score sous 0,8565), on s'abstient sans appeler le modèle.

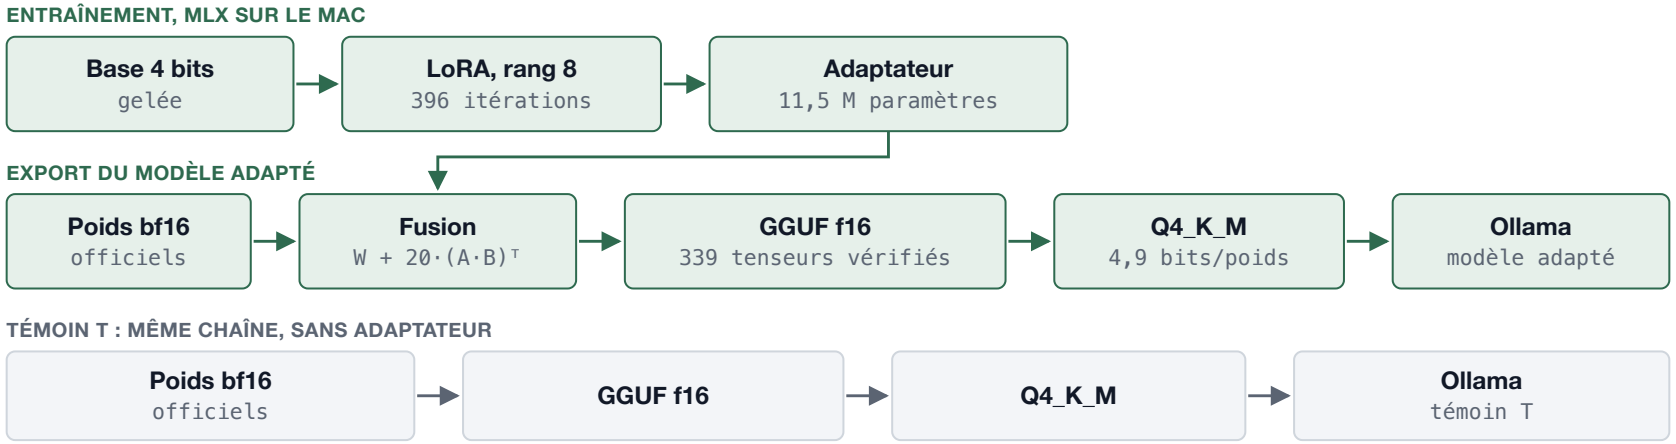
# Des données d'entraînement qui apprennent à citer




- **Façon RAFT** : chaque exemple reproduit l'usage réel, avec de vrais passages récupérés ; la réponse **recopie** des phrases du passage, suivies de leur référence.
- **Séparation** : aucune des 61 fiches du test n'est utilisée, contrôlé par script. 24,8 % d'abstentions, la part du test.
- **Relecture humaine** : lot v1 **refusé** (8 faux sur 30 : le modèle prêtait aux passages ce qu'ils ne disent pas), lot v2b **accepté** (3 sur 30, règle des 10 %).

**RAFT** (Retrieval-Augmented Fine-Tuning) : entraîner le modèle dans les conditions du RAG, pour qu'il apprenne à se servir des passages. **Validation** : 20 exemples gardés hors de l'entraînement pour suivre l'apprentissage. Les réponses sont écrites par Qwen lui-même, puis filtrées et relues.

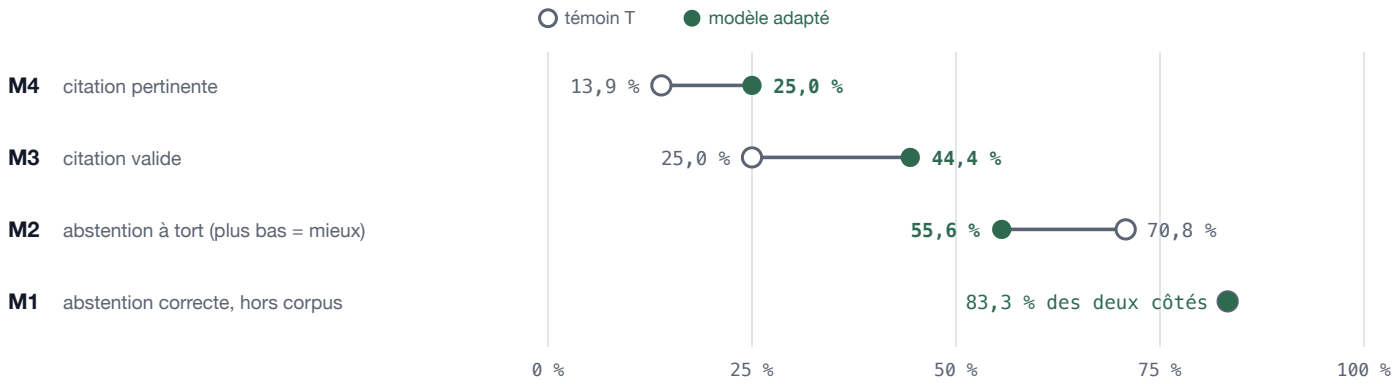
# Entraîner sur le Mac, servir sous Ollama




- **LoRA** : on gèle les 7,6 milliards de poids et on n'apprend qu'un petit correctif : **11,5 millions** de paramètres (0,15 %), 2 époques.
- **Ollama refuse les correctifs LoRA** : on le fusionne dans les poids d'origine, puis on compresse en **Q4_K_M**.
- **Témoin T** : le modèle d'origine passé par exactement la même chaîne. Comparer à T isole l'effet de l'adaptation.

**LoRA** : le correctif est le produit de deux petites matrices A et B (rang 8), seules apprises. **Quantification** : stocker chaque poids sur moins de bits (4,9 en moyenne au lieu de 16) pour tenir en mémoire. **bf16** : format sur 16 bits des poids publiés. **Époque** : un passage complet sur les données.

# L'adaptation améliore ce qu'elle visait, pas l'exactitude




- **M4**, critère principal : de 13,9 % à **25,0 %**, soit **+11,1 points**, IC à 97,5 % [+2,1 ; +23,8] : **amélioration démontrée** (8 questions gagnées, aucune perdue).
- **M1** : 83,3 % des deux côtés ; intervalle [–20,5 ; +20,5] : ni gain démontré, ni perte exclue.
- **Exactitude**, jugée à l'aveugle : réponses mieux **appuyées** sur leurs passages, **pas plus exactes**, souvent **incomplètes** (annexe 5).

**M4** : la réponse cite au moins un passage pertinent. **M1** : abstention correcte sur une question hors corpus. **IC à 97,5 %** : plage plausible de l'écart réel ; 97,5 % et non 95 % car il y a deux critères principaux (correction de Bonferroni).

# Deux volets, deux compromis

| | Volet A, recherche | Volet B, assistant |
|---|---|---|
| **Coût** | aucun serveur ; 61,3 Mio transférés à la première visite (fichiers compressés), puis en cache | aucun service payant, mais une machine dédiée ; modèle de 4,36 Gio |
| **Latence** | 21 ms par recherche (médiane) | 4,8 s par réponse générée (médiane, Mac M4 Pro) |
| **Qualité** | bon passage dans les 5 premiers : 43,8 % | réponse citant un passage pertinent : 25,0 % |
| **Contrôle** | tout est figé et vérifiable par empreinte | poids figés, mais comportement appris sur des données inconnues |
| **Explicabilité** | des passages réels, rien n'est généré | la réponse cite ses passages ; une citation ne prouve pas l'exactitude |
| **Dépendance** | aucune à l'exécution | Ollama et poids ouverts de Qwen (Apache 2.0) ; aucune API distante |

Les deux chiffres de qualité ne mesurent pas la même chose : le volet A trouve des passages, le volet B rédige une réponse. **Empreinte** : code calculé sur un fichier (SHA-256) ; s'il change d'un octet, l'empreinte change.

# Arbitrages, limites et suite

## Arbitrages assumés

- Encodeur réentraîné (#49) **non servi** : gain seulement exploratoire ; règle de repli écrite d'avance.
- Exemples « passage retiré » **retirés** : ils apprenaient à s'abstenir là où une réponse partielle existait.
- Mesures finales sur **une seule machine**, le Mac : l'entraînement ne tient pas dans les 8 Gio de la carte graphique du PC Legion.

## Limites

- B2 s'abstient encore à tort sur **55,6 %** des questions couvertes.
- Réponses fidèles aux passages mais **souvent incomplètes** : l'exactitude ne progresse pas.
- 24 questions hors corpus, c'est peu.

## Suite

- Brancher la **récupération v2** : un passage pertinent dans le contexte pour **72,6 %** des questions, contre 45,2 % (démontré).
- Entraîner aussi sur des réponses qui **combinent plusieurs passages**.
- Mieux régler le seuil, agrandir le jeu de test.

**Récupération v2** : recherche hybride (sens et mots-clés, fusionnés par leurs rangs), puis reclassement des 20 meilleurs candidats par un second modèle, plus précis, qui lit la question et chaque passage ensemble.

# Trois choses à retenir

1. Un même corpus, **bien découpé**, sert deux usages : **chercher** (volet A) et **répondre en citant** (volet B).
2. Une adaptation **ciblée sur le défaut mesuré**, et comparée à un témoin, fait gagner **11 points** de réponses citant le bon passage, sans gain d'exactitude à ce stade.
3. Des protocoles **figés avant chaque mesure** : nos chiffres ne dépendent pas de choix faits après coup.

Site : datatigersnlp.github.io/data_tigers_nlp · dépôt : github.com/datatigersNLP/data_tigers_nlp

# Annexe 1. L'encodeur E5 et l'allègement du site

- **E5-small** : un encodeur de type BERT, 12 couches, largeur 384, **117,7 M** de paramètres, dont **81,6 %** dans la table de vocabulaire (250 037 entrées).
- Entraînement contrastif : rapprocher une question de son passage, éloigner les autres passages du lot (perte InfoNCE). Préfixes obligatoires « query: » et « passage: ».
- **Élagage sans perte** : on garde les pièces de vocabulaire sans lettre, ou en lettres latines ou grecques (121 271 pièces). Pour un texte français, le découpage en pièces est inchangé, donc les vecteurs aussi : **822 requêtes sur 822** identiques bit à bit.
- **q8** : poids sur 8 bits ; 112,8 puis **65,7 Mio** (–41,8 %), sous la limite de 100 Mio par fichier de GitHub ; 91,8 % de premiers résultats identiques au calcul exact dans le navigateur.

**Tokeniseur** : outil qui découpe un texte en pièces de vocabulaire ; celui d'E5 en compte 250 002, la plupart pour d'autres alphabets. **Bit à bit** : nombres strictement identiques, sans aucun arrondi différent.

# Annexe 2. Les seuils d'abstention

- **Volet A, 0,8560** : 5e centile des scores maximaux de **479 variantes** de requêtes du jeu CDTN, externe à notre jeu de test ; fixé le 10/10, **avant** la mesure. Par construction, 95 % de ces questions dépassent le seuil.
- **Volet B, S = 0,8565** : même méthode, calcul en fp32 côté Python ; intervalle à 95 % de **0,8464 à 0,8653** par rééchantillonnage des 103 requêtes.
- **Ce que donne le seuil du volet A** : AUC de **0,841** [0,747 ; 0,921] ; 9 questions hors corpus rejetées sur 24, 72 questions couvertes gardées sur 73.

**Score maximal** : similarité entre la question et le passage le plus proche. **5e centile** : valeur sous laquelle tombent 5 % des scores. **AUC** : probabilité qu'une question couverte obtienne un score plus élevé qu'une question hors corpus (0,5 = hasard, 1 = parfait). **CDTN** : jeu de requêtes du Code du travail numérique, indépendant de notre jeu de test.

# Annexe 3. Les tests statistiques

- **Données appariées** : les deux systèmes répondent aux mêmes questions ; seules les questions **discordantes** (l'un réussit, l'autre échoue) renseignent sur l'écart.
- **McNemar exact** : test binomial sur les discordantes. Pour M4 : 8 gagnées, 0 perdue, $p = 2 \times 0{,}5^8 =$ **0,0078**.
- **Non-infériorité (score de Tango)** : on teste « le site est moins bon de 15 points ou plus » ; le rejet ($z = 2{,}45$, $p = 0{,}007$) démontre la non-infériorité.
- **Grappes (Obuchowski, effet de plan)** : 73 questions viennent de 61 fiches ; des questions d'une même fiche ne sont pas indépendantes, donc on élargit les intervalles (effet de plan de 1,27 pour M4).
- **Bonferroni** : deux critères principaux, chacun au niveau 97,5 %, pour garder 5 % d'erreur au total. **Wilson** : intervalle d'une proportion simple (3 sur 30 : 3,5 à 25,6 %).

**p** : probabilité d'observer un écart au moins aussi grand si les deux systèmes étaient équivalents ; on conclut s'il passe sous le risque fixé d'avance (2,5 % ici). **Intervalle de confiance** : plage de valeurs compatibles avec les données pour l'écart réel.

# Annexe 4. Le protocole de mesure du volet B

| État | Configuration |
|---|---|
| B0 | modèle seul, sans passage |
| B1 | RAG, sans consigne d'abstention |
| B2 | RAG complet et seuil S |
| R+ | répond toujours en citant [P1] |
| R– | s'abstient toujours |

| Métrique | Population | Définition |
|---|---|---|
| M1 | 24 hors corpus | abstention correcte |
| M5 | 24 hors corpus | réponse affirmative (erreur) |
| M2 | 72 couvertes | abstention à tort |
| M3 | 72 couvertes | citation valide |
| M4 | 72 couvertes | citation pertinente (D4) |

- **Gel** le 04/11 ; **verrou** de 10 empreintes (protocole, scripts, jeu, index, seuil), contrôlé à chaque exécution ; une seule exécution par état.
- Un état est invalide au-delà de 5 % d'erreurs techniques ; au 11/11, au plus 2,1 % (2 sur 97). Q088 est en erreur partout : 72 couvertes mesurées sur 73.

**Règle D4** : un passage est pertinent s'il partage avec l'extrait annoté un fragment continu couvrant au moins la moitié de l'extrait. **R+ et R–** : références qui montrent qu'un taux élevé de citations valides ne prouve rien seul.

# Annexe 5. Le jugement à l'aveugle de l'exactitude

| Mesure (20 réponses citées de B2 par modèle) | Témoin T | Modèle adapté |
|---|---|---|
| Entièrement exacte, selon Maïmouna | 12/20 (60 %) | 7/20 (35 %) |
| Entièrement exacte, selon Vaneck | 8/20 (40 %) | 5/20 (25 %) |
| Entièrement appuyée sur ses passages, selon Maïmouna | 9/20 (45 %) | 19/20 (95 %) |
| Entièrement appuyée sur ses passages, selon Vaneck | 12/20 (60 %) | 19/20 (95 %) |
| Score d'exactitude moyen des deux juges (0 à 2) | 1,4 | 1,2 |

- **Échantillon** : réponses tirées au hasard (graine 20261018), mélangées, anonymisées ; juges désignés le 25/10, qui n'ont écrit ni la chaîne ni l'adaptation. Résultats descriptifs.
- **Sélection** : le modèle adapté répond à 14 questions de plus. Sur les questions auxquelles les deux répondent, score 1,4 pour T et 1,3 pour le modèle adapté ; là où T s'abstenait, 0,9.
- **Accord des juges** : kappa 0,27 sur l'exactitude ; critère « conditions et exceptions » inexploitable (« sans objet » choisi 23 fois contre 1).

**Kappa de Cohen** : accord entre deux juges, corrigé de l'accord dû au hasard (0 : hasard, 1 : accord parfait). **Score d'exactitude** : non 0, partiel 1, oui 2, moyenne des deux juges. **À l'aveugle** : les juges ignorent quel modèle a produit chaque réponse.

# Annexe 6. Les données d'adaptation, lot v2b

- **218 exemples** : 164 réponses citées et 54 abstentions hors corpus (24,8 %) ; 198 d'entraînement, 20 de validation.
- **154 réponses écartées par les filtres** : 103 non recopiées, 33 sans citer le passage cible, 13 abstentions du modèle, 5 autres (sortie invalide, coupée, texte après la dernière référence).
- 50 questions déjà relues pour le lot v1 **exclues** : elles avaient servi à choisir le correctif.
- **Relecture** : 30 exemples tirés par strates, deux relecteurs indépendants, grille au plus sévère ; règle écrite d'avance : 10 % de faux au plus. Résultat : 3 sur 30. Les 2 048 arbitrages possibles entre les deux relectures donnaient tous de 0 à 3 faux.

**Tirage par strates** : on tire séparément dans chaque type d'exemple, pour que chacun soit représenté. **Grille au plus sévère** : pour chaque case, on garde le verdict le plus défavorable des deux relecteurs.

# Annexe 7. La quantification et l'export

- **MLX 4 bits** (entraînement) : groupes de 64 poids, une échelle et un décalage par groupe : 4,5 bits par poids.
- **Q4_K_M** (llama.cpp, service) : super-blocs de 256 poids en 8 blocs de 32 ; 4,5 bits en Q4_K, couches sensibles en Q6_K : **4,91 bits** par poids en moyenne, 4,36 Gio.
- **Pourquoi fusionner en bf16** : simulée, l'adaptation survit à la recompression à **97,5 à 99,9 %** par la voie bf16, contre 47 à 62 % par la base 4 bits déquantifiée.
- **Vérifications** : 339 tenseurs du fichier GGUF égaux à leur source ; contrôle négatif sur les 112 matrices modifiées ; T diffère du fichier officiel de Qwen par le choix des couches en Q6_K.

**Quantification** : w ≈ échelle × q + décalage, avec q entier sur peu de bits. **GGUF** : format de fichier de modèle de llama.cpp, lu par Ollama. **Contrôle négatif** : vérifier que le test détecte bien une différence quand il y en a une.

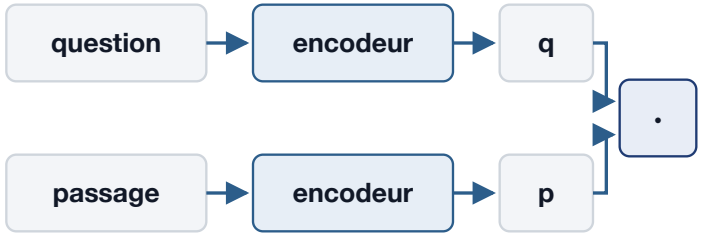
# Annexe 8. La récupération v2

- **Fusion RRF** d'E5 et de BM25 : chaque passage reçoit la somme de 1 / (60 + rang) sur les deux classements.
- **Reclassement** des 20 meilleurs candidats par **bge-reranker-v2-m3** (568 M de paramètres, sur CPU, environ 2 s par question), puis 10 passages donnés au modèle.
- **Réglée** sur le jeu CDTN (112 configurations comparées), puis **confirmée une seule fois** sur le test, protocole 07 figé avant : 45,2 % → **72,6 %** des questions ont un passage pertinent dans le contexte, **+27,4 points** [+16,3 ; +38,5], $p = 5{,}1 \times 10^{-5}$.
- Récupération seule : la génération n'a pas encore été mesurée avec elle.

**BM25** : score par mots-clés, sans apprentissage (rareté du mot, fréquence, longueur du passage). **RRF** : fusion qui ne compare que des rangs, pas des scores d'échelles différentes. **Reclasseur** : modèle qui lit la question et un passage ensemble, plus précis mais plus lent.

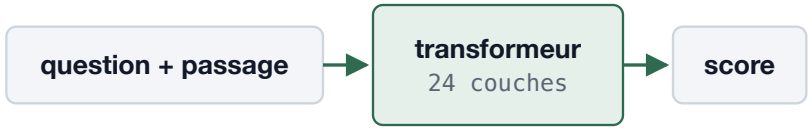
# Annexe 9. Les modèles du projet

**BI-ENCODEUR (E5)**



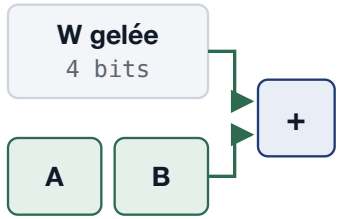

p est calculé une fois (index) ;
score = cosinus(q, p)

**CROSS-ENCODEUR (BGE)**




les deux textes sont lus ensemble :
plus précis, un calcul par paire

**LORA (QWEN)**




rang 8, facteur 20 ;
seuls A et B s'entraînent

| Modèle | Rôle | Taille | Licence |
|---|---|---|---|
| multilingual-e5-small | encodeur, volets A et B | 117,7 M paramètres, 12 couches | MIT |
| bge-reranker-v2-m3 | reclasseur, récupération v2 | 568 M paramètres, 24 couches | Apache 2.0 |
| Qwen2.5-7B-Instruct | modèle de langage, volet B | 7,6 Md paramètres, 28 couches | Apache 2.0 |

**Bi-encodeur** : question et passage encodés séparément, comparés par cosinus ; rapide car les passages sont encodés une fois. **Cross-encodeur** : les deux textes lus ensemble ; plus précis, un calcul par paire.

# Annexe 10. Organisation et outils de travail

- **GitHub** : branches par ticket, pull requests vers `dev`, une approbation exigée ; `dev` et `main` protégées. Jalons J1 à J4, réunions hebdomadaires, classeur de suivi.
- **Journal d'usage de l'IA** : 63 sessions consignées au 13/11, avec les erreurs détectées et leur correction.
- **Assistants utilisés** : Claude Code, Google Antigravity (Gemini), ChatGPT et Codex. Leurs affirmations sont vérifiées dans le dépôt ; celles qui étaient fausses, y compris déjà publiées, sont consignées avec leur correction.
- **Cinq outils novateurs** (bonus) : Transformers.js, ONNX Runtime, Playwright, GitHub CLI, assistants de développement par IA.

**Branche protégée** : on ne peut y intégrer une modification qu'après relecture et approbation. Chaque fiche d'outil (docs/suivi/outils/) décrit l'usage réel, l'apport, les limites et ce que la documentation ne dit pas.

# Annexe 11. Ce que les cinq outils nous ont appris

| Outil | Apport | Limite observée |
|---|---|---|
| Transformers.js | recherche sans serveur, une vingtaine de ms | sans options explicites, l'extracteur renvoie un vecteur par token |
| ONNX Runtime | un seul fichier de modèle, Python et Web | le même q8 calcule autrement dans le navigateur : premier résultat identique au calcul exact pour 91,8 % des requêtes, contre 96,5 % en Python |
| Playwright | parcours complets du site sous trois navigateurs | sous WebKit, l'interception capte aussi les URL blob: |
| GitHub CLI | opérations reproductibles et scriptables | `gh api` passe de GET à POST dès qu'un champ `-f` est fourni |
| Assistants IA | capacité de production et de mesure | affirmations plausibles mais fausses, détectées par vérification |

Le sujet valorise les conditions d'échec et ce que la documentation omet : chaque limite ci-dessus a été rencontrée et consignée dans les fiches d'outils.

# Annexe 12. Les machines et la mémoire

- **PC Legion** (portable), GPU RTX 5070 Laptop, 8 Gio : l'inférence de Qwen en Q4_K_M (4,36 Gio) y tient ; l'entraînement LoRA non (9,17 Gio demandés pour 7,96 Gio disponibles, 274 s par pas).
- **Mac M4 Pro**, 24 Gio de mémoire unifiée : entraînement LoRA avec un pic de 7,6 Gio ; Qwen sous Ollama génère environ 46 tokens par seconde.
- **Amendement M1** (10/11) : toutes les mesures finales, témoin T et après adaptation, sur le Mac, pour éviter tout écart dû à la machine.

**Mémoire unifiée** : le processeur et le GPU du Mac partagent la même mémoire, d'où la place pour l'entraînement. **Pas** : une mise à jour des paramètres. **Token par seconde** : vitesse de génération du texte.

# Annexe 13. Glossaire

**Abstention** : réponse fixe « Je ne peux pas répondre… » quand les passages ne suffisent pas.

**AUC** : probabilité qu'un cas positif ait un score plus élevé qu'un cas négatif.

**Aveugle (jugement à l')** : les juges ignorent quel modèle a produit chaque réponse.

**bf16** : nombres sur 16 bits, format des poids publiés de Qwen.

**BM25** : recherche par mots-clés, sans apprentissage.

**Cache KV** : mémoire des calculs déjà faits sur le contexte, pour générer plus vite.

**Citation pertinente** : la référence citée renvoie à un passage pertinent (règle D4).

**Découpage** : coupure des fiches en passages comparables à une question.

**E5** : encodeur qui transforme un texte en vecteur de 384 nombres.

**Embedding, vecteur** : liste de nombres qui résume le sens d'un texte.

**GGUF** : format de fichier de modèle lu par Ollama.

**Intervalle de confiance** : plage plausible de la valeur réelle.

**LoRA** : adaptation par un petit correctif appris, le modèle restant gelé.

**McNemar** : test pour deux systèmes évalués sur les mêmes questions.

**Non-infériorité** : démontrer qu'on n'est pas moins bon qu'une marge donnée.

**Ollama** : logiciel qui sert un modèle de langage en local.

**Q4_K_M** : compression des poids à environ 4,9 bits.

**Quantification** : stockage des poids sur moins de bits.

**RAFT** : entraîner un modèle dans les conditions du RAG.

**RAG** : réponse générée à partir de passages récupérés.

**Recall@5** : part des questions avec un passage pertinent dans les 5 premiers.

**Reclasseur** : modèle qui réordonne les candidats d'une recherche.

**RRF** : fusion de classements par leurs rangs.

**Seuil S** : score sous lequel on s'abstient sans appeler le modèle.

**Témoin T** : modèle d'origine passé par la même chaîne, sans adaptation.

**Token** : morceau de mot traité par un modèle.